



**ΔΗΜΟΚΡΙΤΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ  
ΘΡΑΚΗΣ** **DEMOCRITUS  
UNIVERSITY  
OF THRACE**

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών  
Υπολογιστών

Τομέας Ηλεκτρονικής και Συστημάτων Πληροφορικής

**Αυτόνομη ενεργειακή διαχείριση σπιτιού με σύστημα  
κλιματισμού και φωτοβολταϊκό**

**ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ**

Παναγιώτης Δ. Μιχαηλίδης  
56348

**Επιβλέπων: Ηλίας Κοσματόπουλος**  
Καθηγητής Δ.Π.Θ

Ξάνθη, Οκτώβριος, 2022

**Βεβαιώνω ότι είμαι συγγραφέας της παρούσας εργασίας και ότι έχω αναφέρει ή παραπέμπει σε αυτή, ρητά και συγκεκριμένα, όλες τις πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών, προτάσεων ή λέξεων, είτε αυτές μεταφέρονται επακριβώς (στο πρωτότυπο ή μεταφρασμένες) είτε παραφρασμένες. Επίσης βεβαιώνω ότι αυτή η εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για την συγκεκριμένη έρευνα, στο πλαίσιο εκπόνησης της διπλωματικής μου εργασίας.**

*Αφιερώνεται στην οικογένεια μου*



# Περίληψη

Η κατανάλωση ενέργειας έχει αυξηθεί ραγδαία στον κτιριακό τομέα την τελευταία δεκαετία, λόγω της αύξησης του πληθυσμού, του αυξημένου χρόνου διαμονής σε εσωτερικούς χώρους καθώς και της αυξημένης ζήτησης για λειτουργίες ποιότητας εσωτερικού περιβάλλοντος. Για το λόγο αυτό, η ενεργειακή αποδοτικότητα των κτιρίων μπορεί να προσφέρει βασικές λύσεις στην εξοικονόμηση ενέργειας, τις εκπομπές διοξειδίου του άνθρακα και γενικότερα την κλιματική αλλαγή. Σε αυτό το πλαίσιο η ανάπτυξη των έξυπνων δικτύων (smart grids) και η παροχή έξυπνων υπηρεσιών με τη χρήση μεθόδων τεχνητής νοημοσύνης, μπορούν να οδηγήσουν στη μείωση του ενεργειακού αποτυπώματος των κτιρίων. Μια προσέγγιση προς την κατεύθυνση αυτή είναι η μείωση της κατανάλωσης ηλεκτρικής ενέργειας που απαιτείται για τις ανάγκες θέρμανσης και κλιματισμού των εσωτερικών χώρων στους οποίους λειτουργούν σύνθετες διατάξεις HVAC. Τα συστήματα αυτά λόγω μεγάλης κλίμακας και αριθμού ηλεκτρομηχανικών στοιχείων, συχνά παρουσιάζουν βλάβες σε διάφορα εξαρτήματά τους, οι οποίες παρόλο που δεν διακόπτουν τη λειτουργία του συστήματος, επηρεάζουν αρνητικά την κατανάλωση ενέργειας και δεν επιτυγχάνουν τα επιθυμητά επίπεδα άνεσης ή setpoints που θέτουν οι διαχειριστές. Αυτές οι βλάβες περνούν συχνά απαρατήρητες αφού το σύστημα συνεχίζει να λειτουργεί με μη αποδοτικό τρόπο. Προς αυτή την κατεύθυνση έρχεται να συνεισφέρει η ανίχνευση και διάγνωση σφαλμάτων (fault detection & diagnosis). Η τεχνική αυτή σκοπεύει στην έγκαιρη ανίχνευση κάποιου ελαττωματικού στοιχείου του συστήματος HVAC, ώστε αυτό να επιθεωρηθεί από τους υπεύθυνους τεχνικούς και να επισκευαστεί άμεσα. Στα πλαίσια της παρούσας εργασίας, εξετάζονται οι εξελίξεις σε αυτόν τον τομέα και κατά πόσο είναι εφικτή η χρήση μεθόδων μηχανικής μάθησης με ικανοποιητικά αποτελέσματα ακρίβειας, ακόμη και κάτω από συνθήκες περιορισμών, όπως τα ελλιπή δεδομένα που παρουσιάζουν μεγάλη ετερογένεια. Για το σκοπό αυτό, χρησιμοποιούνται δύο τεχνητά σύνολα δεδομένων από προσομοιώσεις μοντέλων HVAC, με στόχο την επιτηρούμενη εκπαίδευση τεσσάρων αλγορίθμων στατιστικής μηχανικής μάθησης (K-Nearest Neighbors, Random Forest, Gradient Boosting και Support Vector Machine) και δύο αλγορίθμων βαθιάς μάθησης (ANN, LSTM) και έπειτα συγκρίνεται η ακρίβεια τους και η πρακτική τους σημασία.

# Abstract

Energy consumption has increased rapidly in the building sector over the last decade, due to population growth, increased indoor living time and growing demand for indoor environmental quality functions. For this reason, energy efficiency of buildings can provide key solutions to energy conservation, carbon emissions reduction and climate change in general. In this context the development of smart homes and provision of smart services using artificial intelligence methods, can lead to the reduction in building energy footprint. An approach to this direction, is to reduce electricity consumption required for the needs of heating and air conditioning of indoor spaces where various complex HVAC systems run constantly. These systems due to their large scale and many electromechanical components, present frequent faults to their various components, and though they do not disrupt the operation of the system, they negatively affect energy consumption and fail to reach the desirable comfort levels or setpoints that system managers set. Those faults often go unnoticed since the system continues running in a non-efficient way. To this direction the promising branch of fault detection and diagnosis (FDD) is in development. This technique aims to detect or predict a faulty system component of the HVAC pipeline, accurately and in time, so that it can be inspected and repaired by the supervising technicians. In the context of this thesis, the current state-of-the-art is examined, along with whether the use of machine learning methods is possible, under conditions of constraints, such as missing data and imbalanced labeled data. For this purpose, two simulated datasets from HVAC modeling are used, in order to impose supervised training using four statistical machine learning algorithms (K-Nearest Neighbors, Random Forest, Gradient Boosting and Support Vector Machine) and two deep learning models (ANN, LSTM) and compare their results and practical meaning.



## Πίνακας Περιεχομένων

<b>Κεφάλαιο 1. Εισαγωγή</b>	<b>8</b>
1.1 Αντικείμενο - Στόχος	8
1.2 Οργάνωση εργασίας	11
<b>Κεφάλαιο 2. Μηχανική μάθηση και έξυπνα κτίρια</b>	<b>13</b>
2.1 Έξυπνα κτίρια	13
2.2 Επισκόπηση κατηγοριών μηχανικής μάθησης	16
2.3 Εφαρμογές της μηχανικής μάθησης στα έξυπνα κτίρια	19
2.3.1 Πληρότητα χώρου (occupancy)	20
2.3.2 Αναγνώριση δραστηριότητας	21
2.3.3 Προτιμήσεις και συμπεριφορά ενοίκων	21
2.3.4 Πρόβλεψη φορτίου και ζήτησης	22
2.3.5 Ανάλυση προφίλ και διαγνωστικός έλεγχος σφαλμάτων	22
<b>Κεφάλαιο 3. Ανίχνευση και διάγνωση σφαλμάτων σε συστήματα HVAC (FDD)</b>	<b>24</b>
3.1 Γενική εικόνα του συστήματος HVAC	25
3.2 Σύνοψη σφαλμάτων που εμφανίζονται στο σύστημα HVAC	28
3.3 Πρόοδος της επιστήμης στον έλεγχο συστημάτων HVAC	29
3.4 Πρόοδος της επιστήμης στην ανίχνευση και διάγνωση σφαλμάτων HVAC	30
3.5 Σύγχρονες μέθοδοι μηχανικής μάθησης για ανίχνευση σφαλμάτων σε συστήματα κτιρίων	32
3.6 Επιλογή χαρακτηριστικών (feature selection)	33
3.7 Επιτηρούμενη μάθηση	36
3.7.1 Μηχανές διανυσμάτων στήριξης	38
3.7.2 Νευρωνικά δίκτυα	40
3.8 Μη επιτηρούμενη μάθηση	42
3.8.1 Συσταδοποίηση	42
3.8.2 Παλινδρόμηση	44
<b>Κεφάλαιο 4. Μεθοδολογία ανάπτυξης και εκτέλεσης πειράματος</b>	<b>47</b>
4.1 Θεωρητικό υπόβαθρο	47
4.1.1 Κ-κοντινότεροι γείτονες	47
4.1.2 Δένδρα αποφάσεων - τυχαία δάση	50
4.1.3 Gradient Boosting	53
4.1.4 Μηχανές διανυσμάτων στήριξης	53
4.1.5 Τεχνητά νευρωνικά δίκτυα	54
4.1.5.1 Συνελικτικά νευρωνικά δίκτυα	55
4.1.5.2 Αναδρομικά νευρωνικά δίκτυα	57
4.1.5.3 Νευρώνες μακράς-βραχυπρόθεσμης μνήμης	58
4.2 Διαδικασία ανάπτυξης	61
4.2.1 Προεπεξεργασία δεδομένων	63



4.2.2 Εκπαίδευση μοντέλων	65
4.2.2.1 Μοντέλα για το σύνολο δεδομένων MZVAV-2-2	65
4.2.2.2 Μοντέλο για το σύνολο δεδομένων MZVAV-1	68
4.2.3 Μετρικές αξιολόγησης	72
<b>Κεφάλαιο 5. Ανάλυση αποτελεσμάτων</b>	<b>74</b>
5.1 Αποτελέσματα για το σύνολο δεδομένων MZVAV-2-2	74
5.2 Αποτελέσματα για το σύνολο δεδομένων MZVAV-1	79
<b>Κεφάλαιο 6. Επίλογος</b>	<b>82</b>
Βιβλιογραφία	86

## Πίνακας Εικόνων

Εικόνα 1: Το σύστημα HVAC ευθύνεται από μόνο του για το μεγαλύτερο μέρος κατανάλωσης.	12
Εικόνα 2: Πρόγνωση της Statista του μεριδίου της αγοράς για την παγκόσμια αγορά έξυπνων σπιτιών από το 2016 έως το 2020.	17
Εικόνα 3: Δομικά στοιχεία των έξυπνων κτιρίων (SB).	17
Εικόνα 4: Οι τέσσερις γενικές κατηγορίες Μηχανικής Μάθησης όπως περιγράφηκαν παραπάνω.	21
Εικόνα 5: Γενικό πλαίσιο λύσεων μηχανικής μάθησης στα έξυπνα κτίρια.	22
Εικόνα 6: Οι βασικές κατηγορίες λύσεων μηχανικής μάθησης στα έξυπνα κτίρια.	22
Εικόνα 7: Οι τύποι μονάδων AHU, με τις διαφορές τους όπως περιγράφηκαν παραπάνω.	28
Εικόνα 8: Σχηματικό διάγραμμα ενός γενικού συστήματος HVAC που περιλαμβάνει μονάδα θέρμανσης, μονάδα ψύξης και AHU, κουτια VAV, επιτοίχια σώματα καλοριφέρ και υποδαπέδια θέρμανση για κάθε δωμάτιο.	29
Εικόνα 9: Κατηγοριοποίηση των μεθόδων ανίχνευσης και διάγνωσης σφάλματος.	33
Εικόνα 10: Το δέντρο των μεθοδολογιών που βασίζονται στην εκμάθηση πάνω σε δεδομένα.	34

Εικόνα 11: Ανάλυση κυρίων συνιστωσών στο διδιάστατο επίπεδο. Η πράσινη ευθεία αντιστοιχεί στην πρώτη κύρια συνιστώσα, όπου μεγιστοποιείται η διακύμανση των μπλε σημείων.	38
Εικόνα 12: Ένα-προς-ολα (ΟvO) ταξινόμηση.	41
Εικόνα 13: Perceptron πολλαπλών στρωμάτων σύμφωνα με το Θεώρημα Καθολικής Προσέγγισης.	42
Εικόνα 14: Αναπαράσταση της μεθόδου DBSCAN.	44
Εικόνα 15: Έξι στάδια επανάληψης της συσταδοποίησης K-means.	45
Εικόνα 16: Ταξινόμηση άγνωστης παρατήρησης.	51
Εικόνα 17: Η διαδικασία κατασκευής τυχαίων δασών.	53
Εικόνα 18: Τα δεδομένα της εικόνας στο διδιάστατο χώρο δεν είναι γραμμικώς διαχωρίσιμα, όταν όμως προβληθούν στον τριδιάστατο χώρο μπορεί να βρεθεί ένα επίπεδο που τα διαχωρίζει.	56
Εικόνα 19: Τεχνητός νευρώνας.	57
Εικόνα 20: Αρχιτεκτονική συνελκτικού νευρωνικού δικτύου.	58
Εικόνα 21: Παράδειγμα διαδικασίας συνέλιξης.	58
Εικόνα 22: Παράδειγμα τεχνικής max pooling.	59
Εικόνα 23: Ξεδιπλωμένο αναδρομικό νευρωνικό δίκτυο.	60
Εικόνα 24: Η δομή ενός LSTM νευρώνα.	61
Εικόνα 25: Αρχιτεκτονική αμφίδρομου LSTM.	62
Εικόνα 26: Κατανομές τιμών αληθείας για τα dataset MZVAV-1 και MZVAV-2-2.	64
Εικόνα 27: Στοιχεία των datasets.	64
Εικόνα 28: Το θηκόγραμμα του συνόλου.	66
Εικόνα 29: Πίνακας συσχέτισης.	67

Εικόνα 30: Το σύστημα στο μεγαλύτερο μέρος του λειτουργεί με σφάλμα.	70
Εικόνα 31: Πίνακας σύγκρισης μεθόδου KNN.	76
Εικόνα 32: Πίνακας σύγκρισης μεθόδου RF.	77
Εικόνα 33: Πίνακας σύγκρισης μεθόδου Gradient Boost.	78
Εικόνα 34: Πίνακας σύγκρισης μεθόδου SVM.	79
Εικόνα 35: Η γραφική παράσταση του σφάλματος εκπαίδευσης για το DNN	80
Εικόνα 36: Πίνακας σύγκρισης.	80
Εικόνα 37: Πίνακας σύγκρισης για το μοντέλο LSTM.	81
Εικόνα 38: Η καμπύλη ROC αποτελεί ένδειξη της επικάλυψης των κατανομών True Positive και True Negative τιμών. Όταν το AUC είναι 0.85, αυτό σημαίνει ότι το μοντέλο έχει πιθανότητα 85% να ξεχωρίσει την κλάση 0 (Normal) από την κλάση 1 (Faulty).	82

### Υπόμνημα Πινάκων

<b>Πίνακας 1:</b> Αρχιτεκτονική του μοντέλου LSTM που εφαρμόστηκε	72
<b>Πίνακας 2:</b> Υπερπαράμετροι εκπαίδευσης LSTM	73
<b>Πίνακας 3:</b> Αναφορά ταξινόμησης για τη μέθοδο K-Nearest Neighbours	76
<b>Πίνακας 4:</b> Αναφορά ταξινόμησης για τη μέθοδο Random Forest	77
<b>Πίνακας 5:</b> Αναφορά ταξινόμησης για τη μέθοδο Gradient Boost	78
<b>Πίνακας 6:</b> Αναφορά ταξινόμησης για τη μέθοδο Support Vector Machine	79
<b>Πίνακας 7:</b> Αναφορά ταξινόμησης για τη μέθοδο Artificial Neural Network	80
<b>Πίνακας 8:</b> Αναφορά ταξινόμησης για τη μέθοδο LSTM	81

# Κεφάλαιο 1. Εισαγωγή

## 1.1 Αντικείμενο - Στόχος

Η θέρμανση, ο εξαερισμός και ο κλιματισμός (heating, ventilation and air-conditioning, HVAC), είναι ή χρήση διαφόρων τεχνολογιών για τον έλεγχο της θερμοκρασίας, της υγρασίας και της ποιότητας του αέρα σε έναν κλειστό χώρο. Ο στόχος ενός τέτοιου συστήματος είναι να παρέχει άνεση και ασφάλεια για την υγεία ποιότητα του εσωτερικού αέρα. Ο σχεδιασμός ενός συστήματος HVAC ανήκει στον κλάδο της μηχανολογίας, καθώς βασίζεται στις βασικές αρχές της θερμοδυναμικής, της μηχανικής ρευστών και της μεταφοράς θερμότητας.

Ο τομέας των κτιρίων ευθύνεται περίπου για το 40% της παγκόσμιας ενεργειακής κατανάλωσης, η οποία εξακολουθεί να αυξάνεται τις τελευταίες δεκαετίες [85,86]. Επιπλέον, αναγνωρίζεται συχνά ως ο τομέας με τη μεγαλύτερη προοπτική για εξοικονόμηση ενέργειας, σε σύγκριση με άλλες πτυχές της οικονομίας. Η ενεργειακή κατανάλωση των κτιρίων οφείλεται σε μεγάλο βαθμό στις ανάγκες θέρμανσης, εξαερισμού και κλιματισμού, αντιπροσωπεύοντας πάνω από το 40% του συνολικού ενεργειακού φορτίου (87).

Στην Ευρώπη, τα κτίρια ευθύνονται επίσης για το 40% περίπου της κατανάλωσης ενέργειας, και το 28% των εκπομπών διοξειδίου του άνθρακα (CO<sub>2</sub>) [1,2]. Μεγάλο μέρος αυτής της ενέργειας οφείλεται στον κλιματισμό, ιδίως την ψύξη και θέρμανση. Πράγματι, η εσφαλμένη λειτουργία των εγκαταστάσεων αυτών οδηγεί σε σημαντική σπατάλη, προκαλώντας 20-30% αύξηση στην ολική ενέργεια που απαιτεί το κτίριο [3].

Στην Ελλάδα, το ποσοστό της καταναλισκόμενης ενέργειας για θέρμανση σε κτίρια και κατοικίες αγγίζει το 64%, σύμφωνα με μελέτη της ΕΛ.ΣΤΑΤ, με τα ελληνικά κτίρια να χαρακτηρίζονται ιδιαίτερα ενεργοβόρα, λόγω παλαιότητας (μερική ή παντελής έλλειψη θερμομόνωσης) και μη ενσωμάτωσης σύγχρονων τεχνολογιών, που οφείλεται στην έλλειψη σχετικής νομοθεσίας τα τελευταία 30 έτη.<sup>1</sup> Οι σύγχρονες τάσεις εξοικονόμησης ενέργειας και μείωσης του ενεργειακού αποτυπώματος, θέτουν υψηλούς στόχους για το εγγύς μέλλον. Για την επίτευξη αυτών των απαιτήσεων υψηλής απόδοσης, η προσέγγιση συντήρησης και διαχείρισης του κτιριακού εξοπλισμού πρέπει να βελτιωθεί.

Ο έλεγχος του θερμικού περιβάλλοντος αποτελεί βασικό στόχο ουσιαστικά για όλα τα κατειλημμένα κτίρια. Για πολλές χιλιετίες, ο έλεγχος αυτός απλά περιοριζόταν στην προσπάθεια να εξασφαλιστεί η επιβίωση κατά τη διάρκεια των ψυχρών χειμώνων. Στο σύγχρονο κόσμο, οι προσδοκίες του θερμικού ελέγχου πηγαίνουν αρκετά πέρα από την επιβίωση και περιλαμβάνουν τις σύνθετες θεωρήσεις για

---

<sup>1</sup> <https://ypen.gov.gr/>

θερμική άνεση και ποιότητα του αέρα, που επηρεάζουν την υγεία, την ικανοποίηση και την παραγωγικότητα των ατόμων που καταλαμβάνουν τους χώρους του κάθε κτιρίου.

Ένα σύστημα θέρμανσης ("H" του HVAC) σχεδιάζεται για να προσθέτει θερμική ενέργεια σε ένα χώρο ή κτίριο, προκειμένου να διατηρείται κάποια επιλεγμένη θερμοκρασία αέρα, η οποία ειδικά δεν θα μπορούσε να επιτευχθεί λόγω της ροής της θερμότητας προς το εξωτερικό περιβάλλον (απώλεια θερμότητας). Ένα σύστημα εξαερισμού ("V") έχει ως σκοπό του το να κυκλοφορεί τον αέρα σε ένα χώρο, ώστε να τον κινεί χωρίς να χρειάζεται να αλλάξει η θερμοκρασία του. Τα συστήματα εξαερισμού μπορούν, και σε ορισμένες περιπτώσεις πρέπει, να χρησιμοποιούνται για να βελτιώνουν την ποιότητα του εσωτερικού αέρα και, κατ' αυτόν τον τρόπο, τα επίπεδα άνεσης των ενοίκων.


Ένα σύστημα ψύξης (ή, αλλιώς, δροσισμού), που δεν περιλαμβάνεται ρητά ως έννοια στο αρκτικόλεξο HVAC, σχεδιάζεται για να αφαιρεί θερμική ενέργεια από ένα χώρο ή κτίριο. Αυτό είναι ανάγκη να γίνεται προκειμένου να διατηρείται κάποια επιλεγμένη θερμοκρασία του αέρα, χαμηλότερη συγκριτικά με αυτή που, αλλιώς, θα επικρατούσε λόγω της αναπόφευκτης ροής θερμότητας τόσο από τις εσωτερικές πηγές της, όσο και από το εξωτερικό περιβάλλον προς το εσωτερικό του χώρου (κέρδος θερμότητας). Οι ψυκτικές διατάξεις εξετάζονται συνήθως ως τμήμα του "AC", σε σχέση με τα αρχικά HVAC. Το "AC" υποδηλώνει τον κλιματισμό (Air-Conditioning).

Ένα σύστημα κλιματισμού, σύμφωνα με τον ορισμό της ASHRAE (Αμερικάνικη Ομοσπονδία των Μηχανικών Θέρμανσης, Κατάψυξης και Κλιματισμού), είναι μία συνάθροιση συνιστωσών, με μια καθορισμένη δομή και λειτουργία, που πρέπει να εκπληρώνει τέσσερις στόχους ταυτόχρονα. Αυτοί είναι ο έλεγχος:

- της θερμοκρασίας του αέρα,
- της υγρασίας του αέρα,
- της κυκλοφορίας του αέρα και
- της ποιότητας του αέρα.

Η λειτουργία των συστημάτων HVAC ευθύνεται τουλάχιστον για ένα ποσοστό 30% της συνολικής ενεργειακής κατανάλωσης. Ωστόσο, έχει πλέονδειχθεί ότι μόλις σε ένα μικρό τμήμα κτιρίων οι εγκαταστάσεις HVAC λειτουργούν απρόσκοπτα και αποδοτικά σύμφωνα με τις προδιαγραφές σχεδιασμού τους [4,5]. Η **εικόνα 1** απεικονίζει σε γράφημα (pie chart) τους τομείς που είναι υπεύθυνοι για εκτεταμένη κατανάλωση ενέργειας μέσα σε ένα κτίριο. Μερικές μελέτες αναφέρουν ότι το σύστημα HVAC καταναλώνει περίπου το 40% της συνολικής ενέργειας του κτιρίου [84].

Μελέτες έχουν δείξει ότι τα λειτουργικά σφάλματα είναι ένας από τους κύριους λόγους της μη αποδοτικής λειτουργίας αυτών των συστημάτων. Υπολογίζεται ότι είναι εφικτή μια εξοικονόμηση ενέργειας 5 έως 15% απλά και μόνο επιδιορθώνοντας τα σφάλματα αυτά και βελτιστοποιώντας τα κτιριακά συστήματα ελέγχου [6].



**Εικόνα 1:** Το σύστημα HVAC ευθύνεται από μόνο του για το μεγαλύτερο μέρος κατανάλωσης [83, 84].

Οι συνήθεις μέθοδοι ανίχνευσης σφαλμάτων ή σταδιακής απώλειας απόδοσης στα συστήματα HVAC είναι επίπονη διαδικασία. Τυπικά, οι διαχειριστές του κτιρίου ή οι μηχανικοί συντήρησης χρησιμοποιούν τη διαίσθησή τους καθώς και διάφορα σετ από εμπειρικούς κανόνες για να ταυτοποιήσουν που είναι το πρόβλημα. Στην πράξη, η κουραστική φύση αυτών των διεργασιών είναι τέτοια ώστε να μην εκτελούνται συστηματικά, ή και να μην εκτελούνται καθόλου στα περισσότερα κτίρια. Αν υπάρχει βλέψη για την εξοικονόμηση μέχρι 15% που αναφέραμε, τα συστήματα ενεργειακής διαχείρισης κτιρίων πρέπει να είναι ικανά να ανιχνεύουν τότε έχει συμβεί μια αστοχία ή τότε η απόδοση αρχίζει να κυλάει προς τα κάτω, και να μπορούν να εντοπίσουν τα πιθανά υπαίτια στοιχεία ή συνθήκες λειτουργίας. Τα αυτοματοποιημένα συστήματα ανίχνευσης σφαλμάτων είναι επομένως ουσιώδη για την εκπλήρωση των “πράσινων” στόχων που θέτουν ολοένα και περισσότερες χώρες.

Το ζήτημα του αυτοματοποιημένου εντοπισμού σφαλμάτων και διαγνωστικής (Fault Detection and Diagnostics, FDD) αποτελεί ενεργό πεδίο έρευνας και ανάπτυξης τις τελευταίες τέσσερις δεκαετίες σε εφαρμογές όπως η αεροναυπηγική, ο έλεγχος διεργασιών, η αυτοκίνηση και η βιομηχανία [7,8]. Στις εγκαταστάσεις HVAC κτιρίων, η FDD λαμβάνει ολοένα και αυξανόμενη προσοχή κυρίως τα τελευταία είκοσι χρόνια. Πλέον έχει αναπτυχθεί ένα πλήθος διαγνωστικών μεθόδων, από προσεγγίσεις μοντέλων βασισμένων στους φυσικούς νόμους μέχρι προσεγγίσεις εμπειρικών μοντέλων και μοντέλων με βάση ποιοτικούς κανόνες (qualitative/rule based) για τον εντοπισμό και την απομόνωση σφαλμάτων στα συστήματα HVAC [9].

Παρά την πρόοδο των τελευταίων ετών, οι μέθοδοι διαχείρισης σφαλμάτων σε συστήματα HVAC κτιρίων παραμένουν γενικά υποανάπτυκτες. Συγκεκριμένα, η έλλειψη αξιόπιστων, οικονομικά βιώσιμων και επεκτάσιμων λύσεων για τη διαχείριση σφαλμάτων εξακολουθεί να υπάρχει. Υπάρχουν διάφορες εξηγήσεις για αυτό, από τεχνικά εμπόδια μέχρι οικονομικά κίνητρα, που ευθύνονται για την μικρή υιοθέτηση και περιορισμένη διαθεσιμότητα πρακτικών συστημάτων FDD στα κτίρια [12]. Από τεχνικής άποψης, κάτι που πραγματεύεται και η συγκεκριμένη εργασία, υπάρχουν σίγουρα περιορισμοί στη μοντελοποίηση, τις μετρήσεις, και την διαφοροποίηση και πολλαπλότητα των σφαλμάτων που εμφανίζονται, και αυτό συνθέτει ένα ακόμη πιο σύνθετο πρόβλημα από ότι φαίνεται αρχικά.

Η απόδοση και εξοικονόμηση ενέργειας των εγκαταστάσεων HVAC κτιρίων μπορεί να βελτιωθεί με την υλοποίηση καλύτερης στρατηγικής ανίχνευσης σφαλμάτων του εξοπλισμού. Αντλώντας έμπνευση από τα παραπάνω, η παρούσα εργασία παρουσιάζει τις τελευταίες εξελίξεις στον τομέα εντοπισμού σφαλμάτων καθώς και την υλοποίηση κάποιων μοντέλων με τεχνικές μηχανικής μάθησης πάνω σε δεδομένα λειτουργίας από δύο εγκαταστάσεις HVAC. Επιδιώκεται έτσι να διαπιστωθεί κατά πόσο αυτές οι τεχνικές μπορούν να ενταχθούν στο σύστημα διαχείρισης ενέργειας (Building Energy Management System, BEMS) των έξυπνων κτιρίων (smart buildings) όπου θα διαπιστώνουν ή θα προβλέπουν επικείμενα σφάλματα, ώστε να διορθωθούν εγκαίρως, αντικαθιστώντας τον ανθρώπινο παράγοντα στο κομμάτι της επιτήρησης.

## 1.2 Οργάνωση εργασίας

Στο πρώτο κεφάλαιο γίνεται μια εισαγωγή στο αντικείμενο της πρόβλεψης και διάγνωσης σφαλμάτων σε συστήματα HVAC κτιρίων, τίθεται ο γενικός σκοπός ενώ περιγράφονται τα βήματα υλοποίησης.

Στο δεύτερο κεφάλαιο πραγματοποιείται μια συστηματική βιβλιογραφική ανασκόπηση των κατηγοριών μηχανικής μάθησης (Machine Learning), και καταδεικνύεται το αυξανόμενο ενδιαφέρον και η ταχεία εξάπλωση της χρήσης τέτοιων τεχνικών για την επιτυχή αντιμετώπιση των προκλήσεων στα έξυπνα σπίτια στα οποία εντάσσεται και ο έλεγχος των HVAC.

Στο τρίτο κεφάλαιο περιγράφεται η βασική δομή και κάποιες αρχές λειτουργίας ενός συστήματος θέρμανσης, εξαερισμού και κλιματισμού κτιρίου, καθώς και τα σημεία στα οποία εμφανίζονται συνήθως σφάλματα. Έπειτα αναφέρονται οι τρεις βασικές κατηγορίες ανίχνευσης και διάγνωσης σφαλμάτων με τα πλεονεκτήματα και μειονεκτήματά τους.

Στο τέταρτο κεφάλαιο γίνεται μια προσπάθεια σύνοψης της τελευταίας λέξης της τεχνολογίας στις εφαρμογές μηχανικής μάθησης για ανίχνευση και διάγνωση σφαλμάτων σε συστήματα HVAC, chillers, και παρεμφερείς εγκαταστάσεις,

Στο πέμπτο κεφάλαιο περιγράφεται η προσέγγιση που υιοθετήθηκε για τη συγκεκριμένη εργασία. Αρχικά πραγματοποιείται μια θεωρητική ανάλυση των αλγορίθμων που χρησιμοποιήθηκαν, ώστε να καταστεί μια διαισθητική κατανόηση του τρόπου λειτουργίας τους και στη συνέχεια περιγράφονται τα στάδια υλοποίησης.

Στο έκτο κεφάλαιο γίνεται μια σύγκριση των αποτελεσμάτων και ορισμένες παρατηρήσεις πάνω στα μοντέλα που αναπτύχθηκαν, με τη χρήση κατάλληλων μετρικών, και εξάγονται χρήσιμα συμπεράσματα καθώς και προτάσεις-ιδέες για τεχνικές που δείχνουν υποσχόμενο μέλλον.



## Κεφάλαιο 2. Μηχανική μάθηση και έξυπνα κτίρια

Οι αλγόριθμοι τεχνητής νοημοσύνης (Artificial Intelligence, AI) και μηχανικής μάθησης (Machine Learning, ML) απολαμβάνουν ευρεία χρήση σε πολλαπλούς τομείς, όπως στην αναγνώριση ομιλίας και εικόνων, στη βελτιστοποίηση συστημάτων, στους αυτοματισμούς, καθώς και στην οικονομία. Αν και ο όρος “έξυπνο κτίριο” (smart building, SB) μπορεί να φέρνει συνειρμούς ενός φανταστικού έξυπνου χώρου από κάποια ταινία επιστημονικής φαντασίας, η πραγματικότητα είναι ότι τα έξυπνα κτίρια υπάρχουν και ολοένα αυξάνονται. Με τις πρόσφατες εξελίξεις στη μηχανική μάθηση, την ανάλυση μεγάλων δεδομένων (big data), τις τεχνολογίες αισθητηρίων και το διαδίκτυο των πραγμάτων (Internet of Things, IoT), τα απλά κτίρια μπορούν με οικονομικά βιώσιμο τρόπο να μετατραπούν σε έξυπνα κτίρια, με λίγες βασικές μετατροπές στις υποδομές τους. Υπάρχουν έξυπνα γραφεία, βιβλιοθήκες, σπίτια, εγκαταστάσεις περίθαλψης, που μπορούν να παρέχουν αυτοματοποιημένες υπηρεσίες με μεγάλα οφέλη (όπως μείωση της σπατάλης ρεύματος) και να διασφαλίζουν την άνεση, την υγεία και την ασφάλεια των ενοίκων.

Η υπερσυνδεσιμότητα που θα φέρει η άνοδος του IoT θα αυξήσει αυτές τις μεγάλες υποσχέσεις που δίνουν τα έξυπνα κτίρια, καθώς πλέον όλες οι βασικές παροχές των κτιρίων, από τα ψυγεία μέχρι τα πλυντήρια ρούχων και τα κλιματιστικά, θα είναι διασυνδεδεμένα. Όμως όλη αυτή η ευκολία σύνδεσης και πληθώρα δεδομένων που είναι διαθέσιμα, περιπλέκουν ταυτόχρονα τη διαχείριση των έξυπνων κτιρίων. Η μηχανική μάθηση, η δειγματοληψία και συμπίεση, η εκπαίδευση (τόσο των συσκευών όσο και των χρηστών), αποκτούν ολοένα και περισσότερη σημασία στην ερμηνεία και τη διαχείριση ροών μεγάλων δεδομένων [10].

### 2.1 Έξυπνα κτίρια

Το 1981, ο όρος έξυπνα κτίρια (Intelligent Buildings - IBs) προτάθηκε από την εταιρία ενωμένης τεχνολογίας κτιριακών συστημάτων (UTBS) στις Η.Π.Α. Τον Ιούλιο του 1983, τα IBs έγιναν πραγματικότητα με τα εγκαίνια του κτιρίου City Place στο Hartford του Κονέκτικατ [11]. Στις μέρες μας, ο αριθμός “έξυπνων” κτιρίων αυξάνεται ραγδαία, συμπεριλαμβάνοντας έξυπνα γραφεία, εγκαταστάσεις διαμονής, εκπαίδευσης κ.τ.λ. Ένα SB ή IB περιγράφεται ως ένα ενοποιημένο σύστημα που εκμεταλλεύεται το εύρος των υπολογιστικών και τηλεπικοινωνιακών υποδομών και τεχνικών [13]. Παραδείγματα τέτοιων έξυπνων υπηρεσιών είναι οι έξυπνοι θερμοστάτες που επιτρέπουν τον έλεγχο της θερμοκρασίας με βάση τη χρονική περίοδο της ημέρας (ανάλογα και με την εποχή) και τις προτιμήσεις των χρηστών, με ελάχιστη ή μηδενική χειροκίνητη ρύθμιση, χρησιμοποιώντας ανάλυση δεδομένων για να “μάθουν” από τις συνήθειες των ενοίκων προτού ενεργήσουν κατάλληλα. Πρόσφατα, έξυπνες καφετιέρες έκαναν την εμφάνισή τους στην αγορά, με τη δυνατότητα να ετοιμάζουν τον καφέ αυτόματα, ανάλογα με τις συνήθειες των

χρηστών, όπως επίσης ψυγεία που προσφέρουν εξειδικευμένες διεπαφές ελέγχου στο κινητό των χρηστών.


Προκειμένου να μεγιστοποιούν την άνεση, να ελαχιστοποιούν το κόστος και να προσαρμόσθούν στις ανάγκες των ενοίκων, τα SBs στηρίζονται σε εκλεπτυσμένα εργαλεία για να μάθουν, να προβλέψουν και να πάρουν έξυπνες αποφάσεις. Οι αλγόριθμοι SB καλύπτουν ένα μεγάλο εύρος τεχνολογιών, συμπεριλαμβανομένων της πρόβλεψης (prediction), της λήψης αποφάσεων (decision-making), της ρομποτικής, των έξυπνων υλικών, των ασύρματων δικτύων αισθητήρων, πολυμέσων και υπολογιστικού νέφους. Χάρη σε αυτές τις τεχνολογίες, τα κτίρια μπορούν αυτοβούλως να διαχειρίζονται πολλές έξυπνες υπηρεσίες που έχουν να κάνουν με την ασφάλεια, την ιδιωτικότητα, την ενεργειακή αποδοτικότητα, τη συντήρηση και γενικά, το επίπεδο των συνθηκών διαβίωσης και ψυχαγωγίας.

Η τεράστια ποσότητα αισθητηριακών δεδομένων από μετρητές και συσκευές πρέπει να αναλυθούν από αλγόριθμους και να μετασχηματιστούν σε χρήσιμες πληροφορίες από τις οποίες θα εξορυχθεί γνώση ώστε οι μηχανές να αντιληφθούν τους ανθρώπους και το περιβάλλον τους. Επιπρόσθετα, όλη αυτή η γνώση μπορεί να αξιοποιηθεί και για την ανάπτυξη νέων απομακρυσμένων υπηρεσιών, όπως για παράδειγμα την παρακολούθηση ασθενών που φορούν φορητές συσκευές με αισθητήρες, αλλά και τη βελτίωση συστημάτων μεγαλύτερης κλίμακας, για παράδειγμα τα συστήματα κλιματισμού HVAC, που αποτελούν και κομμάτι αυτής της μελέτης.

Σύμφωνα με μία αναφορά της MarketsandMarkets [14], η αγορά των έξυπνων κτιρίων αναμένεται να αναπτυχθεί από τα 7.42 δισεκατομμύρια δολάρια το 2017 σε 32.74 δισεκατομμύρια δολάρια το 2022. Σύμφωνα πάλι με μία άλλη μελέτη, μέχρι το 2024 η αγορά προβλέπεται να φτάσει τα 61 δις, με εντυπωσιακό ετήσιο ρυθμό αύξησης. Η αγορά οδηγείται πρωτίστως από κυβερνητικές πρωτοβουλίες παγκοσμίως, καθώς οι διεθνείς προτάσεις πράσινης ανάπτυξης και εξοικονόμησης ενέργειας συμπεριλαμβάνουν και ενσωματωμένες λύσεις για τη διαχείριση των ενεργειακών συστημάτων των κτιρίων. Η **εικόνα 2** δείχνει την πρόγνωση της Statista του μεριδίου της αγοράς για την παγκόσμια αγορά έξυπνων σπιτιών από το 2016 έως το 2022 (σε δισεκατομμύρια δολάρια) [15].

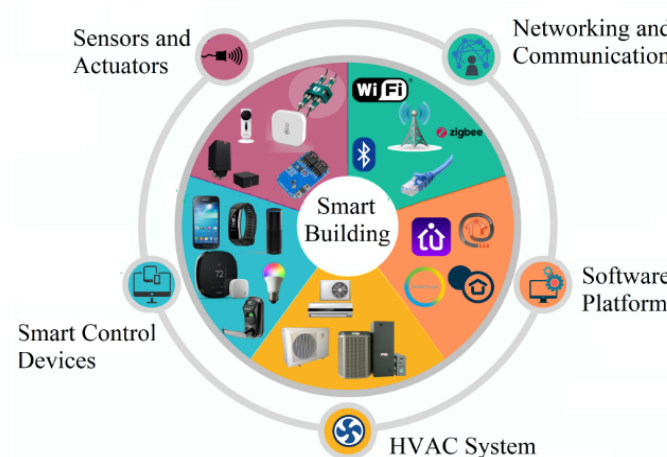
Όπως έγινε αντιληπτό, τα έξυπνα κτίρια είναι απλώς μια νέα γενικά κτιρίων που περιέχουν το συνδυασμό πολλών τεχνολογιών και υπάρχει η δυνατότητα ενσωμάτωσης και νεότερων στο μέλλον. Καθώς λοιπόν υπάρχουν πολλοί “παίκτες” της βιομηχανίας που αλληλεπιδρούν για τη δημιουργία τέτοιων κτιρίων, είναι δύσκολο να δοθεί ένας αυστηρός ορισμός στις μέρες μας ή μια μόνο οπτική αποδεκτή και κοινή σε όλο τον κόσμο. Ωστόσο, είναι σημαντικό να έχουμε μια καλή κατανόηση του κυρίως σώματος και των βιομηχανικών κλάδων που εμπλέκονται στο σχηματισμό και την ανάπτυξη έξυπνων σπιτιών. Σύμφωνα με την “Ψηφιακή κοινωνία και κοινωνία της πληροφορίας” της Ευρωπαϊκής Επιτροπής [16], έξυπνα κτίρια σημαίνει

κτίρια που τροφοδοτούνται με πληροφορίες και τηλεπικοινωνιακές τεχνολογίες στο γενικό πλαίσιο του συνδυασμού της παγκόσμιας πληροφορικής (Ubiquitous Computing) και του IoT.



**Εικόνα 2:** Πρόγνωση της Statista του μεριδίου της αγοράς για την παγκόσμια αγορά έξυπνων σπιτιών από το 2016 έως το 2022 [15].

Η **εικόνα 3** δείχνει παραδείγματα έξυπνων διατάξεων, συμπεριλαμβανομένων και των συστημάτων κλιματισμού, φωτισμού, ηλιακής παραγωγής ενέργειας, τροφοδοσίας, αισθητήρων θερμοκρασίας, υγρασίας και ηλεκτρικής ισχύος. Ο κεντρικός έλεγχος όλων αυτών των στοιχείων μπορεί να προωθήσει την αποδοτική χρήση ενέργειας μέσω της ευφυούς διαχείρισης όλων των στοιχείων και την παροχή πληροφοριών και ειδοποιήσεων στους χρήστες για την κατάσταση λειτουργίας τους.



**Εικόνα 3:** Δομικά στοιχεία των έξυπνων κτιρίων (SB) [88].

Όπως σημειώθηκε προηγουμένως, η ενσωμάτωση συσκευών IoT σε κάθε τομέα της υποδομής του δικτύου είναι ένα υποχρεωτικό βήμα για τη μετάβαση προς το

έξυπνο δίκτυο. Έχει επίσης αναφερθεί ότι το καθοριστικό χαρακτηριστικό αυτών των συσκευών είναι η ικανότητά τους να επικοινωνούν με άλλες συσκευές και κέντρα ελέγχου και να στέλνουν χρήσιμες πληροφορίες. Έτσι, ένας τεράστιος όγκος δεδομένων παράγεται σε ένα διασυνδεδεμένο δίκτυο, θέτοντας προκλήσεις για τις συμβατικές μεθόδους μεταφοράς, αποθήκευσης και ανάλυσης δεδομένων. Τα “μεγάλα δεδομένα” (Big Data) αναφέρονται σε τεράστιο όγκο δεδομένων, που απαιτεί πιο προηγμένες μεθόδους για τη σύλληψη, την επιμέλεια, τη διαχείριση και την ανάλυση από τα παραδοσιακά εργαλεία και τα μοντέλα επεξεργασίας σήματος.

Ο όγκος των δεδομένων που ορίζει τα Big Data δεν ορίζεται ρητά, αλλά επαναπροσδιορίζεται καθώς η τεχνολογία εξελίσσεται. Γενικά, τα δεδομένα τα οποία παρουσιάζουν τα ακόλουθα χαρακτηριστικά μπορούν να θεωρηθούν ως μεγάλα δεδομένα: έχουν μεγάλο όγκο, η ταχύτητα ή η συχνότητα παραγωγής, αποθήκευσης ή μετάδοσης των δεδομένων είναι υψηλή, και υπάρχει μεγάλη ποικιλία στο σύνολο δεδομένων.

Η πιο προφανής πρόκληση που προκύπτει από την παραγωγή μεγάλου όγκου δεδομένων από το έξυπνο δίκτυο είναι οι αποτελεσματικοί τρόποι ανάλυσής τους, για την εξαγωγή πολύτιμων πληροφοριών. Χωρίς την εξαγωγή χρήσιμων πληροφοριών, τα δεδομένα που συλλέγονται έχουν μικρή ή μηδενική αξία. Η μηχανική μάθηση εμφανίζεται ως το εργαλείο που απαιτείται, για το υψηλό έργο της διερεύνησης του τεράστιου όγκου δεδομένων που παράγονται σε ένα σύστημα δικτύου, βασισμένο στο IoT. Μπορεί να θεωρηθεί ως το τελευταίο κομμάτι του συστήματος έξυπνου δικτύου, το οποίο καθοδηγείται από τη συλλογή δεδομένων, την ανάλυση και τη λήψη αποφάσεων. Οι τεχνικές μηχανικής μάθησης παρέχουν έναν αποτελεσματικό τρόπο ανάλυσης, με απώτερο σκοπό τη λήψη των κατάλληλων αποφάσεων για τη λειτουργία του δικτύου, επιτρέποντας έτσι στο έξυπνο δίκτυο να λειτουργεί όπως προβλέπεται.

## **2.2 Επισκόπηση κατηγοριών μηχανικής μάθησης**

Η μηχανική μάθηση αποτελεί μια τεχνική ανάλυσης δεδομένων οποία στοχεύει στην εκπαίδευση υπολογιστών, έτσι ώστε μέσα από μια διαδικασία μάθησης να μπορούν να εκτελούν εργασίες όπως ο άνθρωπος. Η έρευνα γύρω από τη μηχανική μάθηση διερευνά τη μελέτη και την κατασκευή αλγορίθμων, οι οποίοι μπορούν να μαθαίνουν από τα δεδομένα και να πραγματοποιούν προβλέψεις σχετικά με αυτά. Οι αλγόριθμοι χρησιμοποιούν υπολογιστικές μεθόδους, για να αξιοποιούν απαραίτητες πληροφορίες απευθείας από τα δεδομένα, χωρίς να βασίζονται σε προκαθορισμένες εξισώσεις, ενώ η αύξηση της διαθεσιμότητας των δεδομένων μπορεί να βελτιώσει σημαντικά την απόδοσή τους. Τέτοιοι αλγόριθμοι λειτουργούν κατασκευάζοντας μοντέλα από πειραματικά δεδομένα, προκειμένου να κάνουν προβλέψεις βασιζόμενες στα δεδομένα ή να εξάγουν αποφάσεις. Η Μηχανική μάθηση εφαρμόζεται σε μια σειρά από υπολογιστικές εργασίες, όπου τόσο ο σχεδιασμός όσο και ο ρητός προγραμματισμός των αλγορίθμων είναι ανέφικτος. Κατά τη διάρκεια της τελευταίας

δεκαετίας, η μηχανική μάθηση έχει επιδείξει μια πολλά υποσχόμενη συμβολή σε πολλούς τομείς έρευνας και μηχανικής, βοηθώντας σε εφαρμογές όπως είναι η οπτική αναγνώριση χαρακτήρων, οι μηχανές αναζήτησης και τα φίλτρα spam e-mails [17].

Η ενσωμάτωση προηγμένων τεχνολογιών πληροφορικής και επικοινωνιών στην υποδομή του ηλεκτρικού δικτύου, ιδίως του IoT, είναι ένα από τα πρωταρχικά βήματα προς το έξυπνο δίκτυο. Η συνεχής διείσδυση διαφόρων μορφών ανανεώσιμων πηγών ενέργειας και διακοπτόμενων συστημάτων σε συνδυασμό με την αξιόπιστη πλέον επικοινωνία μεταξύ των διαφόρων οντοτήτων του δικτύου, έχει δημιουργήσει μια σειρά τεχνικών προκλήσεων. Συγκεκριμένα, οι προκλήσεις αυτές περιλαμβάνουν τον αυξανόμενο όγκο δεδομένων που παράγονται σε όλο το δίκτυο, την παράλληλη ανάγκη αποθήκευσης και επεξεργασίας δεδομένων, την ανάγκη διαχείρισης μη γραμμικών συστημάτων ισχύος με μεταβλητά χωροχρονικά χαρακτηριστικά, τις αυστηρές απαιτήσεις σταθερότητας συχνότητας και τάσης του συστήματος, όπως επίσης και την ανάγκη ασφάλειας του συστήματος έναντι απειλών.

Είναι ευρέως αποδεκτό ότι οι συμβατικές τεχνικές υπολογισμού και διαχείρισης που χρησιμοποιούνται στα συστήματα ηλεκτρικής ενέργειας δεν είναι πλέον επαρκείς για την αντιμετώπιση των προαναφερθέντων ζητημάτων, λόγω των περιορισμών τους στον χειρισμό και την ανάλυση του τεράστιου όγκου δεδομένων, της περιορισμένης γενίκευσης των συμβατικών μοντέλων, της ανεπάρκειας αυτόνομων λειτουργιών και επεξεργασίας σε πραγματικό χρόνο, της μεγάλης εξάρτησης από κεντρικές στρατηγικές ελέγχου αλλά και της έλλειψης ικανότητας μοντελοποίησης εξαιρετικά μη γραμμικών συστημάτων. Η ανεπάρκεια και οι περιορισμοί των συμβατικών υπολογιστικών τεχνικών αναδεικνύουν το κίνητρο της χρήσης τεχνικών μηχανικής μάθησης.

Οι τεχνικές μηχανικής μάθησης μπορούν να ταξινομηθούν σε τέσσερις γενικές κατηγορίες, όπως απεικονίζεται στην **Εικόνα 4**, και περιγράφονται ως εξής:

**Supervised Learning** ή Επιτηρούμενη Μάθηση είναι η κατηγορία της μηχανικής μάθησης, στην οποία η εκπαίδευση πραγματοποιείται μέσω ενός επισημασμένου συνόλου δεδομένων, δηλαδή ενός συνόλου αποτελούμενου από παραδείγματα όπου για κάθε είσοδο είναι γνωστή η επιθυμητή έξοδος, κατασκευάζοντας με αυτόν τον τρόπο μια συνάρτηση συσχετισμού. Στόχος είναι η γενίκευση της συνάρτησης αυτής για εισόδους με άγνωστη έξοδο. Τα προβλήματα που μελετώνται χρησιμοποιώντας αυτή την κατηγορία μηχανικής μάθησης είναι τα προβλήματα ταξινόμησης (classification) και παλινδρόμησης (regression).<sup>2</sup>

**Unsupervised Learning** ή μη Επιτηρούμενη Μάθηση είναι μια κατηγορία μηχανικής μάθησης όπου η εκπαίδευση ενός αλγορίθμου πραγματοποιείται με τη

---

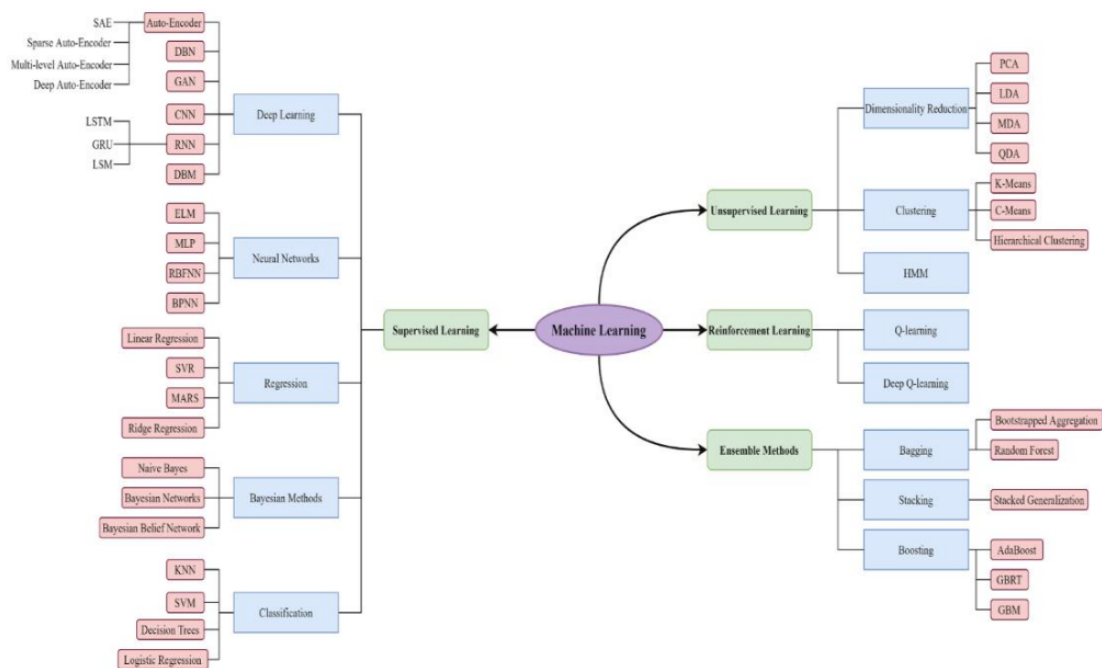
<sup>2</sup> Τα τελευταία χρόνια έχουν αναπτυχθεί και υβριδικές μέθοδοι αυτο-επιτηρούμενης μάθησης (self-supervised) που μαθαίνουν από μη επισημασμένα ή τεχνητά δεδομένα.

χρήση πληροφοριών που δεν είναι ούτε επισημασμένες, ούτε ταξινομημένες, με αποτέλεσμα χωρίς να παρέχεται κάποια εμπειρία στον αλγόριθμο μάθησης να πρέπει να βρει τη δομή των δεδομένων εισόδου. Παρόλο που οι αλγόριθμοι μάθησης χωρίς επίβλεψη μπορούν να εκτελέσουν πιο σύνθετες εργασίες επεξεργασίας σε σύγκριση με τη μάθηση με επίβλεψη, τα αποτελέσματα τους ενδέχεται σε κάποιες περιπτώσεις να μην είναι το ίδιο ακριβή. Το πιο συνηθισμένο πρόβλημα που εξετάζεται με τη χρήση μεθόδων μη επιβλεπόμενης μάθησης είναι η συσταδοποίηση (clustering), η οποία αφορά τη διερευνητική ανάλυση των δεδομένων με σκοπό την κατηγοριοποίηση τους σε ομάδες με κοινά χαρακτηριστικά ή την εύρεση κρυφών μοτίβων. Τέλος, η μη Επιτηρούμενη Μάθηση βρίσκει εφαρμογή σε προβλήματα μείωσης διαστασιμότητας (Dimensionality Reduction), με σκοπό να εξαχθούν χρήσιμα χαρακτηριστικά εκπαίδευσης με λιγότερες διαστάσεις από το αρχικό σετ.

**Reinforcement Learning** ή ενισχυτική μάθηση είναι ένα παράδειγμα μάθησης όπου ένας «πράκτορας» αλληλεπιδρά σε ένα δυναμικό περιβάλλον και για την επίτευξη του στόχου του τροποποιεί τις ενέργειές του, με βάση τα ερεθίσματα που λαμβάνει ως απάντηση σε αυτές. Με άλλα λόγια, η ενισχυτική μάθηση διαφέρει από τις προηγούμενες κατηγορίες, καθώς η εκπαίδευση του αλγορίθμου δεν απαιτεί επισημειωμένα ζεύγη εισόδου και εξόδου, αλλά βασίζεται σε ένα σύστημα λήψης επιβράβευσης ή τιμωρίας ως απάντηση στις ενέργειες του. Αυτή η λειτουργία επιτρέπει τον προσδιορισμό συμπεριφορών αυτόματα, γεγονός που παραπέμπει στον τρόπο που λειτουργεί ο ανθρώπινος εγκέφαλος.

**Ensemble methods** ή συγκεντρωτικές μέθοδοι είναι αλγόριθμοι οι οποίοι κάνουν συνδυασμό πολλών αλγορίθμων μηχανικής μάθησης για να βελτιώσουν την απόδοση σε σύγκριση με τη χρήση ενός μόνο αλγορίθμου. Η μάθηση Ensemble συνδυάζει τη γνώση που έχει αποκομίσει από τους διάφορους βασικούς εκπαιδευτές για την επίλυση ενός ενιαίου προβλήματος, το οποίο παρέχει μια πιο σφαιρική απόφαση συγκριτικά με τους μεμονωμένους βασικούς εκπαιδευτές. Χρησιμοποιείται συστηματικά στα δέντρα αποφάσεων.

Η μηχανική μάθηση εκπαιδεύει τους υπολογιστές στο να “μαθαίνουν” από δεδομένα προηγούμενων εμπειριών. Η μάθηση είναι η πιο κατάλληλη μέθοδος σε περιπτώσεις που δεν είναι δυνατό να γραφτούν απευθείας προγράμματα καθώς η λύση δεν είναι a priori γνωστή. Στα πλαίσια των κτιρίων, δομικά προβλήματα όπως η πρόβλεψη της συμπεριφοράς των ενοίκων, η πρόγνωση της ενεργειακής ζήτησης, και η επίβλεψη των συστημάτων HVAC για τυχόν ζητήματα που εφιστούν την προσοχή των διαχειριστών, είναι δύσκολο να λυθούν με παραδοσιακές προγραμματιστικές αρχές. Η μηχανική μάθηση δύναται να προσφέρει νέες λύσεις σε αυτό, που μπορούν να εφαρμοστούν μόνο μαθαίνοντας από τα δεδομένα.



Εικόνα 4: Οι τέσσερις γενικές κατηγορίες Μηχανικής Μάθησης όπως περιγράφηκαν παραπάνω [89].

## 2.3 Εφαρμογές της μηχανικής μάθησης στα έξυπνα κτίρια

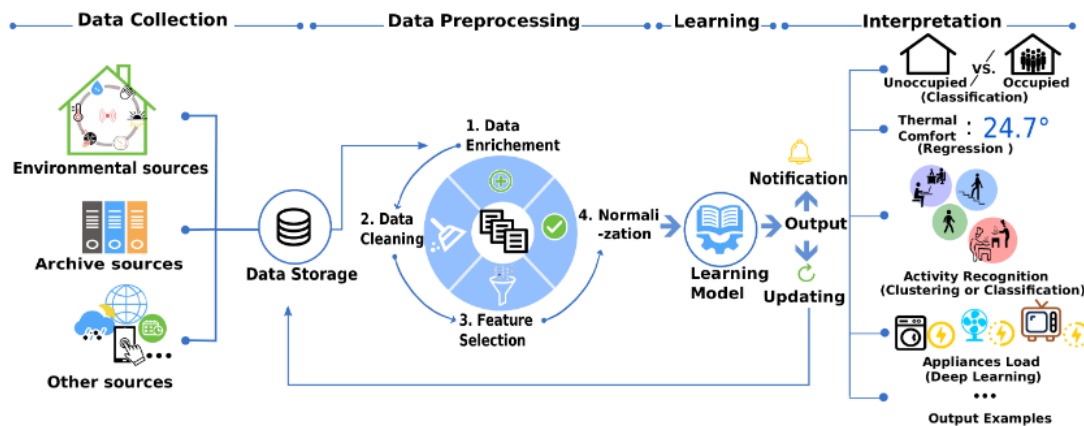
Η χρησιμοποίηση εργαλείων μηχανικής μάθησης σε ανερχόμενους τομείς όπως τα έξυπνα κτίρια ανήκει στις ερευνητικές τάσεις που προσελκύουν κοινότητες ερευνητών από ποικίλα γνωστικά αντικείμενα, όπως η επιστήμη υπολογιστών, τα ηλεκτρονικά ισχύος και η ηλεκτρολογία, η επιστήμη του πολιτικού μηχανικού και η αρχιτεκτονική [18].

Η εικόνα 5 παρουσιάζει ένα γενικό πλαίσιο, εννοιολογικά κοινό στις περισσότερες λύσεις έξυπνων σπιτιών [18]. Αποτελείται από τέσσερα στάδια:

1. Συλλογή δεδομένων, τα οποία συγκομίζονται από πληθώρα πηγών, όπως αισθητήρες, αρχεία δεδομένων καιρού, λίστες συμβάντων και ανάδρασης από τους χρήστες. Τα δεδομένα από αυτές τις ετερογενείς πηγές συγκεντρώνονται σε μια κοινή βάση δεδομένων, από την οποία μπορεί να γίνει εξόρυξη χρήσιμων χαρακτηριστικών.
2. Προεπεξεργασία των αποθηκευμένων δεδομένων πριν την οδηγηθούν για χρήση με κάποιο μοντέλο ML. Αυτό το στάδιο περιλαμβάνει: α) εμπλουτισμό των δεδομένων με στατιστικές τιμές που παρουσιάζουν μεγαλύτερη συσχέτιση με το στόχο, β) καθαρισμό των δεδομένων (στα HVAC σβήσιμο των κενών καταγραφών ή των λάθος μετρήσεων, γ) επιλογή των κατάλληλων χαρακτηριστικών για εκπαίδευση, όπου ενδέχεται να χρησιμοποιηθούν τεχνικές όπως η PCA (Principal Component Analysis) για τη μείωση της διαστασιμότητας του προβλήματος και δ) κανονικοποίηση των δεδομένων αν


αυτό απαιτείται από τη φύση του αλγορίθμου μηχανικής μάθησης που θα εφαρμοστεί.

3. Στάδιο μάθησης, όπου οι τεχνικές ML εφαρμόζονται για να εξάγουν κάποια συνάρτηση μέσω παλινδρόμησης (regression) ή κάποιο μοντέλο.
4. Ερμηνεία των αποτελεσμάτων του προηγούμενου βήματος, ανάλογα με την εφαρμογή που στοχεύει.



Εικόνα 5: Γενικό πλαίσιο λύσεων μηχανικής μάθησης στα έξυπνα κτίρια [90]

Η ταξινόμηση των βασικών εφαρμογών μηχανικής μάθησης στα έξυπνα κτίρια χωρίζεται σε δύο κλάσεις, ανθρωποκεντρικές και σε σχέση με την ενέργεια ή τις συσκευές. Η **εικόνα 6** παρουσιάζει σε ένα απλό διάγραμμα αυτές τις υποκατηγορίες, για τις οποίες θα δοθούν κάποια βασικά στοιχεία στη συνέχεια, με έμφαση στην κατηγορία της ενέργειας, στην οποία εντάσσεται η διάγνωση σφαλμάτων.



Εικόνα 6: Οι βασικές κατηγορίες λύσεων μηχανικής μάθησης στα έξυπνα κτίρια [90]

### 2.3.1 Πληρότητα χώρου (occupancy)

Οι λύσεις αυτές σχετίζονται με την παρουσία ατόμων ή κατοικιδίων στο χώρο. Έχει εύρος από τη δυαδική συμπερασματολογία του αν υπάρχουν ένοικοι στο χώρο, έως τον πιο εξελιγμένο υπολογισμό (αριθμός ατόμων, φύλο). Παλαιότερες μελέτες ήταν επικεντρωμένες στη χρήση ασύρματων τεχνολογιών αισθητήρων για να ανιχνεύουν και να παρακολουθούν τους ενοίκους σε πραγματικό χρόνο (real time). Οι



πλέον προχωρημένες προτάσεις δεν περιορίζονται στη real time ανίχνευση αλλά στηρίζονται σε πληροφορίες των αισθητήρων για να προβλέπουν τη μελλοντική πληρότητα του χώρου. Σε αντίθεση με το πλαίσιο των έξυπνων πόλεων που περιλαμβάνουν ανοικτούς, δημόσιους χώρους, η διατήρηση της ιδιωτικότητας σε γραφεία, αίθουσες συνεδριάσεων και διαμερίσματα αποτελεί βασικό μέλημα. Επομένως η χρήση μη παρεμβατικών (non-invasive) τεχνολογιών αισθητηρίων (υπέρυθρη, υπερηχητική), είναι καταλληλότερη από τη χρήση καμερών και μικροφώνων.

### **2.3.2 Αναγνώριση δραστηριότητας**

Λύσεις αυτής της κατηγορίας δεν σχετίζονται με τον υπολογισμό πλήθους στο χώρο αλλά με την τυχόν ύπαρξη δραστηριότητας, που είναι σημαντική σε πολλές εφαρμογές, όπως η περίθαλψη και η φροντίδα των ηλικιωμένων και ευπαθών. Αρκετές προσεγγίσεις έχουν προταθεί στη βιβλιογραφία [19], και παρόλο που οι περισσότερες αναφέρονται στην αναγνώριση δραστηριοτήτων όπως το μαγείρεμα, το φαγητό, ο ύπνος, η παρακολούθηση τηλεόρασης κ.α, υπάρχουν και πιο λεπτομερείς ορισμοί, που ξεχωρίζουν το είδος του γεύματος, ή συσχετίζουν τη χρονοσφραγίδα κάθε διεργασίας με τις δραστηριότητες ώστε να κατηγοριοποιηθούν.

### **2.3.3 Προτιμήσεις και συμπεριφορά ενοίκων**

Σε αυτό το τμήμα παρουσιάζονται λύσεις που εκτιμούν τις συνήθειες και προτιμήσεις των ενοίκων-χρηστών με διαφορετικούς τρόπους. Οι περισσότερες επικεντρώνονται στην κλιματική άνεση, ενώ κάποιες άλλες θεωρούν και την οπτική άνεση (επίπεδα και θερμοκρασία φωτισμού). Τέτοιες μέθοδοι έχουν εφαρμοστεί στο παρελθόν για να εξαχθούν πρότυπα για τις θερμοκρασιακές και κλιματικές προτιμήσεις της πλειοψηφίας σε δημόσιους χώρους.

Αυτή η προσέγγιση αποδεικνύεται πολύπλοκη και αποτυγχάνει να συμπεραίνει εξατομικευμένα προφίλ που διαφέρουν από άτομο σε άτομο, ακόμη και για το ίδιο άτομο με το πέρασμα του χρόνου, λόγω περιβαλλοντικών και προσωπικών παραγόντων. Οι μέθοδοι αυτής της κατηγορίας αξιοποιούν τα δεδομένα (data-driven), που λαμβάνονται από αναφορές των ίδιων των χρηστών, δηλαδή ως επισημασμένα δεδομένα (labeled), η μελετώντας την παρελθοντική δραστηριότητα των χρηστών ώστε να συνάγουν τις προτιμήσεις ή ρυθμίσεις που ικανοποιούν την άνεση τους. Έχουν δοκιμαστεί διαφορετικές μέθοδοι αναφοράς, από τους οποίους οι διεπαφές σε έξυπνα κινητά τηλέφωνα (smartphones) είναι οι πιο βολική.

### **2.3.4 Πρόβλεψη φορτίου και ζήτησης**

Τα κτίρια αντιπροσωπεύουν ένα μεγάλο μέρος της παγκόσμιας κατανάλωσης ενέργειας και των σχετικών εκπομπών CO<sub>2</sub>. Σύμφωνα με τους Amasyali &

El-Gohary, (2018), ο κτιριακός τομέας αντιπροσωπεύει το 39% και 40% αντίστοιχα στην ΕΕ και στις ΗΠΑ, ενώ ευθύνονται για περίπου το 38% και 36% αντίστοιχα του συνόλου των εκπομπών CO<sub>2</sub>. Η κύρια αιτία της κλιματικής αλλαγής είναι η καύση ορυκτών καυσίμων, όπως το πετρέλαιο, ο άνθρακας και το φυσικό αέριο, κατά την οποία εκπέμπονται αέρια του θερμοκηπίου στην ατμόσφαιρα. Τα κράτη μέλη θα πρέπει να στοχεύσουν σε μια οικονομικά αποδοτική ισορροπία μεταξύ της απαλλαγής του ενεργειακού εφοδιασμού από ανθρακούχες εκπομπές και της μείωσης της τελικής κατανάλωσης ενέργειας. Επομένως, η αύξηση του ρυθμού ανακαίνισης του κτιριακού δυναμικού της ΕΕ κατά τα προσεχή έτη, προκειμένου να βελτιωθεί η ενεργειακή του απόδοση, είναι ζωτικής σημασίας.

Σε αυτό το πλαίσιο, η πρόβλεψη της ενεργειακής κατανάλωσης στα κτίρια είναι κρίσιμης σημασίας για τη βελτίωση λήψης αποφάσεων προς την κατεύθυνση της μείωσης της κατανάλωσης ενέργειας και των εκπομπών CO<sub>2</sub>, καθώς μπορεί να βοηθήσει στην αξιολόγηση διαφόρων εναλλακτικών λύσεων σχεδιασμού κτιρίων και στρατηγικών λειτουργίας κτιρίων (όσον αφορά την ενεργειακή τους απόδοση), όπως και στη βελτίωση διαχείρισης της ζήτησης και της προσφοράς ενέργειας.

Αυτή η κλάση λύσεων δεν περιλαμβάνει κάθε βελτιστοποίηση ενεργειακής αποδοτικότητας μέσω μηχανικής μάθησης, παρά μόνο αυτές που σχετίζονται με την καταγραφή και την εκτίμηση του ενεργειακού φόρτου του δικτύου ενός κτιρίου, που σχετίζεται άμεσα με την άνεση των ενοίκων και την απόδοση του συστήματος. Με αυτές τις μεθόδους μπορούν να μοντελοποιηθούν οι ανάγκες θέρμανσης και ψύξης, η ενεργειακή ζήτηση (electricity demand) και να εξαχθούν τα ξεχωριστά προφίλ χρήσης κάθε ηλεκτρικής συσκευής. Η συμπερίληψη τέτοιων μεθόδων έχει πολύ σημαντικό πεδίο εφαρμογής, κυρίως στη μείωση του ενεργειακού κόστους, αλλά και σε εφαρμογές εντοπισμού και διάγνωσης σφαλμάτων, βελτιστοποίηση ελεγκτών κ.α.

### **2.3.5 Ανάλυση προφίλ και διαγνωστικός έλεγχος σφαλμάτων**

Οι λύσεις που αξιοποιούν μηχανική μάθηση για να αναγνωρίζουν το είδος της συσκευής, στοχεύουν να ανιχνεύουν ανωμαλίες (anomaly detection) ή αστοχίες σε διαφορετικά συστατικά του υλικού εξοπλισμού του συστήματος διαχείρισης ενέργειας όπως μονάδες διαχείρισης ροής αέρα (AHU) και κλιματισμού (HVAC). Οι συσκευές αυτές παρουσιάζουν μεγάλη πιθανότητα να είναι υπαίτιες για επικίνδυνες καταστάσεις και ενεργειακή σπατάλη. Για παράδειγμα μια μελέτη του 2014 [20] δείχνει ότι το 70% των υπολογιστικών συστημάτων παραμένει αναμμένο συνεχώς. Επομένως, η αυτοματοποιημένη αναγνώριση των συσκευών, της κατάστασής τους, και των τυχόν σφαλμάτων έχουν πολλαπλούς σκοπούς στα έξυπνα κτίρια και σε αυτό έρχεται πάλι να συμβάλλει η έρευνα και οι τεχνικές μηχανικής μάθησης.



## Κεφάλαιο 3. Ανίχνευση και διάγνωση σφαλμάτων σε συστήματα HVAC (FDD)

Η Έκθεση Παγκόσμιας Κατάστασης του 2018 από τον Διεθνή Οργανισμό Ενέργειας (IEA) βρήκε ότι η λειτουργία των κτιρίων αντιπροσωπεύει το 36% της παγκόσμιας χρήσης ενέργειας [21]. Επιπλέον, οι Yang et al. διαπίστωσαν ότι τα συστήματα θέρμανσης, εξαερισμού και κλιματισμού (HVAC) αντιπροσωπεύουν το 40% όλης της κατανάλωσης ενέργειας του κτιρίου [22]. Αυτό οδηγεί στη γνώση ότι το σύστημα HVAC αντιπροσωπεύει το 14% της χρήσης ενέργειας σε όλο τον κόσμο. Οι Qin et al. βρήκαν ότι στο Χονγκ Κονγκ, το 20,9% των εμπορικών κτιρίων λειτουργούν συνεχώς με σφάλματα, συμπεριλαμβανομένου σφαλμάτων του αισθητήρα και αστοχίες ενεργοποιητή, που υποβαθμίζουν την απόδοσή τους [23]. Υπάρχουν πολλές σημεία αποτυχίας σε ένα σύστημα κτιρίου λόγω των χιλιάδων αισθητήρων, αποσβεστήρων ή άλλων ελεγχόμενων συσκευών. Οι Katipamula et al. διαπίστωσαν ότι τα λειτουργικά σφάλματα στα κτίρια είναι τα αίτια για 15-30% απώλεια ενέργειας σε εμπορικά κτίρια [24].

Στη σύγχρονη εποχή, συστήματα διαχείρισης κτιρίων έχουν εγκατασταθεί σε πολλά κτίρια. Αυτά τα συστήματα παρέχουν μια διεπαφή για συνεχή μέτρηση και παρακολούθηση των στοιχείων του συστήματος HVAC, που δημιουργεί νέες δυνατότητες για προηγμένο εντοπισμό σφαλμάτων και διαγνωστική.

Τα συστήματα διαχείρισης κτιρίων παρέχουν πληροφορίες σχετικά με τα στοιχεία του συστήματος τα οποία μπορεί να αναλυθεί χρησιμοποιώντας εργαλεία λογισμικού. Αυτές οι πληροφορίες περιλαμβάνουν όλες τις μετρήσεις αισθητήρων στο κτίριο, όπως η τοποθεσία ενός ενεργοποιητή ή ο έλεγχος κινητήρων. Αυτές οι μετρήσεις μπορούν να είναι υπό παρακολούθηση για σταθερότητα ή ανωμαλίες, αν και αλληλεξαρτήσεις μεταξύ εξαρτημάτων και ο αυτοδιορθωτικός προγραμματισμός κτιρίου μπορεί να αποκρύψει ορισμένα σφάλματα και να αποτρέψει την ανίχνευση τους.

Τα σφάλματα ενός συστήματος HVAC μπορεί να αυξήσουν την κατανάλωση ενέργειας έως 18% και να υποβαθμίσουν την άνεση των ενοίκων όταν δεν επιτυγχάνονται τα επιθυμητά θερμικά σημεία (setpoints). Η βλάβη ενός αισθητήρα μπορεί να αυξήσει την κατανάλωση ενέργειας παραποιώντας τη θερμοκρασία του αέρα που ρέει στο σύστημα, κάτι το οποίο πρέπει να διορθωθεί από επόμενα εξαρτήματα. Τέτοιες αποτυχίες συχνά αντιπροσωπεύονται στα δεδομένα που συλλέγονται από το σύστημα διαχείρισης κτιρίων και μπορούν να ανιχνευθούν με χρήση προηγμένων στοιχείων ανάλυσης. Οι βλάβες μπορούν να εντοπιστούν γρήγορα και με περιορισμένη πρόσθετη χειροκίνητη ανάλυση χρησιμοποιώντας αλγόριθμους μηχανικής μάθησης για τον εντοπισμό και τη διάγνωση σφαλμάτων, κάτι που μειώνει

τον χρόνο που δαπανά το κτίριο σε εσφαλμένη λειτουργία και ελαχιστοποιεί τη σπατάλη ενέργειας αυξάνοντας την παραγωγικότητα των ενοίκων.

### 3.1 Γενική εικόνα του συστήματος HVAC

Το σύστημα HVAC είναι ένα μεγάλης κλίμακας, πολύπλοκο σύστημα με πολλά διασυνδεδεμένα υποσυστήματα που αποτελούνται από πολλά ηλεκτρομηχανικά εξαρτήματα και μια σειρά από κτιριακές ζώνες ή ζώνες απασχόλησης (occupation zones). Συστήματα HVAC με λειτουργία θέρμανσης αποτελούνται από συσκευές όπως λέβητες, αντλίες θερμότητας, σπειρώματα θέρμανσης κ.λπ., ενώ τα συστήματα HVAC με λειτουργία ψύξης αποτελούνται από πύργους ψύξης, ψυκτικά συγκροτήματα, σπειρώματα ψύξης κ.λπ. Ειδικότερα, μονάδες HVAC που είναι εγκατεστημένες σε εμπορικά κτίρια, οι οποίες είναι δύσκολο να αερίζονται φυσικά [25], είναι εξοπλισμένες με παροχή αερισμού (δηλαδή, ανεμιστήρες, αγωγοί τροφοδοσίας/επιστροφής, κουτιά ανάμειξης, αγωγοί εξαγωγής, φίλτρα κ.λπ.) που παρέχουν στους εσωτερικούς χώρους καθαρό αέρα, απομακρύνουν και φιλτράρουν τον μολυσμένο αέρα λόγω υψηλής συγκέντρωσης διοξειδίου του θείου (υποπροϊόν της καύσης ορυκτών καυσίμων), μονοξειδίου (CO), και διοξειδίου του αζώτου [26]. Υπάρχουν διάφοροι τύποι ανταλλαγής θερμότητας για τις κτιριακές ζώνες όπως:


- Καλοριφέρ θέρμανσης
- Μονάδες διαχείρισης αέρα (Air Handling Units, AHU)
- Μονάδες AHU σταθερού όγκου (CAV ή Fan-Coil)
- AHU μεταβλητού όγκου (VAV)
- Συστήματα υποδαπέδιας θέρμανσης/δροσισμού
- Υποδαπέδιας διανομής αέρα (UnderFloor-Air-Distribution, UFAD)

Τα συστήματα καλοριφέρ θέρμανσης είναι οι πιο δημοφιλείς εκπομποί κεντρικής θέρμανσης. Ζεστό νερό (περίπου μεταξύ 75 έως 80ο C) διέρχεται από τους σωλήνες του σπειρώματος/καλοριφέρ και αυτό κάνει τη θερμοκρασία της επιφάνειας του σπειρώματος μεγαλύτερη από τη θερμοκρασία του εσωτερικού αέρα. Επομένως, μέσω της μεταφοράς θερμότητας και της απαγωγής, ο αέρας μέσα στη θερμική ζώνη/δωμάτιο θερμαίνεται.

Στα συστήματα ενδοδαπέδιας θέρμανσης, το νερό χαμηλής θερμοκρασίας (π.χ. 35–40ο C) κυκλοφορεί μέσω ενός πλέγματος σωλήνων που κρύβονται κάτω από τα πλακάκια δαπέδου. Η διάχυση θερμότητας στο δωμάτιο είναι κυρίως αποτέλεσμα ακτινοβολίας και επιτρέπει στους χρήστες να απολαύσουν ομοιόμορφη κατανομή θερμοκρασίας στην κλιματιζόμενη ζώνη.

Τα συστήματα HVAC AHU εγκαθίστανται συνήθως σε κτίρια μεγάλης κλίμακας, καθώς μπορούν να παρέχουν θέρμανση και ψύξη σε πολλαπλές ζώνες. Μία μονάδα AHU, που συχνά παρατηρούνται στις οροφές κτιρίων γραφείων, νοσοκομείων κ.α, αποτελείται από ανεμιστήρα, σπείρωμα θέρμανσης/ψύξης, κουτί ανάμειξης και

φίλτρο. Το κουτί ανάμειξης χρησιμοποιείται για τη διατήρηση της κατάλληλης υγρασίας και ποσότητας εξαερισμού αέρα σε κάθε κλιματιζόμενο χώρο και έτσι μπορεί να εξασφαλιστεί καλή ποιότητα του εσωτερικού αέρα. Ένα AHU μπορεί να χρησιμοποιήσει τόσο τον καθαρό αέρα όσο και τον επιστρεφόμενο αέρα από το υποκείμενο κλιματιζόμενο δωμάτιο, όπου το το ποσοστό του φρέσκου αέρα και του επιστρεφόμενου αέρα ρυθμίζεται από το κιβώτιο ανάμειξης προκειμένου να επιτευχθεί αντιστάθμιση μεταξύ της σπατάλης ενέργειας και της ποιότητας του εσωτερικού αέρα. Όπως φαίνεται στην **εικόνα 7**, υπάρχουν δύο τύποι συστημάτων AHU, εξοπλισμένα είτε με: (i) μονάδες σταθερού όγκου αέρα (CAV), που ονομάζονται επίσης fan-coil μονάδες (FCU) ή (ii) μονάδες μεταβλητού όγκου αέρα (VAV). Η κύρια διαφορά μεταξύ αυτών των δύο συστημάτων είναι ότι ένα σύστημα VAV προσαρμόζει τη ροή του αέρα ανάλογα με τη διακύμανση της κατάστασης του φορτίου του κτιρίου, χρησιμοποιώντας είτε ανεμιστήρα τροφοδοσίας εξοπλισμένο με μονάδα μεταβλητής συχνότητας (VFD) είτε κουτί VAV στο οποίο ένας αποσβεστήρας ρυθμίζει την ποσότητα αέρα που παρέχεται στο δωμάτιο. Το σύστημα CAV/FCU παρέχει σταθερό αέρα ροή σε μια κλιματιζόμενη ζώνη και ρυθμίζοντας τη ροή του νερού μέσα από τα σπειρώματα ρυθμίζει τη θερμοκρασία του αέρα του δωματίου [27].




**Εικόνα 7:** Οι τύποι μονάδων AHU, με τις διαφορές τους όπως περιγράφηκαν παραπάνω [91].

Όλα τα προαναφερθέντα συστήματα ανταλλαγής θερμότητας τροφοδοτούνται με φορτίο θέρμανσης ή ψύξης από ένα κεντρικό σύστημα HVAC όπως μονάδες θέρμανσης, μονάδες ψύξης, αντλίες θερμότητας ή γεωθερμικά συστήματα. Τα γεωθερμικά συστήματα [28, 32] μπορούν να παρέχουν τις ανταλλαγές θερμότητας με οποιαδήποτε θέρμανση ή ψυκτικό φορτίο αφού εκμεταλλεύονται τη διαφορά θερμοκρασίας περιβάλλοντος (θερμοκρασία επιφανειακού αέρα) που μεταβάλλεται ανάλογα με τις περιβαλλοντικές συνθήκες σε σύγκριση με τις γεωθερμικές δεξαμενές που πρακτικά έχουν σταθερή θερμοκρασία. Χρησιμοποιώντας σωλήνες, ένα αποθηκευμένο υγρό περνά σε ένα ορισμένο επίπεδο βάθους που επιτρέπει την αλλαγή

του θερμικού περιεχομένου του και στη συνέχεια αντλείται σε αποθήκη πάνω από την επιφάνεια του εδάφους, προκειμένου να διανεμηθεί σε ένα σύστημα ανταλλαγής θερμότητας (π.χ., ενδοδαπέδιο σύστημα θέρμανσης, σύστημα AHU, καλοριφέρ κ.λπ.). Προς το παρόν, τα γεωθερμικά συστήματα δεν είναι τόσο δημοφιλή λόγω του υψηλού κόστους εγκατάστασης και της μακροπρόθεσμης απόσβεσης που καθιστά το κόστος τους αναποτελεσματικό.

Οι μονάδες θέρμανσης αποτελούνται από εξαρτήματα όπως καυστήρες, λέβητες, συμπυκνωτές, δεξαμενές αποθήκευσης, ενώ οι μονάδες ψύξης αποτελούνται από εξαρτήματα όπως ψύκτες (chillers) και πύργοι ψύξης. Να σημειωθεί ότι είτε η μονάδα θέρμανσης είτε η μονάδα ψύξης είναι ενεργή σε κάθε στιγμή. Η κατεύθυνση της αγοράς των κεντρικών συστημάτων HVAC είναι στα συστήματα αντλιών θερμότητας λόγω των υψηλών ρυθμών ενεργειακής τους απόδοσης. Εκτός από το ενεργειακό κομμάτι, τα συστήματα αντλιών θερμότητας μπορούν να αλλάξουν από τη λειτουργία θέρμανσης σε ψύξη. Επίσης, μια ειδική περίπτωση αποτελούν τα συστήματα αντλιών τεσσάρων σωλήνων που μπορούν να τροφοδοτήσουν τα συστήματα ανταλλαγής θερμότητας με θέρμανση και ψυκτικό φορτίο ταυτόχρονα. Αυτή η λειτουργία είναι αποτελεσματική για κτίρια μεγάλης κλίμακας (π.χ. εμπορικά κέντρα, ξενοδοχεία, νοσοκομεία, σχολεία, πανεπιστημιούπολεις) που μπορεί να έχουν απαιτήσεις θέρμανσης και ψύξης ταυτόχρονα. Η **εικόνα 8** παρουσιάζει ένα σχηματικό διάγραμμα που δίνει μια απεικόνιση των τύπων συστημάτων HVAC που μπορούν να εφαρμοζονται σε ένα κτίριο. Συγκεκριμένα, αποτελείται από σύστημα καλοριφέρ κεντρικής θέρμανσης, Air Handling Units (AHUs), μια μονάδα θέρμανσης, μια μονάδα ψύξης και ένα σύστημα θέρμανσης υπό ροή.



**Εικόνα 8:** Σχηματικό διάγραμμα ενός γενικού συστήματος HVAC που περιλαμβάνει μονάδα θέρμανσης, μονάδα ψύξης και AHU, κουτιά VAV, επιτοίχια σώματα καλοριφέρ και υποδαπέδια θέρμανση για κάθε δωμάτιο [91].

### 3.2 Σύνοψη σφαλμάτων που εμφανίζονται στο σύστημα HVAC

Όπως έχει αναφερθεί προηγουμένως, τα συστήματα HVAC είναι πολύπλοκα ηλεκτρομηχανικά συστήματα με τεράστιο αριθμό εξαρτημάτων. Λόγω της αδιάλειπτης λειτουργίας του εξοπλισμού των συστημάτων HVAC, μπορεί να προκύψουν διάφορα είδη βλαβών. Ένας τρόπος κατηγοριοποίησης των τύπων σφαλμάτων μπορεί να βασίζεται στο στοιχείο που επηρεάζεται. Για παράδειγμα, τα σφάλματα μπορούν να κατηγοριοποιηθούν σε: (i) σφάλματα αισθητήρα (μέτρησης θερμοκρασίας, υγρασίας, CO<sub>2</sub>, κίνησης) [130], (ii) σφάλματα ενεργοποιητή (π.χ. βαλβίδα, ανεμιστήρας, σωλήνας, αποσβεστήρας, συμπιεστής, κινητήρας, κ.λπ.), (iii) σφάλματα διεργασίας (δηλαδή ανοιχτό παράθυρο, ανοιχτή εξωτερική πόρτα κ.λπ.), (iv) σφάλμα επικοινωνίας (δηλαδή, διακοπή καλωδίου, απώλεια μηνύματος, διαχωρισμός δικτύου, παράλειψη/κενό, σφάλματα χρονισμού, εντελώς αυθαίρετα σφάλματα) [34, 36, 40]. Οι βλάβες αυτές μπορεί να προκύψουν σε διαφορετικά επίπεδα επηρεάζοντας ένα στοιχείο, υποσύστημα, σύστημα ή ακόμα και ολόκληρο το κτίριο.

Ένα σφάλμα σε οποιοδήποτε από αυτά τα επίπεδα μπορεί να επηρεάσει περαιτέρω τις λειτουργίες πολλών άλλων σχετικών στοιχείων και ως εκ τούτου, καθιστά δύσκολη την κατανόηση της σχέσης μεταξύ αιτιών και αποτελεσμάτων και τον ποσοτικό προσδιορισμό των συνολικών επιπτώσεων στην ενεργειακή απόδοση ολόκληρου του κτιρίου. Για παράδειγμα, η υποβάθμιση των ανεμιστήρων μπορεί να επηρεάσει κυκλοφορία αέρα του συστήματος μειώνοντας τη ροή αέρα παροχής ή αυξάνοντας την ισχύ του ανεμιστήρα. Μπορεί να επιδράσει επίσης στην απόδοση μεταφοράς θερμότητας των σπειρωμάτων και την κατανάλωση ενέργειας.

Δεύτερον, τα λειτουργικά σφάλματα μπορεί να έχουν ποικίλες επιπτώσεις σε διάφορες πτυχές της απόδοσης του κτιρίου. Για παράδειγμα, μια θετική μετατόπιση του θερμοστάτη (η ένδειξη θερμοκρασίας αέρα ζώνης να φαίνεται στο σύστημα υψηλότερη από την πραγματική τιμή) μπορεί να δημιουργήσει διαφορετική επίδραση τόσο στην κατανάλωση ενέργειας όσο και στη θερμική άνεση κατά τις διάφορες εποχιακές περιόδους. Έπειτα, σε περιόδους θέρμανσης, μειώνει την κατανάλωση ενέργειας θέρμανσης διατηρώντας τη θερμοκρασία δωματίου σε χαμηλότερα επίπεδα, αλλά, εν τω μεταξύ, επιδεινώνει τις συνθήκες θερμικής άνεσης σε εσωτερικούς χώρους. Κατά την εποχή ψύξης, η κατανάλωση ενέργειας αυξάνεται και μπορεί να εμφανιστεί υπερβολική ψύξη.

Τρίτον, μπορεί να υπάρχει ένα συγκεκριμένο σφάλμα με πολύ διαφορετικά λειτουργικά χαρακτηριστικά από τα υπόλοιπα και να πρέπει να αντιμετωπιστεί με διαφορετική προσέγγιση. Παίρνοντας σαν παράδειγμα τη μετατόπιση τιμής του



αισθητήρα θερμοκρασίας, μπορεί να συμβαίνει: (1) ένα στατικό σφάλμα (κολλημένο σε μια τιμή), εάν η μετατόπιση είναι μια σταθερή τιμή σε όλη την περίοδο ανάλυσης, (2) ένα απότομο σφάλμα, εάν η μετατόπιση προκύψει ξαφνικά κατά τη διάρκεια της περιόδου ανάλυσης και παραμένει σε σταθερό επίπεδο μετά την εμφάνιση, (3) σφάλμα υποβάθμισης, εάν η μετατόπιση του αισθητήρα μετατοπίζεται με την πάροδο του χρόνου. Με παρόμοιο τρόπο, τα σφάλματα ενεργοποιητή (actuator faults) αντιπροσωπεύουν στα συστήματα HVAC διαρροές στον στατικό εξοπλισμό (δηλ. σωλήνες) ή τότε ο εξοπλισμός με κινούμενα μέρη (δηλ. βαλβίδες, ανεμιστήρες, αποσβεστήρες, συμπιεστές, κινητήρες) έχει κολλήσει ή έχει υποβαθμιστεί [37].

### 3.3 Πρόοδος της επιστήμης στον έλεγχο συστημάτων HVAC

Αρκετοί ερευνητές έχουν προτείνει έναν μεγάλο αριθμό σχεδίων ελέγχου τόσο για τη βελτίωση των δύο επιδόσεων παρακολούθησης χειρισμού όσο και την ενεργειακή απόδοση των συστημάτων HVAC. Οι μέθοδοι ελέγχου για τα συστήματα HVAC αναφέρονται στη βιβλιογραφία με τους εξής ορισμούς:

- κλασικός έλεγχος, με ενεργοποίηση/απενεργοποίηση με τη χρήση PID ελεγκτών [41]
- σκληρός έλεγχος, χρησιμοποιώντας PID προγραμματισμού κέρδους, που περιλαμβάνει το μη γραμμικό έλεγχο [38], τον ισχυρό έλεγχο, τον προσαρμοστικό έλεγχο, καθώς και τα μοντέλα πρόβλεψης ελέγχου (Model Predictive Control, MPC) [39, 42]
- μαλακός έλεγχος (δηλαδή ασαφής λογική, έλεγχος νευρωνικού δικτύου)
- υβριδικός έλεγχος (προσαρμοστική ασαφής λογική, προσαρμοστικό νευρωνικό, ασαφές PID) [43]
- άλλες τεχνικές ελέγχου όπως ο γραμμικός έλεγχος άμεσης ανάδρασης, ο έλεγχος με προσαρμοστική διαμόρφωση παλμού, ο προσαρμοστικός έλεγχος αναγνώρισης προτύπων, ο έλεγχος ενισχυτικής μάθησης.

Λαμβάνοντας υπόψη τον διαδοχικό τρόπο με τον οποίο είναι συνδεδεμένα τα εξαρτήματα AHU, όπως το κουτί ανάμειξης, ο ανεμιστήρας και τα σπειρώματα θέρμανσης και ψύξης, μπορεί να χρησιμοποιηθεί έλεγχος σε σύνδεση καταρράκτη (cascade topology). Ο έλεγχος τοπολογίας καταρράκτη είναι μία εξειδικευμένη αρχιτεκτονική ελέγχου που σχηματίζεται από εσωτερικούς και εξωτερικούς βρόχους ανάδρασης. Αρκετοί ερευνητές έχουν αναπτύξει συστήματα ελέγχου καταρράκτη, τα περισσότερα από τα οποία στοχεύουν στον έλεγχο της θερμοκρασίας του αέρα τροφοδοσίας (supply air temperature) ρυθμίζοντας τη βαλβίδα νερού των σπειρωμάτων [55], ενώ μόνο σε μία μελέτη από αυτές προτάθηκε ένα σχέδιο καταρράκτη για τον έλεγχο θερμοκρασίας του αέρα της ζώνης χρησιμοποιώντας έναν γενετικό αλγόριθμο [54].

Εκτός από την εκμετάλλευση της τοπολογίας καταρράκτη των μονάδων AHU, ο σχεδιασμός ελέγχου θα πρέπει να ξεπεράσει τις προκλήσεις που προκύπτουν λόγω της μεγάλης κλίμακας των κτιρίων και να μετριάσει την υπολογιστική πολυπλοκότητα των κλασικών κεντρικών μεθόδων ελέγχου, ώστε να αποφευχθούν τα μεμονωμένα σημεία αστοχίας. Με τις πρόσφατες προόδους του Internet of Things (IoT), η σχεδίαση κατανεμημένου ελέγχου ενδέχεται να μην υποφέρει από το μειονεκτήματα των κλασικών συστημάτων, αλλά αντίθετα μπορεί να μειώσει τις απαιτήσεις επικοινωνίας και να βελτιώσει την επεκτασιμότητα της κλίμακας, ανάλογα με τις ανάγκες του κάθε κτιρίου. Ως εκ τούτου, την τελευταία δεκαετία η πλειονοψηφία των δημοσιεύσεων σχετικά με τον έλεγχο HVAC προτείνει αλγόριθμους κατανεμημένου ελέγχου με σχεδιασμό MPC [44] που προσφέρει μια βέλτιστη λύση, αλλά χωρίς να λαμβάνονται υπόψη οι επιπτώσεις της αβεβαιότητας μοντελοποίησης (χρήση χώρου, εξοπλισμός, ανοίγματα θυρών), όπως και άγνωστες διαταραχές ή υποβάθμιση του εξοπλισμού HVAC.

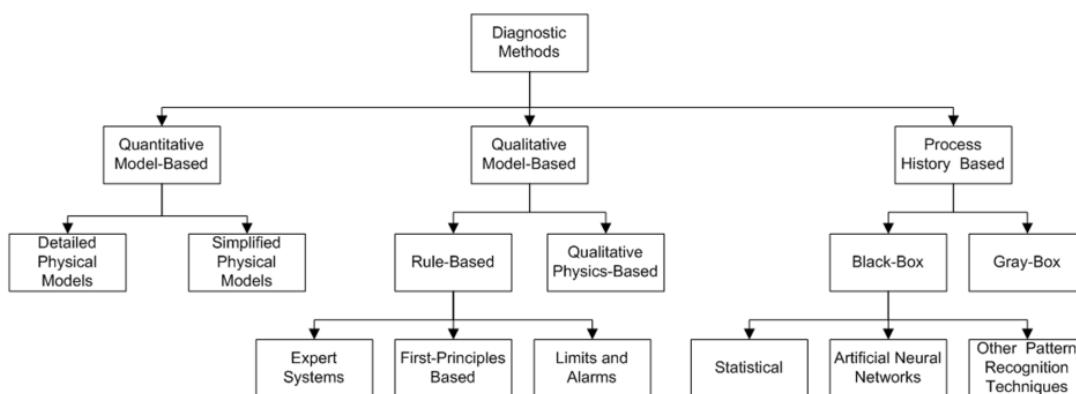
### **3.4 Πρόοδος της επιστήμης στην ανίχνευση και διάγνωση σφαλμάτων HVAC**

Η αξιοπιστία του εξοπλισμού HVAC (βαλβίδες, ανεμιστήρες, αποσβεστήρες, αντλίες) καθώς και των δεδομένων που αντιλαμβάνονται οι αισθητήρες (όπως η εξασφάλιση θερμοκρασίας και ροής αέρα/νερού/ψυκτικού μέσου) είναι ζωτικής σημασίας για την απόδοση των παραπάνω αναφερόμενων αλγορίθμων ελέγχου. Λόγω της διακοπτόμενης λειτουργίας συστημάτων HVAC, αστοχίες ή βλάβες σε ενεργοποιητές και αισθητήρες είναι αναπόφευκτο να συμβούν, προκαλώντας μη ικανοποιητικές θερμικές συνθήκες εσωτερικού χώρου και σπατάλη ενέργειας, που υπολογίζονται μεταξύ 15% και 30% της συνολικής χρήσης ενέργειας του κτιρίου [45, 46]. Μια ολική αποτυχία, δηλαδή μια μόνιμη διακοπή της ικανότητας ενός συστήματος να εκτελέσει μια απαιτούμενη λειτουργία, είναι πιο πιθανό να διαγνωστεί ή ακόμη και να παρατηρηθεί από το προσωπικό ή τους ενοίκους. Εναλλακτικά, ένα σφάλμα, δηλαδή μια απόκλιση από τη φυσιολογική λειτουργία, περνά συνήθως απαρατήρητο από το προσωπικό συντήρησης και είναι δύσκολο ή και αδύνατο να διαγνωστεί χωρίς τη χρήση διάγνωσης βλαβών (FDD).

Λόγω των προαναφερθέντων επιχειρημάτων, η διάγνωση σφάλματος (FD) που μελετά την ανίχνευση, απομόνωση και τον εντοπισμό των βλαβών, έχει κερδίσει μεγάλη προσοχή στον τομέα των κτιριακών συστημάτων. Επί του παρόντος, Η πλειονοψηφία των συστημάτων παρακολούθησης HVAC στον κλάδο χρησιμοποιεί αλγόριθμους βασισμένους σε κανόνες (rule-based) για τη διάγνωση ανωμαλιών κατά τη λειτουργία των συστημάτων HVAC, λόγω της απλότητάς τους. Οι κανόνες διαμορφώνονται συγκρίνοντας δεδομένα αισθητήρα ή σχέσεις δεδομένων αισθητήρων με προκαθορισμένα σταθερά κατώφλια που λαμβάνονται από εμπειρογνώμονες (συνήθως ονομάζονται επίσης συστήματα ειδικών). Μερικά

παραδείγματα σχημάτων διάγνωσης βλαβών βάσει κανόνων για τα συστήματα HVAC είναι: (i) οι κανόνες αξιολόγησης απόδοσης που προσδιορίζουν τον τρόπο λειτουργίας χρησιμοποιώντας ειδικές μαθηματικές σχέσεις μεταξύ των μετρούμενων πληροφοριών και (ii) τα γραφήματα αιτίου αποτελέσματος (cause-effect graphs) όπου οι διάφοροι τρόποι λειτουργίας του συστήματος (τόσο ο υγιής όσο και ο ελαττωματικός τρόπος λειτουργίας) παρουσιάζονται ως διακριτά γεγονότα. Η κύρια αδυναμία των μεθόδων βασισμένων σε κανόνες έγκειται στο ότι περιορίζονται στο σύστημα για το οποίο έχουν φτιαχτεί, στο οποίο μπορεί να συμβούν σφάλματα που δεν ήταν στα όρια του σχεδιασμού και είναι δύσκολο να γίνει αναβάθμιση των κανόνων για να τα περιλαμβάνουν και αυτά.

Οι προηγμένοι αλγόριθμοι FDD χωρίζονται σε δύο κατηγορίες: Μέθοδοι αξιοποίησης/εξόρυξης δεδομένων (data driven) και αλγόριθμοι FDD βάσει μοντέλου (model-based). Η πρώτη κατηγορία περιλαμβάνει κυρίως αλγόριθμους που προέρχονται από το πεδίο της μηχανικής μάθησης και αναγνώρισης προτύπων. Οι μέθοδοι δεδομένων απαιτούν ιστορικά δεδομένα (σύνολα δεδομένων αισθητήρων) για την εκπαίδευση των κανόνων απόφασης. Μεταξύ των δημοφιλών μεθόδων που βασίζονται σε δεδομένα είναι: Η Ανάλυση Κύριων Συνιστωσών (PCA), οι Μηχανές Διανυσμάτων Στήριξης (Support Vector Machines, SVM), τα Νευρωνικά Δίκτυα (NN), οι Γενετικοί Αλγόριθμοι (GA) και τα μοντέλα ασαφούς λογικής (fuzzy logic). Στην **εικόνα 9** φαίνεται η διάκριση των μεθόδων FDD όπως έχει διαμορφωθεί. Παρατηρείται ότι οι μέθοδοι βασισμένες σε μοντέλο, χωρίζονται επιπλέον σε ποιοτικές (qualitative) και ποσοτικές (quantitative), ανάλογα με το αν χρησιμοποιούν λεπτομερή φυσικά μοντέλα ή εξειδικευμένους κανόνες. Οι μέθοδοι αυτοί ξεφεύγουν από το θέμα της εργασίας, οπότε δε θα αναλυθούν περαιτέρω.




**Εικόνα 9:** Κατηγοριοποίηση των μεθόδων ανίχνευσης και διάγνωσης σφάλματος [78].

Οι μέθοδοι αξιοποίησης δεδομένων ή μαύρου κουτιού τις οποίες πραγματεύεται η εργασία αυτή, βασίζονται κυρίως σε στατιστικές αναλύσεις χρονοσειρών και αλγόριθμους μηχανικής μάθησης για την αξιολόγηση και την πρόβλεψη της ενεργειακής κατανάλωσης του κτιρίου, την ανίχνευση σφαλμάτων στο σύστημα HVAC και την υπόδειξη στοιχείων που προβλέπεται να παρουσιάσουν σφάλμα στο

κοντινό μέλλον. Αυτές οι μέθοδοι δεν απαιτούν στοιχεία σχετικά με τις ιδιότητες των κτιρίων, αλλά στηρίζονται σε ιστορικά δεδομένα ενεργειακής κατανάλωσης για την πρόβλεψη. Σε αυτή την κατηγορία εντάσσονται και οι τεχνικές που αξιοποιούν τη μηχανική μάθηση.

### 3.5 Σύγχρονες μέθοδοι μηχανικής μάθησης για ανίχνευση σφαλμάτων σε συστήματα κτιρίων

Η υπολογιστική ισχύς έχει αυξηθεί δραματικά τα τελευταία χρόνια μαζί με σημαντική αύξηση της συλλογή δεδομένων, δημιουργώντας νέες δυνατότητες για μεθόδους ανίχνευσης σφαλμάτων χρησιμοποιώντας μηχανική μάθηση. Οι Zhao et al. διεξήγαγαν μια ανασκόπηση το 2019 των τάσεων στη χρήση της βιομηχανίας μεθόδων τεχνητής νοημοσύνης για FDD [47]. Η εργασία χώρισε τις μεθόδους σε δύο ευρείες κατηγορίες: μέθοδοι που βασίζονται σε δεδομένα και μέθοδοι που βασίζονται στη γνώση. Υποκατηγορίες αλγορίθμων μηχανικής μάθησης στις οποίες διαχωρίζονται περαιτέρω αυτές οι ευρείες κατηγορίες περιλαμβάνουν την επιτηρούμενη και τη μη επιτηρούμενη μάθηση. Στην **εικόνα 10** φαίνεται διαγραμματικά αυτός ο διαχωρισμός:



**Εικόνα 10:** Το δέντρο των μεθοδολογιών που βασίζονται στην εκμάθηση πάνω σε δεδομένα [78].

Όπως αναφέρθηκε σε προηγούμενη ενότητα, μερικά από τα πιο συχνά σφάλματα που έχουν εντοπιστεί είναι:

- Δυσλειτουργικοί ενεργοποιητές
- Λανθασμένες ενδείξεις
- Φραγμένοι αεραγωγοί
- Κακώς συντηρημένα φίλτρα
- Διακύμανση των σημείων ρύθμισης πίεσης
- Αστοχία κινητήρων, ανεμιστήρων
- Καθαλάτωση σπειρωμάτων

Οι επιτηρούμενες μέθοδοι μάθησης χρησιμοποιούν τα χαρακτηριστικά εισόδου ενός συνόλου δεδομένων και τις γνωστές κλάσεις εξόδου για την εκπαίδευση ενός μοντέλου. Αυτές οι μέθοδοι απαιτούν περισσότερα επεξεργασμένα δεδομένα από άλλους τύπους αλγορίθμων, καθώς τα σύνολα δεδομένων εισόδου απαιτούν πρόσθετες πληροφορίες για την αναπαράσταση των κλάσεων. Αυτές οι κατηγορίες

εξόδου μπορούν να παρέχονται από τους αισθητήρες στο κτίριο, ή μπορεί να εκχωρηθούν χειροκίνητα. Για παράδειγμα, σε μία μονάδα AHU που επιθυμούμε να φτιάξουμε ένα μοντέλο που θα προβλέπει πότε ο αποσβεστήρας (ρυθμιζόμενη σχάρα που ρυθμίζει τη ροή αέρα) είναι κολλημένος σε μία θέση, χρειάζεται να έχουμε αρκετά δεδομένα τόσο στη φυσιολογική λειτουργία όσο και στην κατάσταση σφάλματος.

Τα προβλήματα μη επιτηρούμενης μάθησης διαφέρουν από την εποπτευόμενη μάθηση στο ότι η εκπαίδευση του συνόλου δεδομένων περιέχει μόνο τιμές εισόδου χωρίς τις αντίστοιχες τιμές εξόδου. Ο αλγόριθμος χωρίς επίβλεψη καθορίζει μια πιθανή έξοδο με βάση ένα σύνολο εισόδων που μετρήθηκαν από το σύστημα. Ένα πρόβλημα μη επιτηρούμενης μάθησης λύνεται συχνά χρησιμοποιώντας συσταδοποίηση (clustering), όπου γίνεται ένα σύνολο δεδομένων (dataset) ομαδοποιείται σε διαφορετικές συστάδες σχηματίζοντας “νέφη” πυκνότητας. Το αντίστοιχο σε αυτό το πρόβλημα στην επιτηρούμενη μάθηση είναι η ταξινόμηση (classification), όπου ένα σύνολο δεδομένων ταξινομείται με βάση τη γνώση κάποιας ταμπέλας (label) των ταξινομημένων δεδομένων εισόδου, όπως για παράδειγμα το αν ένα δείγμα προέρχεται από ομαλή λειτουργία του συστήματος ή από σφάλμα. Τα παραπάνω αποτελούν δύο πολύ βασικά παραδείγματα αλγορίθμων που χρησιμοποιούνται κατά κόρον, και που βρίσκουν εφαρμογή και σε πιο σύνθετες μεθόδους, όπως τα τεχνητά νευρωνικά δίκτυα (Artificial Neural Networks, ANN).

Οι Tidriri et al. θεώρησαν μια υβριδική προσέγγιση που συνδυάζει μεθόδους βασισμένες σε δεδομένα και μοντέλα [29]. Οι συγγραφείς διαπίστωσαν ότι η απόδοση των μεθόδων που βασίζονται σε δεδομένα εξαρτώνται πολύ από τα δεδομένα εκπαίδευσης, ενώ η απόδοση των μεθόδων που βασίζονται σε μοντέλα συσχετίζεται άμεσα με το μαθηματικό μοντέλο που χρησιμοποιείται στην ανάλυση. Οι συγγραφείς προτείνουν ότι μία υβριδική προσέγγιση που χρησιμοποιεί μεθόδους που βασίζονται σε δεδομένα για τον εντοπισμό σφαλμάτων και μεθόδους που βασίζονται σε μοντέλα για τη διάγνωση σφαλμάτων θα μπορούσε να αποδειχθεί πιο επιτυχημένη από τη χρήση μεθόδων που βασίζονται μόνο σε δεδομένα ή μόνο σε μοντέλα. Διαπιστώθηκε επίσης ότι πολλοί ερευνητές δυσκολεύονται να γεφυρώσουν τις δύο μεθόδους, καθώς δεν υπάρχει κάποιο καθιερωμένο πλαίσιο εργασίας, γεγονός που καθιστά τον συνδυασμό των δύο μεθόδων δύσκολο να εφαρμοστεί. Τα ήδη υπάρχοντα συνδυαστικά μοντέλα μπορεί να είναι ακόμη λίγα [30, 31], ωστόσο η έρευνα σε αυτόν τον τομέα αρχίζει να αυξάνεται με νέες δημοσιεύσεις.

### 3.6 Επιλογή χαρακτηριστικών (feature selection)

Η επιλογή των κατάλληλων χαρακτηριστικών είναι αναγκαία τόσο στην επιτηρούμενη όσο και στη μη επιτηρούμενη μάθηση και χρησιμοποιείται για να αφαιρεθούν περιττά δεδομένα του συνόλου δεδομένων, κάτι το οποίο βελτιώνει την ταχύτητα και την ακρίβειά της φάσης εκπαίδευσης, ανάλογα με την προσέγγιση.

Έχουν προταθεί στη βιβλιογραφία αρκετές επιλογές για να βρεθούν οι βέλτιστες προσεγγίσεις για την επιλογή χαρακτηριστικών.

Οι Changrashekar et al. διεξήγαγαν μια ανασκόπηση του αντίκτυπου της επιλογής χαρακτηριστικών σε μία ανάλυση [33]. Ο Changrashekar διαπίστωσε ότι για ένα από τα σύνολα δεδομένων του, μειώνοντας από 34 χαρακτηριστικά σε μόλις 9 χαρακτηριστικά βελτίωσε την απόδοση του μοντέλου από 90% σε 95%. Μοντέλα που περιέχουν πλεονάζοντα χαρακτηριστικά μπορεί να εφαρμόζουν υπερβολικά καλά στο σύνολο δεδομένων κατά τη φάση της εκπαίδευσης αλλά να έχουν χειρότερη απόδοση στη δοκιμή σε άγνωστα, νέα δεδομένα. Το πρόβλημα αυτό ονομάζεται υπερπροσαρμογή (overfitting) και σχεδόν όλες οι μέθοδοι μηχανικής μάθησης κινδυνεύουν από αυτό. Οι ίδιοι ερευνητές αν και πρότειναν ότι η περικοπή ορισμένων χαρακτηριστικών από τα δεδομένα είναι ευεργετική σε ένα άλλο σύνολο δεδομένων όταν χρησιμοποίησαν όλα τα χαρακτηριστικά παρήγαγαν ακρίβεια σχεδόν 80%, ενώ όταν μείωσαν αυτό το σύνολο δεδομένων κατά 1 χαρακτηριστικό, σε σύνολο 7, η ακρίβειά του μειώθηκε σε μόλις 71%. Αυτά τα παραδείγματα δείχνουν ότι το κλάδεμα χαρακτηριστικών από ένα σύνολο δεδομένων μπορεί να υποβαθμίσουν την απόδοση. Τα συμπεράσματα των συγγραφέων είναι ότι η επιλογή χαρακτηριστικών θα πρέπει να επικυρώνεται για κάθε εφαρμογή.

Οι Yan et al. αξιολόγησαν τα οφέλη ενός αλγορίθμου επιλογής χαρακτηριστικών για προεπεξεργασία δεδομένων [31]. Ο Yan διαπίστωσε ότι η επιλογή χαρακτηριστικών μπορεί να βοηθήσει στον καθορισμό των πληροφοριών που βελτιώνουν στο μέγιστο την απόδοση του μοντέλου. Αυτό μπορεί να χρησιμοποιηθεί όταν αποφασίζεται ποιοί αισθητήρες θα αγοραστούν, επειδή κάθε αισθητήρας έχει ταξινομηθεί ανάλογα με τη σημασία που έχουν τα δεδομένα του για το μοντέλο. Επιπλέον αξιολογήθηκε η ανάλυση περιορισμένου κόστους, η οποία προσομοιώνει έργα με περιορισμένο οικονομικό προϋπολογισμό και διαπίστωσε ότι η χρήση μόλις 16 αισθητήρων στο σύστημα ψύξης τους μπορεί να προσφέρει αρκετές πληροφορίες για να δοκιμαστούν τεχνικές μηχανικής μάθησης, με ακρίβεια μεγαλύτερη από 95%.

Οι ίδιοι ερευνητές χρησιμοποίησαν τον αλγόριθμο ReliefF, ο οποίος υπολογίζει μια βαθμολογία χαρακτηριστικών για κάθε χαρακτηριστικό ώστε να καθορίζει τη σημασία τους (correlation), παράλληλα με την ανάλυση SVM για την επιλογή κατάλληλων χαρακτηριστικών με επιτυχία [35]. Οι συγγραφείς χρειάστηκαν μόλις 6 μεταβλητές στο τελικό μοντέλο αντί για τις αρχικές 65 μεταβλητές και τα παραγόμενα μοντέλα είχαν ακρίβεια μεγαλύτερη από 90%. Όπως γίνεται αντιληπτό, η σημαντική αυτή μείωση των αριθμού των χαρακτηριστικών, μειώνει κατά πολύ τη διαστασιμότητα του προβλήματος, κάτι που διευκολύνει πολύ το υπολογιστικό κομμάτι, και από ότι φαίνεται, μπορεί να έχει και πιο ακριβή αποτελέσματα σε πολλές περιπτώσεις.


Οι Wang και Xiao εφάρμοσαν τη μέθοδο PCA σε αισθητήρες AHU στις μελέτες τους [48]. Οι Li και Wen συνδύασαν το PCA με το μετασχηματισμό κυματιδίου

(wavelet transform) για την ανίχνευση σφαλμάτων σε μονάδες AHU [30]. Οι Du et al. συνδύασαν το PCA με την ανάλυση Fisher για FDD σε αισθητήρες μονάδων κουτιού μεταβλητού όγκου (VAV) [49]. Η μέθοδος ανάλυσης κυρίων συνιστωσών (Principal Component Analysis, PCA) έχει χρησιμοποιηθεί ευρέως στην ανίχνευση σφαλμάτων σε αισθητήρες. Σε αντίθεση με την απλή αφαίρεση των χαρακτηριστικών που δεν έχουν στατιστική σημασία σε ένα σύνολο δεδομένων, η μέθοδος PCA δημιουργεί νέα χαρακτηριστικά αλλά σε λιγότερες διαστάσεις, τα οποία συνοψίζουν καλύτερα τη συσχέτιση (correlation) και τη συνδιακύμανση (covariance) μεταξύ των μεταβλητών.

Η πρώτη Κύρια Συνιστώσα του συνόλου δεδομένων είναι η διάσταση που αποτυπώνει το μεγαλύτερο μέρος της διακύμανσής του. Αυτή η διαδικασία απεικονίζεται στην **εικόνα 11**. Η μέθοδος PCA και γενικά οι τεχνικές που πετυχαίνουν μείωση των χαρακτηριστικών του συνόλου δεδομένων, στοχεύουν να λύσουν το πρόβλημα της “κατάρας της διαστασιμότητας” (curse of dimensionality). Το φαινόμενο αυτό παρατηρείται σε τομείς όπως η αριθμητική ανάλυση, η εξόρυξη δεδομένων και φυσικά η μηχανική μάθηση. Το κοινό μοτίβο αυτού του προβλήματος είναι ότι όσο αυξάνονται οι διαστάσεις, δηλαδή ο αριθμός των ανεξάρτητων μεταβλητών, ο όγκος του  $n$ -διάστατου χώρου αυξάνεται τόσο ραγδαία που τα διαθέσιμα δεδομένα γίνονται αραιά. Για να προκύψουν λοιπόν αξιόπιστα αποτελέσματα, το πλήθος δεδομένων που απαιτούνται συνήθως αυξάνονται εκθετικά με τη διαστασιμότητα. Επίσης, η οργάνωση και η αναζήτηση μέσα σε πλήθος δεδομένων συχνά βασίζεται στο να ανιχνευτούν περιοχές όπου τα αντικείμενα δημιουργούν συστάδες με παρόμοιες ιδιότητες. Σε δεδομένα πολλών διαστάσεων όμως, αυτές οι συστάδες συχνά εμπλέκονται και είναι δυσδιάκριτες, κάτι που εμποδίζει εφαρμογές όπως η συσταδοποίηση.

Οι Hu et al. μελέτησαν την ευαισθησία της ανίχνευσης σφάλματος σε διαφορετικά επίπεδα σοβαρότητας του λάθους, σε αισθητήρες ενός ψυκτικού συγκροτήματος [50]. Ωστόσο, υπάρχουν περιορισμοί στη χρήση μεθόδων PCA για διάγνωση σφαλμάτων. Οι Zhao et al. διαπίστωσαν ότι η ανάλυση των κύριων συνιστωσών χρησιμοποιεί γραμμικές υποθέσεις, οι οποίες μπορεί να αποβούν επιζήμιες για την απόδοση επειδή τα δεδομένα του ψυκτικού συγκροτήματος είναι συχνά μη γραμμικά [51].

Οι Beghi et al. χρησιμοποίησαν PCA για να διακρίνουν τις παρεκκλίσεις από την κανονική λειτουργία και ανακατασκεύασε τις συνεισφορές κάθε μεταβλητής για να ταξινομήσει τις μεταβλητές ανάλογα με τη βελτίωσή τους, λαμβάνοντας υπόψη την ακρίβεια του μοντέλου [52]. Οι Mahadevan et al. αξιοποίησαν μεθόδους PCA και δυναμικής PCA για την ανίχνευση σφαλμάτων χρησιμοποιώντας καθιερωμένες διαδικασίες και συνδύασαν αυτά τα αποτελέσματα με έναν δυαδικό ταξινομητή (binary classifier) μέσω μηχανών διανυσμάτων στήριξης (SVM) για την εφαρμογή διαγνωστικής σφαλμάτων [53]. Οι Zhang et al. εφάρμοσαν PCA μαζί με ομαδοποίηση (clustering) για τον εντοπισμό και τη διάγνωση βλαβών στους αισθητήρες κτιρίων [56].



**Εικόνα 11:** Ανάλυση κυρίων συνιστωσών στο διδιάστατο επίπεδο. Η πράσινη ευθεία αντιστοιχεί στην πρώτη κύρια συνιστώσα, όπου μεγιστοποιείται η διακύμανση των μπλε σημείων [92].

Τέλος, οι Xiao et al. ανέπτυξαν μοντέλα PCA που παρακολουθούν την ισορροπία ροής θερμότητας και πίεσης σε ένα AHU [57]. Ο Wang και ο Xiao επεκτάθηκαν σε αυτήν την έρευνα χρησιμοποιώντας εμπειρικούς κανόνες (expert rules) για να βοηθήσουν στη διάγνωση βλαβών και στην ανάπτυξη ξεχωριστών μοντέλων για ροή θερμότητας και εξισορρόπηση πίεσης. Η έρευνα των συγγραφέων ολοκληρώνεται με μια τρίτη επανάληψη του αλγόριθμου σε μοντέλα που προέρχονται από προσομοίωση. Πολλοί ακόμη ερευνητές έχουν μελετήσει τις ικανότητες του PCA στην ανίχνευση και διάγνωση βλαβών αισθητήρα σε ένα σύστημα HVAC. Στις επόμενες ενότητες θα δοθούν βασικά στοιχεία μεθόδων μηχανικής μάθησης που χρησιμοποιούνται σε εφαρμογές ανίχνευσης σφαλμάτων σε συστήματα HVAC, καθώς και πρακτικές εφαρμογές που συναντώνται στη βιβλιογραφία.

### 3.7 Επιτηρούμενη μάθηση

Οι μέθοδοι που βασίζονται σε δεδομένα εκτελούν ανάλυση χρησιμοποιώντας κυρίως στατιστικές μεθόδους όπως η παλινδρόμηση ή πολυταξική ταξινόμηση (multiclass classification). Αυτή η κατηγορία αποτελεί την πλειοψηφία (79%) όλων των υλοποιήσεων στη βιομηχανία [58]. Οι μηχανές διανυσμάτων υποστήριξης έχουν



αποδειχθεί ότι είναι ένα πανίσχυρο εργαλείο πολυταξικής ταξινόμησης σε όλους τους τομείς και έχουν εφαρμοστεί εκτενώς εντός κτιριακών συστημάτων.

Οι Dehestani et al. ανέπτυξαν μια προσέγγιση προώθησης (boosting) χρησιμοποιώντας ένα τεχνητό νευρωνικό δίκτυο για τη δημιουργία υπολοίπων δεδομένων (data residuals), τα οποία στη συνέχεια χρησιμοποιήθηκαν για την εκπαίδευση του SVM [59]. Οι Yan et al. εκμεταλλεύτηκαν τη διαδοχική επιλογή χαρακτηριστικών προς τα εμπρός για να μειώσουν τον αριθμό χαρακτηριστικών στην είσοδο πριν από τη χρήση του SVM [35]. Οι Chandrashekar και Sahin πραγματοποίησαν μια ανασκόπηση των μεθόδων προεπεξεργασίας σε γενικά προβλήματα επιστήμης υπολογιστών και ενσωματωμένες μεθόδους [33].

Οι Han et al. ανέπτυξαν μια μέθοδο για ψύκτες που χρησιμοποιούν SVM, η οποία ήταν σε θέση όχι μόνο να ανιχνεύει, αλλά και να εντοπίζει το εξάρτημα του σφάλματος, επιτυγχάνοντας 95% ακρίβεια για πολλά διαφορετικά σφάλματα [60]. Οι Kriegel et al. ανέπτυξαν έναν αλγόριθμο ανίχνευσης έκτοπων τιμών (outlier detection) που λειτουργεί με βάση τη διακύμανση των γωνιών μεταξύ ζευγών σημείων, που επιλύει την κατάρρα της διάστασης των περίπλοκων συνόλων δεδομένων [62]. Βρήκαν ότι η μέθοδος αυτή παρήγαγε τιμές ανάκλησης και τιμές ακριβείας εντός διαστήματος 10% από άλλους δημοφιλείς αλγόριθμους ανίχνευσης σφαλμάτων όπως ο τοπικός συντελεστής ακραίας τιμής (Local Outlier Factor, LOF).

Οι Bode et al. διαπίστωσαν ότι η χρήση ενός ισορροπημένου συνόλου δεδομένων είναι σημαντική κατά την ανάπτυξη της μηχανής αλγόριθμοι εκμάθησης [46]. Ως ισορροπημένο σύνολο δεδομένων ονομάζεται αυτό για το οποίο οι διαθέσιμες τιμές-στόχοι (labels) για ταξινόμηση, είναι κατανομημένες ομοιόμορφα. Το πείραμά τους απέτυχε να παράγει αξιόπιστες μετρήσεις λόγω ετερογένειας μεταξύ κανονικών και ελαττωματικών δεδομένων στο σύνολο δεδομένων τους. Με το 99,9% των δειγμάτων στο σύνολο δεδομένων χωρίς σφάλματα, ο αλγόριθμος έμαθε να προβλέπει την κατάσταση σφάλματος οποιουδήποτε συνόλου δεδομένων χωρίς σφάλμα, ακριβώς επειδή στην ουσία είχε φτάσει σε σημείο υπερπροσαρμογής (overfitting). Ενώ η ακρίβεια (accuracy) της δοκιμής του ήταν υψηλή, παρήγαγε ένα άχρηστο μοντέλο που δεν μπορεί να προβλέψει καθόλου σφάλματα. Αυτό είναι ιδιαίτερα σημαντικό στις εφαρμογές ανίχνευσης σε έξυπνα κτίρια, όπου μπορεί να είναι δύσκολο να αποκτηθεί ένα σύνολο δεδομένων με γνωστά σφάλματα, όπως θα γίνει εμφανές και στο πειραματικό κομμάτι της εργασίας αυτής.

Οι Ebrahimifakhar et al. αξιολόγησαν εννέα διαφορετικούς αλγόριθμους ταξινόμησης για τον προσδιορισμό της καλύτερης απόδοσης δεδομένου του συνόλου τους που αποτελείται από 15 χαρακτηριστικά με 8 πιθανές κλάσεις εξόδου [63]. Οι συγγραφείς προσδιόρισαν ότι ο ταξινομητής SVM παρήγαγε την καλύτερη ακρίβεια από τους εννέα αλγόριθμους που δοκίμασαν. Οι Shohet et al. αξιολόγησα επίσης αρκετούς διαφορετικούς αλγόριθμους για να μοντελοποιήσουν λέβητες χωρίς συμπίκνωση και διαπίστωσαν ότι τα δένδρα απόφασης και οι SVM παρήγαγαν την

υψηλότερη ακρίβεια πρόβλεψης σφαλμάτων, πάνω από 95% για καθέναν από τους δύο τρόπους.

Οι Lee et al. ανέπτυξαν διάφορες εποπτευόμενες μεθόδους ομαδοποίησης (συσταδοποίησης) για τον εντοπισμό ψευδών συναγερμών (false alarm) σε ψυκτικά συγκροτήματα ενός data center [64]. Οι συγγραφείς βρήκαν το πολυκλάδο νευρωνικό τους δίκτυο να έχει την καλύτερη απόδοση, με ακρίβεια πρόβλεψης 99,6% στο σύνολο δεδομένων δοκιμών του. Οι Wang et al. χρησιμοποίησαν μία μέθοδο του εκθετικού σταθμισμένου κινητού μέσου όρου που βασίζεται υπόλοιπα και κανόνες boolean λογικής για τον εντοπισμό και τη διάγνωση μιας ποικιλίας βλαβών σε AHU [65].

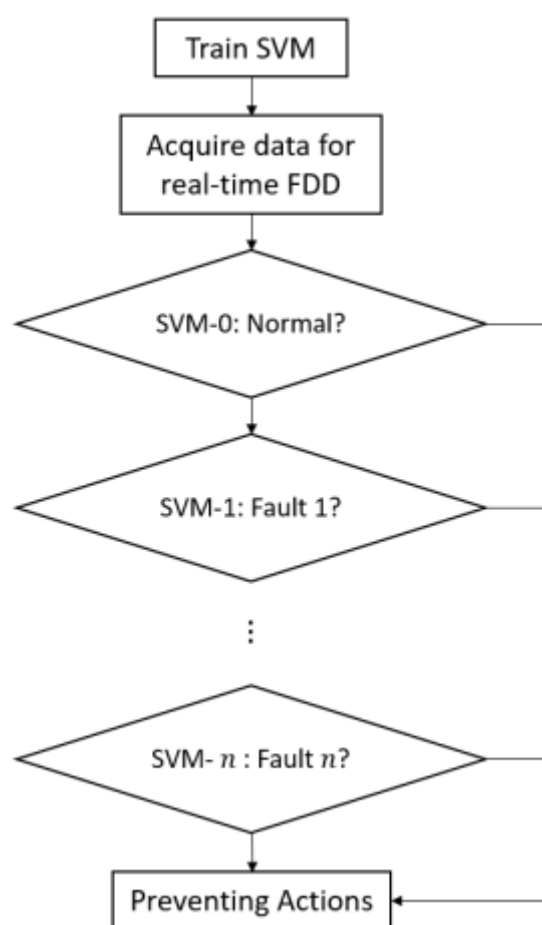
Οι Yu et al. πρότειναν μια τεχνική εξόρυξης δεδομένων που χρησιμοποίησε την εξόρυξη κανόνων συσχέτισης (ARM), η οποία καθορίζει κανόνες που βασίζονται σε κοινούς συσχετισμούς μεταξύ μεταβλητών, παράλληλα με μεθόδους ανίχνευσης πλευρικών ακραίων στοιχείων για τη μοντελοποίηση της κατανάλωσης ενέργειας των κτιρίων σε διάφορα κλίματα [66].

### 3.7.1 Μηχανές διανυσμάτων στήριξης

Μερικοί ερευνητές έχουν εργαστεί στο να συνδυάσουν διάφορες καθιερωμένες μεθόδους FDD για τη δημιουργία νέων, πιο ισχυρών μεθόδων για τον εντοπισμό σφαλμάτων. Οι Liang et al. συνδύασαν το FDD βασισμένο σε φυσικό μοντέλο με SVM [67]. Το μοντέλο τους αναπτύχθηκε χρησιμοποιώντας θερμοδυναμικές σχέσεις για τα ισοζύγια μάζας και ενέργειας στο σύστημα και στη συνέχεια απλοποιήθηκε με τη χρήση μιας μεθόδου ομαδοποιημένης παραμέτρου, η οποία συνδυάζει πολλά στοιχεία του συστήματος σε μία παράμετρο στο μοντέλο. Ένας ψύκτης για παράδειγμα θα γινόταν μία μόνο παράμετρος στο τελικό μοντέλο παρόλο που αποτελείται από πολλά εξαρτήματα. Αυτό τα δεδομένα εξόδου του μοντέλου αναλύθηκαν πρώτα χρησιμοποιώντας ανάλυση υπολοίπων με πολλαπλά κατώφλια ανίχνευσης να καταγράφουν αρκετά διαφορετικές επιδόσεις. Αυτή η ανάλυση λειτουργεί ως το βήμα ανίχνευσης σφάλματος. Αφού εντοπιστεί η ελαττωματική απόδοση, τα δεδομένα αποστέλλονται στον SVM, ο οποίος έχει διαμορφωθεί με παράμετρο “ένα προς όλα” (one vs all, OvO), που εμφανίζεται στην **εικόνα 12**, για να προσδιοριστεί ποιο σφάλμα έχει ενεργοποιηθεί. Οι συντάκτες αυτής της εργασίας μπόρεσαν να παράγουν ακρίβεια 100% για τον ταξινομητή τους. Επιτεύχθηκε τέλεια ακρίβεια συμπεριλαμβάνοντας μόνο ανεξάρτητα σφάλματα στο σύνολο δεδομένων. Έτσι, χωρίς αλληλεξαρτήσεις, αλγόριθμος είναι σε θέση να διαχωρίσει τέλεια κάθε σφάλμα στο χώρο χαρακτηριστικών.

Τα SVM έχουν χρησιμοποιηθεί για την ταξινόμηση δεδομένων κτιρίου. Οι Suykens και Vandewalle ανέπτυξαν ταξινομητές SVM με τη μέθοδο ελαχίστου τετραγώνου για δυαδική ταξινόμηση σφαλμάτων [68], η οποία χρησιμοποιήθηκε από

τους Han et al. για διάγνωση σφαλμάτων ψυκτικού συγκροτήματος [69]. Οι Every et al. ανέπτυξαν μια μέθοδο χωρίς επίβλεψη για διάγνωση σφαλμάτων με χρήση SVM και μοντέλων συστημάτων Gauss [70]. Οι Han et al. ανέπτυξαν έναν άλλο αλγόριθμο FDD που χρησιμοποιεί SVM για ταξινόμηση σε συστήματα συμπίεσης ατμών [71], που κάνει χρήση δεδομένων μέτρησης από το ψυκτικό συγκρότημα από το έργο ASHRAE 1043-RP. Οι συγγραφείς επέλεξαν τη συνάρτηση πυρήνα της συνάρτησης ακτινικής βάσης (RBF) και χρησιμοποίησαν 10 φορές διασταυρούμενη επικύρωση (10 fold cross-validation) για να συντονίσουν τις παραμέτρους του μοντέλου. Οι Li et al. συνδύασαν τη Δυναμική Συνάφεια με τον SVM αλγόριθμο για τη δημιουργία του BR-SVM, το οποίο ήταν σε θέση να διαγνώσει με επιτυχία πολλαπλά σφάλματα ταυτόχρονα σε ένα σύστημα που χρησιμοποιεί ένα μοντέλο εκπαιδευμένο μόνο σε μεμονωμένα σφάλματα [72]. Οι Wu et al. ανέπτυξαν ένα SVM μοντέλο ενός AHU [73]. Το μοντέλο τους είχε ακρίβεια δοκιμής 99,58%, αλλά απέτυχε να ταξινομήσει σωστά τις βλάβες που εντόπισε. Οι Han et al. εφάρμοσαν SVM για τον εντοπισμό πολλαπλών ταυτόχρονων σφαλμάτων σε δεδομένα λειτουργίας ενός ψυκτικού συγκροτήματος, όπου διαπίστωσαν ότι τα μοντέλα τους ήταν σε θέση να προβλέψουν πάνω από 99% πολλαπλών ταυτόχρονων σφαλμάτων στο σύνολο δεδομένων τους [60].




Εικόνα 12: Ένα-προς-ολα (OvO) ταξινόμηση [78].

Τα SVM μπορούν επίσης να εφαρμοστούν με επιτυχία και ως μοντέλα παλινδρόμησης, όπως αναφέρουν οι Tran et al. [74]. Τα SVM γενικά επιχειρούν να λύσουν ένα μη-γραμμικό πρόβλημα με γραμμικό τρόπο. Αυτό το κάνουν αντιστοιχίζοντας τα δεδομένα σε έναν χώρο υψηλότερης διάστασης για να βρουν ένα γραμμικό όριο μεταξύ των κλάσεων εξόδου. Οι συγγραφείς μοντελοποίησαν το σύνολο δεδομένων RP-1043 χρησιμοποιώντας έναν αλγόριθμο SVR διαφορικής εξέλιξης και διαπίστωσαν ότι ο ορθός ρυθμός ανίχνευσης για σφάλματα του ψυκτικού συγκροτήματος ήταν έως και διπλάσιος από την τιμή του στατιστικού μοντέλου αναφοράς. Οι Zhao et al. χρησιμοποίησαν επίσης αλγόριθμους υποστηρικτικής παλινδρόμησης διανυσμάτων (SVR) μαζί με εκθετικά σταθμισμένους κινητούς μέσους όρους για τον εντοπισμό σφαλμάτων του ψυκτικού συγκροτήματος στο σύνολο δεδομένων ASHRAE RP-1043 [50].

### 3.7.2 Νευρωνικά δίκτυα

Τα τεχνητά νευρωνικά δίκτυα (ANN) δείχνουν μεγάλη προοπτική στο να προβλέπουν την κατανάλωση ενέργειας ή να ανιχνεύουν σφάλματα σε εγκαταστάσεις κτιρίων. Οι Afram et al. διεξήγαγαν μια ανάλυση ενός μοντέλου ANN με MPC (Model Predictive Control) μαζί με ένα μοντέλο BNMI (Best Network after Multiple Iterations)[75]. Τέτοιες υλοποιήσεις έχουν εφαρμογές στο κομμάτι της μείωσης την κατανάλωσης ενέργειας ή τη διατήρηση της κλιματικής άνεσης των ενοίκων, μεταβλητές οι οποίες αντιπροσωπεύονται από ένα δείκτη προβλεπόμενης μέσης ψήφου (Predicted Mean Vote, PMV).

Οι Afram et al. σχεδίασαν το νευρωνικό τους δίκτυο το οποίο ήταν ένας Perceptron πολλών στρωμάτων με ένα κρυφό επίπεδο και ένα επίπεδο εξόδου, όπως φαίνεται στην **εικόνα 13**. Το μοντέλο BNMI βρίσκει επαναληπτικά τις βέλτιστες παραμέτρους των βαρών υπολογίζοντας το βαθμό προσαρμογής του μοντέλου (goodness of fit) ύστερα από κάθε επανάληψη και συγκρίνοντας το αποτέλεσμα με ένα κατώφλι.



**Εικόνα 13:** Perceptron πολλαπλών στρωμάτων σύμφωνα με το Θεώρημα Καθολικής Προσέγγισης [78].

Οι Taheri et al. ανέπτυξαν επτά νευρωνικά δίκτυα για να μοντελοποιήσουν δεκαπέντε διαφορετικά χαρακτηριστικά ενός συστήματος VAV προσομοίωσης στο Εθνικό Εργαστήριο Lawrence Berkeley [76]. Τα σύνολα δεδομένων που χρησιμοποιούνται για τους το έργο αποτελούνται από επαληθευμένα κανονικά και ελαττωματικά δεδομένα. Τα νευρωνικά τους δίκτυα προέβλεψαν το σφάλμα του συστήματος των δεδομένων εισόδου. Τα εκπαιδευμένα μοντέλα αξιολογήθηκαν με χρήση των μετρικών ακρίβειας και ανάκλησης. Ως ακρίβεια ορίζεται το κλάσμα των προβλέψεων που ήταν ορθές, ενώ η ανάκληση ορίζεται ως το κλάσμα των ελαττωματικών σημείων που είχαν προβλεφθεί σωστά (True Positive, TP). Οι συγγραφείς διαπίστωσαν ότι ένα από τα λιγότερο σύνθετα μοντέλα τους, που αποτελείται από λιγότερους κόμβους, ξεπέρασε τις επιδόσεις πιο περίπλοκα και παρήγαγαν μέση ακρίβεια 0,8 και 0,72 με μέσο όρο ανάκληση 0,85 και 0,77 για μονοζωνικούς και πολυζωνικούς AHU, αντίστοιχα. Για τα μοντέλα τους, χρησιμοποίησαν μια κατηγορία αναδρομικών νευρωνικών δικτύων (Recurrent NN) που ονομάζεται LSTM και το οποίο θα εξεταστεί λεπτομερώς στο επόμενο κεφάλαιο.

Οι Tang et al. αξιολόγησαν πέντε διαφορετικούς αλγόριθμους εξόρυξης δεδομένων, συμπεριλαμβανομένων των δέντρων αποφάσεων, μηχανές διανυσμάτων στήριξης και νευρωνικά δίκτυα, για να μοντελοποιήσουν το πλήρες σύνολο δεδομένων ενός συστήματος HVAC και διαπίστωσαν ότι ένα πολυστρωματικό μοντέλο perceptron είχε καλύτερη απόδοση για την εφαρμογή συσταδοποίησης [77]. Οι συστάδες που προέκυπταν ήταν σε θέση να ανιχνεύσουν με επιτυχία διαφορετικά σενάρια λειτουργίας για το κτίριο για την παραγωγή ενός μοντέλου με ποσοστό μέσου απόλυτου σφάλματος μικρότερο από 4% της συνολικής κατανάλωσης ενέργειας του συστήματος. Οι Du et al. χρησιμοποίησαν συνδυασμένα νευρωνικά δίκτυα και αφαιρετική ομαδοποίηση για την ανίχνευση διαφόρων βλαβών σε ένα σύστημα HVAC. Οι Fan et al. ανέπτυξαν πολλά νευρωνικά δίκτυα, συμπεριλαμβανομένων των νευρωνικών δικτύων οπισθοδιάδοσης (back-propagation) και Elman για να εντοπιστούν σφάλματα αισθητήρα σε μία μονάδα AHU.

Οι Guo et al. δοκίμασαν ένα νευρωνικό δίκτυο οπισθοδιάδοσης για τον εντοπισμό σφαλμάτων μιας μεταβλητής σε σύστημα κλιματισμού με ροή ψυκτικού υγρού [70]. Οι Magoulès et al. χρησιμοποίησαν έναν αναδρομικό perceptron για τη μοντελοποίηση της κατανάλωσης ενέργειας του κτιρίου, ενώ οι Zhu et al. and Yang et al. συνδυασμένα νευρωνικά δίκτυα με προεπεξεργασία κυματιδίων και φράκταλ για τη μοντελοποίηση της συμπεριφοράς αισθητήρων. Οι Fan et al. προσπάθησαν να εκτελέσει AFDD (automatic FDD) χρησιμοποιώντας νευρωνικά δίκτυα έχοντας στη διάθεση τους περιορισμένα επισημασμένα δεδομένα σε ένα AHU.

Οι Shahnazari et al. ανέπτυξαν αναδρομικά νευρωνικά δίκτυα στρώματος (LRN) για την ανίχνευση και διάγνωση ποικιλίας βλαβών HVAC σε μια σειρά. Οι συγγραφείς διαπίστωσαν ότι τα LRN είναι κατάλληλα για ανίχνευση σφαλμάτων λόγω των μη γραμμικών δυναμικών συναρτήσεων που χρησιμοποιούνται στην


ανάλυσή τους. Τα μοντέλα τους είναι εκπαιδευμένα σε ιστορικό χωρίς σφάλματα και συγκρίνουν υγιή δεδομένα σε σχέση με τα ενημερωμένα δεδομένα μετρήσεων για αποκλίσεις [78].

### 3.8 Μη επιτηρούμενη μάθηση

Οι αλγόριθμοι μάθησης χωρίς επίβλεψη μπορούν να διακριθούν περαιτέρω σε δημοφιλείς μεθοδολογίες, όπως η ομαδοποίηση, οι μέθοδοι που βασίζονται σε κανόνες και οι μέθοδοι που βασίζονται σε παλινδρόμηση. Από αυτές τις διακρίσεις, οι μέθοδοι που βασίζονται σε κανόνες ήταν ιστορικά οι πιο ευρέως χρησιμοποιούμενες μέθοδοι. Από την άλλη, η ανάλυση κύριων συνιστωσών και η παλινδρόμηση με χρήση πολύπλοκων αλγορίθμων σε νευρωνικά δίκτυα έχουν αποκτήσει δημοτικότητα τα τελευταία χρόνια.

#### 3.8.1 Συσταδοποίηση

Οι Li et al. συνδύασαν ομαδοποίηση πυκνότητας και PCA για βελτίωση στο μοντέλο single-PCA. Οι συγγραφείς χρησιμοποίησαν τη μέθοδο DBSCAN (Density-Based Space Clustering of Applications with Noise), που είναι μέθοδος ομαδοποίησης σε δεδομένα με θόρυβο, για διάκριση μεταξύ συστάδων άγνωστων σχημάτων με βάση τις συνδέσεις μεταξύ χώρων υψηλής και χαμηλής πυκνότητας. Το DBSCAN δημιουργεί συμπλέγματα με βάση την πυκνότητα των σημείων, εξαιρουμένων των αραιών σημείων. Η **εικόνα 14** δείχνει την ταξινόμηση των πυκνών έναντι αραιών σημείων. Το PCA χρησιμοποιήθηκε σε συνδυασμό με το DBSCAN για να βοηθήσει στην οπτικοποίηση και ερμηνεία αποτελεσμάτων[78].

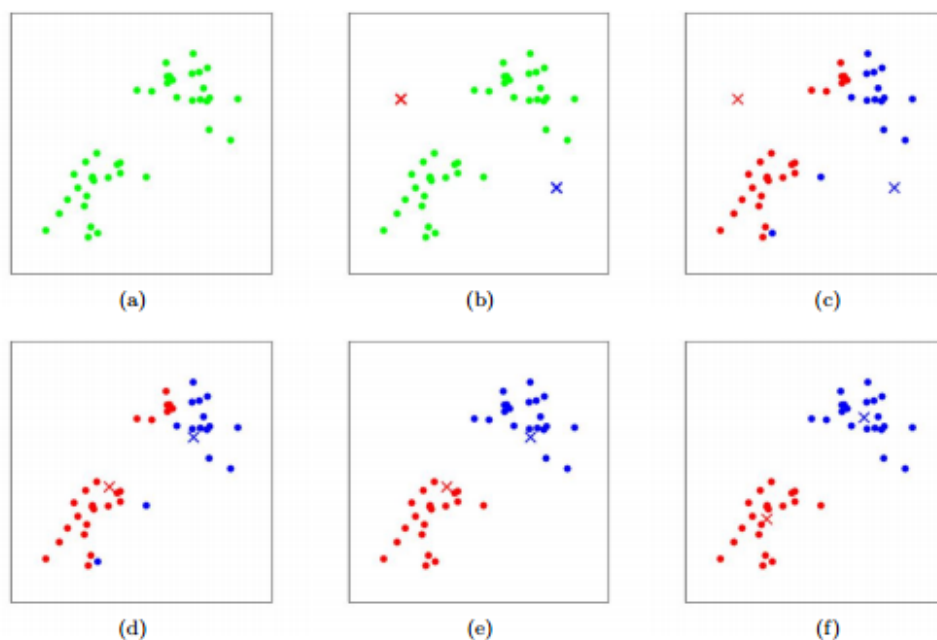


Εικόνα 14: Αναπαράσταση της μεθόδου DBSCAN [78].

Το DBSCAN χρησιμοποιείται στο αρχικό βήμα του αλγορίθμου για τη ομαδοποίηση ιστορικών δεδομένων απόδοσης. Κάθε συνθήκη λειτουργίας υποβλήθηκε σε επεξεργασία χρησιμοποιώντας ένα μοναδικό μοντέλο PCA (περιγράφεται ως υπο-PCA από τους Li και Hu), το οποίο στη συνέχεια

ομαδοποιείται από τον αλγόριθμο DBSCAN. Τα νέα δεδομένα που συλλέγονται από το σύστημα του κτιρίου ταξινομούνται χρησιμοποιώντας τον αλγόριθμο DBSCAN για να προβλεφθεί ποιος τρόπος λειτουργίας κτιρίου είναι ενεργός. Εάν τα νέα δεδομένα ταιριάζουν με μια συνθήκη λειτουργίας που έχει ήδη εκπαιδευτεί από τον αλγόριθμο, το αντίστοιχο μοντέλο θα χρησιμοποιηθεί για ανάλυση. Η προσέγγιση DBSCAN-PCA παρήγαγε βελτίωση 29.8% στην ανίχνευση και 27.9% στην διάγνωση, σε σχέση με την απλή PCA.

Οι Gaitani et al. συνδύασαν ανάλυση κύριων συνιστωσών και ανάλυση συσταδοποίησης για την αξιολόγηση της απόδοσης θέρμανσης σε 1100 σχολικά κτίρια. Η παραγωγή ενέργειας περιγράφει κατά προσέγγιση το ρυθμό κατανάλωσης λαδιού που χρησιμοποιείται στο σύστημα θέρμανσης. Οι συγγραφείς χρησιμοποίησαν K-means ομαδοποίηση, η οποία εκχωρεί μια κλάση εξόδου σε ένα σημείο δεδομένων σύμφωνα με τη μέση τιμή της πλησιέστερης συστάδας. Η μέθοδος εφαρμόστηκε στις κύριες συνιστώσες που προέκυψαν από τις επτά αρχικές μεταβλητές εισόδου για να προσδιοριστεί σε ποια από τις πέντε κατηγορίες ανήκει η λειτουργία του κτιρίου. Η ανάλυση K-means φαίνεται στην **εικόνα 15**, όπου το βήμα 1 αντιπροσωπεύει την αρχική τυχαία εκχώρηση κλάσεων/συστάδων, που ονομάζονται κεντροειδή (centroids), και τα διαδοχικά βήματα δείχνουν την ενημέρωση των κεντροειδών και τη χάραξη νέου ορίου απόφασης. Η ανάλυσή τους ήταν σε θέση να καθορίσει, με μικρή διακύμανση 5%, την ενεργειακή τάξη του σχολικού κτιρίου χρησιμοποιώντας μόνο τις επτά εισόδους.



**Εικόνα 15:** Έξι στάδια επανάληψης της συσταδοποίησης K-means [78].

Οι Luo et al. ανέλυσαν ένα σύστημα κρύου νερού χρησιμοποιώντας την ανάλυση ομαδοποίησης k-means, που εκχωρεί μια κλάση εξόδου σε ένα σημείο δεδομένων

σύμφωνα με τον μέσο όρο του πλησιέστερου συμπλέγματος, σε συνδυασμό με την τιμή Davis–Bouldin για τον προσδιορισμό του βέλτιστου αριθμού συστάδων στο σύνολο δεδομένων. Οι Yang et al. χρησιμοποίησαν τον αλγόριθμο ομαδοποίησης σχήματος  $k$ , ο οποίος είναι ένας αλγόριθμος ομαδοποίησης χρονοσειράς με χρήση κεντροειδών, για την πρόβλεψη μοτίβων χρήσης ενέργειας του κτιρίου χρησιμοποιώντας σύνολα δεδομένων ημερήσιας κατανάλωσης από ένα μοντέλο SVM. Οι Hsu et al. επίσης έκαναν πρόγνωση της κατανάλωσης ενέργειας ενός κτιρίου χρησιμοποιώντας πολλούς διαφορετικούς αλγόριθμους, όπως του K-means, και βρέθηκε αυτή η παλινδρόμηση ομαδικής απόδοσης είχε την καλύτερη απόδοση, με μέσο CVMSE (cross validated mean-squared error) 0,3 και τυπική απόκλιση 0,15. Οι Lavin et al. εντόπισαν επίσης τάσεις στα προφίλ χρήσης ενέργειας των ενοίκων που με k-means ανάλυση και διαπίστωσε ότι ο αλγόριθμος ήταν σε θέση να ομαδοποιήσει σύνολα δεδομένων παρόμοιας απόδοσης. Αρκετοί ερευνητές έχουν χρησιμοποιήσει ομαδοποίηση για να βελτιώσουν τη μοντελοποίηση της επιρροής των ενοίκων στην κατανάλωση ενέργειας ενός κτιρίου. Οι D'Oca et al. εφάρμοσαν παρόμοιες μεθόδους ομαδοποίησης για τον εντοπισμό ανοιχτών και κλειστών παραθύρων σε ένα γραφείο με χρήση αριθμητικών και κατηγορικών μεταβλητών.

Μία άλλη μέθοδος που στηρίζεται σε ομαδοποίηση με σκοπό τη ταξινόμηση είναι ο αλγόριθμος  $k$ -κοντινότερων γειτόνων (kNN), ο οποίος εκχωρεί μια κλάση εξόδου σε κάθε σημείο δεδομένων σύμφωνα με την πιο κοινή κατηγορία των  $k$  πλησιέστερων γειτόνων του, για ανίχνευση έκτοπων τιμών σε σύνολα δεδομένων ηλεκτρικής κατανάλωσης [80]. Οι ερευνητές που πρότειναν αυτό τον τρόπο βρήκαν ότι ο αλγόριθμος kNN ήταν ικανό να παράγει μεγαλύτερη από 90% ακρίβεια στον εντοπισμό ακραίων τιμών.

Οι Yuwono et al. εφάρμοσαν μια τεχνική που ονομάζεται συναινετική ομαδοποίηση Swarm Rapid Centroid Estimation με μία νέα στρατηγική αυτοεξέλιξης ως τεχνική επιλογής χαρακτηριστικών στην ανάλυση AFDD. Χρησιμοποίησαν επίσης τεχνικές Ensemble Rapid Centroid Estimation. Τα αποτελέσματά τους ομαδοποιούνται ανά εποχή και οι μετρήσεις ευαισθησίας και ειδικότητας του μοντέλου για κάθε σφάλμα ήταν μεγαλύτερες από το 97% και στα 3 που αξιολογήθηκαν.

### 3.8.2 Παλινδρόμηση

Η ανάλυση παλινδρόμησης είναι ένα σύνολο στατιστικών διεργασιών για την εκτίμηση της σχέσης μεταξύ της εξαρτημένης μεταβλητής και μίας ή περισσότερων ανεξάρτητων μεταβλητών (χαρακτηριστικών), συνήθως με γραμμική προσέγγιση.

Οι αλγόριθμοι παλινδρόμησης έχουν δει μια έκρηξη σε δημοτικότητα τα τελευταία χρόνια. Οι Yan et al. χρησιμοποίησαν δέντρα απόφασης ταξινόμησης και παλινδρόμησης για FDD μονάδων διαχείρισης αέρα [31]. Η μέση βαθμολογία f-score



για τον αλγόριθμο ήταν 0,97 και μια σύγκριση των διαγνωστικών πληροφοριών με γνώσεις εμπειρογνώμων δείχνουν ότι η ερμηνευσιμότητα του δέντρου αποφάσεων είναι ισχυρή, αν και ορισμένα αποτελέσματα διάγνωσης ήταν λανθασμένα. Οι Li et al. χρησιμοποίησαν επίσης δέντρα απόφασης για την ανίχνευση και διάγνωση βλαβών στο σύστημα ψύξης ενός κτιρίου. Οι συγγραφείς χρησιμοποίησαν έναν πυρήνα μορφής δένδρου εξαρτώμενου από σφάλμα στο μοντέλο, το οποίο παρήγαγε ακρίβεια έως και 90%.

Ο Jones χρησιμοποίησε νευρωνικά δίκτυα προσαρμοστικής θεωρίας συντονισμού πλευρικής εκκίνησης για να ανιχνεύσει και να διαγνώσει βλάβες σε κτιριακά υποσυστήματα. Πρόκειται για συζευγμένα ασαφή δίκτυα, τα οποία χρησιμοποιούν αυτο-οργανούμενη μάθηση αντί για στοχαστική κάθοδο κλίσης. Αξιολογήθηκαν επίσης σφάλματα στην κατασκευή υποσυστημάτων χρησιμοποιώντας νευρωνικά δίκτυα. Οι συγγραφείς βρήκαν ότι η μη γραμμικότητα των δικτύων παλινδρόμησης παράγει ακριβή μοντέλα για λειτουργία κτιρίου.

Οι Howard et al. χρησιμοποίησαν μοντέλα παλινδρόμησης spline, τα οποία μοντελοποιούν μια συνάρτηση ως έναν τμηματικό ορισμό, για τη μοντελοποίηση της ημερήσιας κατανάλωσης ηλεκτρικής ενέργειας σε ένα κτίριο. Οι Yang et al. ανέπτυξαν μια υβριδική ανάλυση χρησιμοποιώντας διάσταση fractal συσχέτισης για μη γραμμική επεξεργασία σήματος με ανάλυση βάσει υπολοίπων για τη διάγνωση αισθητήρα AHU [78].

Οι Yan et al. ανέπτυξαν ένα μοντέλο αυτο-παλινδρόμησης με εξωγενείς όρους (ARX), που μοντελοποιεί τις μελλοντικές επιδόσεις με βάση τις προηγούμενες επιδόσεις, για ψυκτικά συγκροτήματα, το οποίο χρησιμοποιήθηκε σε συνδυασμό με την ανάλυση μηχανών διανυσμάτων υποστήριξης. Οι συγγραφείς διαπίστωσαν ότι χωρίς σωστή προεπεξεργασία των δεδομένων, τα αποτελέσματα ήταν άχρηστα. Οι Yoshida et al. χρησιμοποίησαν ένα αναδρομικό μοντέλο ARX για να ανιχνεύσει σφαλμάτων σε ένα VAV AHU, αλλά διαπίστωσε από σύνολα δεδομένων που περιέχουν σφάλματα αισθητήρα θα προκύψουν μη αποδεκτά αποτελέσματα. Αρκετοί ερευνητές κατάφεραν να αναπτύξουν ένα επιτυχημένο ARX μοντέλο χρησιμοποιώντας τη μέθοδο προεπεξεργασίας ReliefF και ανάλυση SVM στις παραμέτρους του μοντέλου ARX [35].



## Κεφάλαιο 4. Μεθοδολογία ανάπτυξης και εκτέλεσης πειράματος

Στο παρόν κεφάλαιο παρουσιάζεται η προσέγγιση που υιοθετήθηκε για την εφαρμογή της ανίχνευσης σφάλματος σε στοιχεία του εξοπλισμού HVAC. Από την ανάλυση της υπάρχουσας βιβλιογραφίας προκύπτει, ότι η επιτυχής εκτέλεση ενός τέτοιου πειράματος στηρίζεται στην ανάπτυξη μοντέλων βασισμένων σε αλγορίθμους μηχανικής μάθησης, οι οποίοι απαιτούν μεγάλο πλήθος δεδομένων για την εκπαίδευσή τους. Για το σκοπό αυτό, χρησιμοποιούνται δύο σύνολα δεδομένων τα οποία είναι ανοικτά για χρήση και προσφέρονται για τέτοιους σκοπούς. Το πρώτο σύνολο δεδομένων είναι ισορροπημένο ως προς τις δύο κλάσεις (ομαλή λειτουργία - σφάλμα) και η εκπαίδευση γίνεται με χρήση δημοφιλών αλγορίθμων στατιστικής μηχανικής μάθησης. Στη συνέχεια, χρησιμοποιείται ένα δεύτερο σύνολο δεδομένων που παρουσιάζει μεγάλη ετερογένεια, δηλαδή δεν είναι ισορροπημένο. Εδώ υιοθετείται η προσέγγιση του συνόλου δεδομένων ως χρονοσειρά (timeseries) και αξιοποιούνται τα αναδρομικά νευρωνικά δίκτυα μακράς βραχυπρόθεσμης μνήμης (Long Short Memory Recurrent Neural Networks, LSTM/RNN) τα οποία χρησιμοποιούνται γενικά στην πρόβλεψη χρονοσειρών. Στις επόμενες ενότητες, αναλύεται αρχικά το θεωρητικό υπόβαθρο των αλγορίθμων που υιοθετήθηκαν για την εφαρμογή του πειράματος και στη συνέχεια περιγράφονται διεξοδικά τα στάδια της μεθοδολογίας για την ανάπτυξη και εφαρμογή των αλγοριθμικών μοντέλων πάνω σε πειραματικά και προσομοιωμένα σύνολα δεδομένων.

### 4.1 Θεωρητικό υπόβαθρο

Πριν προχωρήσουμε στην ανάλυση της πειραματικής διαδικασίας κρίνεται σκόπιμη μια θεωρητική ανάλυση των αλγορίθμων που χρησιμοποιήθηκαν, προκειμένου να καταστεί κατανοητός ο τρόπος λειτουργίας τους και πως μπορούν να αξιοποιηθούν στο πεδίο της ανίχνευσης σφαλμάτων σε συστήματα HVAC.

#### 4.1.1 Κ-κοντινότεροι γείτονες

Η μέθοδος του κοντινότερου γείτονα είναι μια γενική μέθοδος με εφαρμογές στην κατασκευή μοντέλων πρόβλεψης νέων τιμών που μπορεί να χρησιμοποιηθούν και για την κατάταξη παρατηρήσεων. Η βασική ιδέα είναι πως αν θέλουμε να προβλέψουμε την τιμή μιας καινούριας παρατήρησης  $x$  χρησιμοποιώντας το ήδη υπάρχον δείγμα για να προβλέψουμε μια άλλη μεταβλητή  $y$ , τότε χρησιμοποιούμε για την πρόβλεψη μας την πληροφορία που περιέχουν οι τιμές του δείγματος που μοιάζουν περισσότερο με τη νέα παρατήρηση για την οποία θέλουμε να κάνουμε πρόβλεψη. Η εκτίμηση αυτή δίνεται ως:


$$\hat{y} = \frac{1}{K} \sum_{x_i \in N_k(x)} y_i \quad (1)$$

όπου  $N_k(x)$  είναι το σύνολο που περιέχει τις  $k$  πιο κοντινές παρατηρήσεις στο  $x$  για το οποίο θέλουμε να κάνουμε πρόβλεψη. Δηλαδή βρίσκουμε ποιες παρατηρήσεις είναι πιο κοντά στην τιμή που θέλουμε να κάνουμε πρόβλεψη και προβλέπουμε παίρνοντας το μέσο όρο των τιμών των κοντινότερων παρατηρήσεων.

Η παραπάνω ιδέα έχει ως παραμέτρους αφενός τη τιμή του  $k$ , δηλαδή του αριθμού των πιο κοντινών με το  $x$  παρατηρήσεων και αφετέρου κάποια απόσταση την οποία χρησιμοποιούμε για να βρούμε τις κοντινότερες παρατηρήσεις. Και για τα δύο αυτά χαρακτηριστικά τίθεται το θέμα της επιλογής τους. Υπάρχουν τρόποι να διαλέξουμε το βέλτιστο  $k$ , η απόσταση που θα χρησιμοποιήσουμε εξαρτάται από τη φύση του προβλήματος. Σε όλες τις κοντινές παρατηρήσεις ουσιαστικά δίνουμε το ίδιο βάρος. Μια παραλλαγή της μεθόδου είναι να σταθμίσουμε με την απόσταση, δηλαδή πιο όμοιες παρατηρήσεις με μικρή απόσταση να λαμβάνονται περισσότερο υπόψη.

Σε περιπτώσεις που χρησιμοποιούμε τη μέθοδο του κοντινότερου γείτονα με σκοπό να κατατάξουμε κάποιες παρατηρήσεις τότε δεν μπορούμε να χρησιμοποιήσουμε το μέσο όρο. Συνήθως αυτό που χρησιμοποιούμε ως πρόβλεψη είναι την τιμή με τη μεγαλύτερη συχνότητα στις κοντινότερες παρατηρήσεις. Δηλαδή βρίσκουμε σε ποιες ομάδες ανήκουν οι κοντινότερες παρατηρήσεις και κατατάσσουμε την παρατήρηση μας στην ομάδα στην οποία ανήκουν οι περισσότερες. Εναλλακτικά καθώς έχουμε συχνότητες για κάθε ομάδα μπορούμε να κατατάξουμε με πιθανότητα ανάλογη της σχετικής συχνότητας που βρήκαμε από τις κοντινότερες. Οι κανόνες κατάταξης δεν έχουν κάποια συγκεκριμένη συναρτησιακή μορφή (για παράδειγμα γραμμική, τετραγωνική κλπ). Επίσης με την μέθοδο αυτή μπορεί να φτιάξουμε κανόνα όπου η ομάδα δεν είναι συνεχής, δηλαδή παρεμβάλλεται κάποια άλλη.

Προκειμένου να περιγράψουμε την μέθοδο των  $k$ -κοντινότερων γειτόνων ( $k$ -nearest neighbors) ας σκεφτούμε πως ανάμεσα σε ένα πλήθος από γνωστές παρατηρήσεις, τις οποίες και έχουμε χωρίσει σε δύο ομάδες θέλουμε να κατατάξουμε μια παρατήρηση. Για να γίνει πιο κατανοητό αναφέρουμε ένα παράδειγμα. Ας υποθέσουμε λοιπόν πως υπάρχουν δύο πληθυσμοί παρατηρήσεων και μια άγνωστη παρατήρηση μέσα σε αυτούς την οποία και επιθυμούμε να κατατάξουμε. Όλα τα παραπάνω απεικονίζονται στην **εικόνα 16**, συμβολίζουμε με "συν" την μια ομάδα, με "πλην" την άλλη και με κύκλο την άγνωστη παρατήρηση την οποία και επιθυμούμε να κατατάξουμε στον ένα από τους δύο πληθυσμούς. Σκοπός μας λοιπόν είναι να κατατάξουμε την άγνωστη παρατήρηση σε έναν από τους δύο πληθυσμούς βασιζόμενοι σε έναν επιλεγμένο αριθμό παρατηρήσεων που βρίσκεται πιο κοντά στην άγνωστη για μας παρατήρηση. Με άλλα λόγια ενδιαφερόμαστε να μάθουμε πότε αυτό το άγνωστο σημείο μπορεί να ταξινομηθεί σαν συν και πότε σαν πλην.



Εικόνα 16: Ταξινόμηση άγνωστης παρατήρησης [91].

Πριν συνεχίσουμε ας σκεφτούμε πρώτα το αποτέλεσμα που προκύπτει όταν βασιστούμε σε έναν κοντινότερο γείτονα (1-nearest neighbor). Είναι προφανές πως σε αυτή την περίπτωση η μέθοδος του κοντινότερου γείτονα θα κατατάζει το άγνωστο σημείο σαν "συν" (μιας και το κοντινότερο σημείο όπως φαίνεται στο σχήμα ανήκει στην ομάδα των συν). Ας αυξήσουμε τώρα τον αριθμό των κοντινότερων γειτόνων από έναν σε δύο (2-nearest neighbors). Σε αυτή την περίπτωση η μέθοδος των κοντινότερων γειτόνων δεν μπορεί να κατατάζει την άγνωστη παρατήρηση ούτε ως πλην ούτε ως συν και αυτό γιατί οι δύο πιο κοντινές παρατηρήσεις στο άγνωστο σημείο είναι η μία συν και η άλλη πλην κατά συνέπεια λοιπόν τόσο τα πλην όσο και τα συν έχουν το ίδιο σκορ (ίδιο αριθμό ψήφων). Στη συνέχεια αυξάνουμε τον αριθμό των κοντινότερων γειτόνων σε 5 (5-nearest neighbors). Τώρα καθορίζουμε μια κοντινή γειτονική περιοχή, η οποία και απεικονίζεται στο σχήμα 1 με έναν κύκλο. Από τη στιγμή που σε αυτή την περιοχή (κύκλο) υπάρχουν τα εξής 5 σημεία: 2 συν και 3 πλην αντίστοιχα, τότε το άγνωστο σημείο χαρακτηρίζεται ως πλην.

Από την στιγμή που η μέθοδος των k-κοντινότερων γειτόνων στηρίζει τις προβλέψεις της στην διαισθητική υπόθεση πως οι παρατηρήσεις μεταξύ κοντινών αποστάσεων είναι ενδεχομένως οι ίδιες, επιθυμητό είναι να μπορούμε να διακρίνουμε τις k πιο κοντινές γειτονιές όταν κάνουμε προβλέψεις. Μπορούμε λοιπόν να δώσουμε περισσότερη βαρύτητα στις τιμές που βρίσκονται πιο κοντά στην άγνωστη παρατήρηση. Η παραπάνω σκέψη μπορεί να επιτευχθεί αν δώσουμε βάρος W στις παρατηρήσεις που βρίσκονται πιο κοντά στην γειτονιά της άγνωστης παρατήρησης, που θα καθορίζεται από τις σχετικές ομοιότητες μεταξύ των γειτονιών, με σεβασμό όμως πάντα στο άγνωστο σημείο:

$$W(x, p_i) = \frac{\exp(-D(x, p_i))}{\sum_{i=1}^k \exp(-D(x, p_i))} \quad (2)$$

,όπου  $D(x, p_i)$  είναι η απόσταση μεταξύ του άγνωστου σημείου  $x$  και της  $i$ -στης παρατήρησης  $p_i$  του δείγματος. Είναι προφανές ότι τα βάρη που καθορίσαμε παραπάνω θα ικανοποιούν την εξής σχέση:

$$\sum_{i=1}^k W(x_0, x_i) = 1 \quad (3)$$

Σε προβλήματα παλινδρόμησης ισχύει πως:

$$y = \sum_{i=1}^k W(x_0, x_i) y_i \quad (4)$$

Σε προβλήματα κατάταξης παίρνουμε το μέγιστο της παραπάνω εξίσωσης για κάθε μεταβλητή.

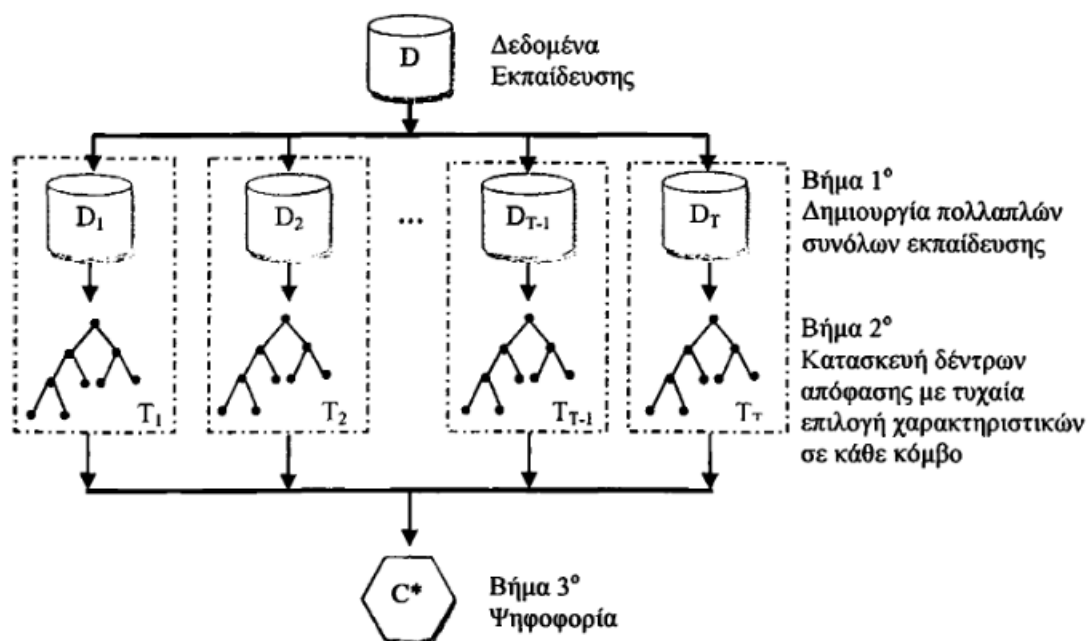
Η μέθοδος των  $k$ -κοντινότερων γειτονιών έχει βρει αρκετές εφαρμογές τα τελευταία χρόνια λόγω της μεγάλης ανάπτυξης των υπολογιστών. Η μέθοδος που παρουσιάσαμε εν συντομία στις παραπάνω σελίδες δεν στηρίζεται σε κάποιο ισχυρό πιθανοθεωρητικό μοντέλο, αλλά στηρίζεται κυρίως σε μαθηματικές προσεγγίσεις και στην διαίσθηση του ερευνητή με αποτέλεσμα σε κανένα σημείο να μην λαμβάνεται σοβαρά υπόψη η μεταβλητότητα που ίσως έχει σοβαρό ρόλο στα αποτελέσματα. Από τη μια πλευρά αυτή η έλλειψη πιθανοθεωρητικού μοντέλου είναι που δεν μας επιτρέπει να κάνουμε στατιστική συμπερασματολογία, από την άλλη μεριά όμως αφήνουμε τα δεδομένα να "μιλήσουν" σε μας και από εκεί να βγάλουμε τα συμπεράσματά μας χωρίς να προσαρμόζουμε ένα μοντέλο που είναι πολύ πιθανόν να είναι λάθος. Στην πράξη τα αποτελέσματα στα οποία καταλήγει η μέθοδος είναι αρκετά ικανοποιητικά.

#### 4.1.2 Δένδρα αποφάσεων - τυχαία δάση

Τα τυχαία δάση (Random Forest, RF) αποτελούν μια ειδική κατηγορία των συγκεραστικών (ensemble) μεθόδων ταξινόμησης η οποία χρησιμοποιεί δέντρα απόφασης.

Για την κατασκευή ενός δέντρου απόφασης ανατίθεται αρχικά στη ρίζα του το σύνολο των δειγμάτων εκπαίδευσης. Κάθε ενδιάμεσος κόμβος περιέχει υποσύνολο των δειγμάτων το οποίο μέσω της εφαρμογής κατάλληλου ελέγχου διαχωρίζεται σε δύο ή περισσότερα μικρότερα υποσύνολα (παιδιά) στο επόμενο επίπεδο. Ο έλεγχος συνήθως αφορά ένα υποσύνολο των χαρακτηριστικών των δειγμάτων εκπαίδευσης. Η επιλογή του καλύτερου διαχωρισμού γίνεται σύμφωνα με μία κατάλληλη μετρική

όπως το gini index, η εντροπία, ή το σφάλμα εσφαλμένης ταξινόμησης. Τα δέντρα του δάσους αναπτύσσονται στο μέγιστο βάθος τους, χωρίς κλάδεμα.



Εικόνα 17: Η διαδικασία κατασκευής τυχαίων δασών [93].

Όπως διακρίνεται στην **εικόνα 17**, η διαδικασία ταξινόμησης αγνώστων παραδειγμάτων (test set) πραγματοποιείται μέσω της διάσχισης των δέντρων του δάσους ξεκινώντας από τη ρίζα και καταλήγοντας σε ένα από τα φύλλα του δέντρου και στη συνέχεια συνδυάζοντας τις προβλέψεις των ταξινομητών σύμφωνα με ένα πλειοψηφικό σύστημα ψηφοφορίας (majority voting scheme). Κάθε παράδειγμα έπειτα ανατίθεται στην κλάση με τη μεγαλύτερη συχνότητα.

Θεωρητικά έχει αποδειχθεί ότι το σφάλμα γενίκευσης (generalization error) των τυχαίων δασών συγκλίνει στην ακόλουθη έκφραση όταν ο αριθμός των δέντρων είναι αρκετά μεγάλος:

$$generalization\ error \leq \frac{\bar{p}(1-s^2)}{s^2} \quad (1)$$

,όπου  $\bar{p}$  είναι η μέση συσχέτιση μεταξύ των ταξινομητών κα  $s$  μια ποσότητα η οποία υπολογίζει τη δύναμη των ταξινομητών. Η δύναμη (strength) ενός συνόλου ταξινομητών αναφέρεται στη μέση απόδοση των ταξινομητών  $M(X, Y)$ . Η απόδοση υπολογίζεται πιθανοτικά ως το περιθώριο του ταξινομητή  $M(X, Y) = P(\hat{Y}_s = Y) - \max_{Z \neq Y} P(\hat{Y}_s = Z)$ , όπου  $\hat{Y}_s$  είναι η προβλεπόμενη κατηγορία του  $X$  σύμφωνα με ένα ταξινομητή ο οποίος έχει κατασκευαστεί από κάποιο τυχαίο διάνυσμα  $\theta$ . Όσο πιο μεγάλο είναι το περιθώριο, τόσο πιο πιθανό είναι

ο ταξινομητής να προβλέψει σωστά την κατηγορία στην οποία ανήκει το  $X$ . Επομένως, όσο μεγαλώνει η συσχέτιση μεταξύ των δέντρων ή αντίστοιχα όσο η δύναμη του δάσους μειώνεται, το όριο του σφάλματος γενίκευσης τείνει να αυξάνεται. Η τυχαιότητα βοηθάει στη μείωση της συσχέτισης μεταξύ των δέντρων απόφασης και κατά συνέπεια στη βελτίωση του σφάλματος γενίκευσης του συνδυαστικού μοντέλου. Η παραπάνω σχέση εξηγεί το λόγο που τα τυχαία δάση (RF) δεν εμφανίζουν φαινόμενα υπερεκπαίδευσης (overfitting) κατά την προσθήκη περισσότερων δέντρων, αλλά αντίθετα τείνουν να περιορίζουν το σφάλμα γενίκευσης.

Παρακάτω συνοψίζονται τα πλεονεκτήματα και οι ιδιότητες των τυχαίων δασών (RF):

- Μπορούν να εκπαιδευτούν σε σύνολα πολλών διαστάσεων, χωρίς να εμφανίζουν υπερεκπαίδευση.
- Εξαιτίας του μεγάλου πλήθους δέντρων, το σφάλμα γενίκευσης είναι περιορισμένο.
- Μη επαναληπτική διαδικασία εκπαίδευσης, ο αλγόριθμος ολοκληρώνεται σε σταθερό αριθμό βημάτων.
- Η τυχαία επιλογή ενός υποσυνόλου των χαρακτηριστικών για τη διαμέριση των παραδειγμάτων κάθε ενδιάμεσου κόμβου ελαττώνει τη συσχέτιση ανάμεσα στα δέντρα και διατηρεί την πόλωση (bias) σε χαμηλά επίπεδα καθώς τα δέντρα αναπτύσσονται χωρίς κλάδεμα. Χρησιμοποιώντας ένα σύνολο δέντρων απόφασης μειώνεται και η διακύμανση (variance).
- Η διάσχιση ενός δέντρου από ένα παράδειγμα ξεκινώντας από τη ρίζα και καταλήγοντας σε έναν από τους τερματικούς κόμβους γίνεται σε λογαριθμικό ως προς το πλήθος των φύλλων του.
- Παρουσιάζουν ανεκτικότητα ως προς το θόρυβο και αριθμητικών σφαλμάτων στα δεδομένα εκπαίδευσης (π.χ. απόκρυψη μέρους του αντικειμένου, ελλιπή δεδομένα).
- Για την επαγωγή κάθε δέντρου περίπου το  $1/3$  των παραδειγμάτων δεν επιλέγεται για εκπαίδευση. Αυτά τα παραδείγματα καλούνται Out-of-Bag παραδείγματα και μπορούν να χρησιμοποιηθούν για την εκτίμηση της πιθανότητας σφάλματος, εξαλείφοντας την ανάγκη ύπαρξης ενός συνόλου ελέγχου ή εφαρμογής της τεχνικής cross-validation.
- Παράγει μια εσωτερική αμερόληπτη εκτίμηση του σφάλματος γενίκευσης καθώς εξελίσσεται η διαδικασία κατασκευής του δέντρου.
- Υπάρχει η δυνατότητα παράλληλης επαγωγής των δέντρων, σε αντίθεση με την μέθοδο προώθησης (Boosting).
- Αναζητά τον καλύτερο διαχωρισμό σε ένα μικρό υποσύνολο των χαρακτηριστικών και δεν κάνει εξαντλητική αναζήτηση όπως ο αλγόριθμος Boosting.
- Μπορεί να χρησιμοποιηθεί για ομαδοποίηση.



- Επιτρέπει τη δημιουργία παραλλαγών της βασικής τεχνικής ως προς την κατασκευή του μοντέλου ταξινόμησης π.χ. χρήση διαφορετικών τεχνικών διαμέρισης των παραδειγμάτων των ενδιάμεσων κόμβων.

Τα τυχαία δάση παρουσιάζουν όμως και κάποια σημαντικά μειονεκτήματα ως προς την εφαρμογή τους τα οποία αναφέρονται συνοπτικά παρακάτω:

- Υψηλό υπολογιστικό κόστος.
- Υπάρχει σημαντικό πλήθος ελεύθερων παραμέτρων τις οποίες πρέπει να προσδιορίσει ο χρήστης π.χ. πλήθος δέντρων, βαθμός κόμβων, πλήθος παραδειγμάτων εκπαίδευσης, συνθήκη τερματισμού διαμέρισης των κόμβων.
- Για την επέκταση ενός μοντέλου με στόχο την εισαγωγή μιας ακόμα κατηγορίας απαιτείται η κατασκευή του μοντέλου από την αρχή.
- Κάθε νέο παράδειγμα πρέπει να διασχίσει όλα τα δέντρα του δάσους για την εκτίμηση της κατηγορίας του.

### 4.1.3 Gradient Boosting

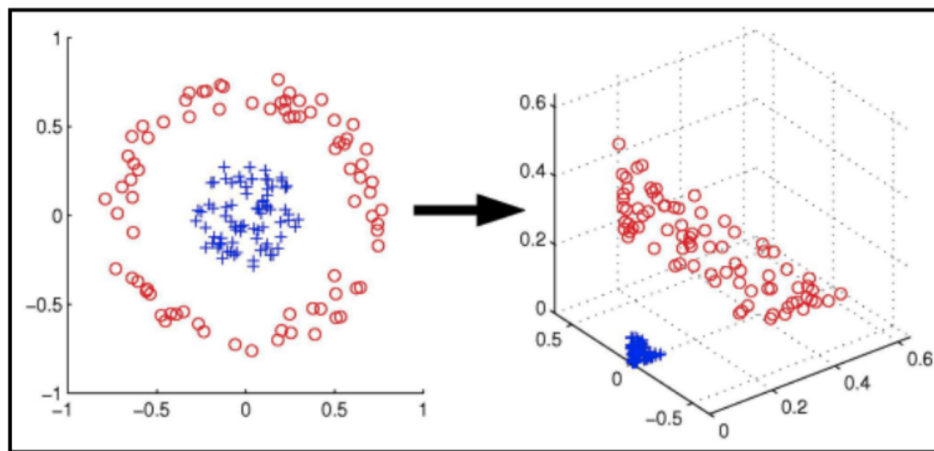
Η προώθηση κλίσης (Gradient Boosting, GB) είναι μια τεχνική μηχανικής μάθησης που χρησιμοποιείται για ταξινόμηση συχνά. Δίνει ένα μοντέλο εκτίμησης υπό τη μορφή ενός συνδυασμού πιο αδύναμων εκτιμητών, που συνήθως είναι δέντρα απόφασης. Η μέθοδος GB συνήθως ξεπερνάει τα τυχαία δάση σε απόδοση.

Πολλά δέντρα αποφάσεων κατασκευάζονται όπου η εκπαίδευση κάθε δέντρου εξαρτάται από προηγούμενως εκπαιδευμένα δέντρα. Στην πράξη, ξεκινά με την εκπαίδευση ενός δέντρου αποφάσεων στο οποίο κάθε παρατήρηση έχει ίσο βάρος. Αφού αξιολογηθεί το πρώτο δέντρο, αυξάνονται τα βάρη εκείνων των παρατηρήσεων που είναι δύσκολο να ταξινομηθούν και μειώνονται τα βάρη για εκείνες που είναι εύκολο να ταξινομηθούν. Το δεύτερο δέντρο λοιπόν αναπτύσσεται σε αυτά τα σταθμισμένα δεδομένα [15]. Κάθε δέντρο εκπαιδεύεται να προβλέπει ψευδό-υπολείμματα των προηγούμενων δέντρων δεδομένης μιας προκαθορισμένης συνάρτησης (objective function). Η αναφορά σε νέα παραδείγματα εφαρμόζεται προσθετικά στο υπόλοιπο αθροιστικό αποτέλεσμα. Ιδιαίτερα το XGBoost διαθέτει μηχανισμούς (παραμέτρους) στοχευμένους στην μείωση του overfitting [16].

### 4.1.4 Μηχανές διανυσμάτων στήριξης

Ο στόχος της μηχανής διανυσμάτων στήριξης (Support Vector Machine, SVM) είναι να βρει μια “γραμμή” που μεγιστοποιεί το περιθώριο μεταξύ δύο κλάσεων. Όταν όμως αντιμετωπίζουν μη γραμμικά προβλήματα, τα SVM δημιουργούν μια αντιστοίχιση μεταξύ ενός συνόλου τιμών εισόδου (παραδείγματα) και ενός χώρου χαρακτηριστικών, στο οποίο αυτές οι αρχικές μη γραμμικές οριακές κλάσεις γίνονται γραμμικά διαχωρίσιμες από έναν μετασχηματισμό (ή χαρτογράφηση) του χώρου των

χαρακτηριστικών (feature space). Αυτή η χαρτογράφηση γίνεται από ένα σύνολο μαθηματικών συναρτήσεων που ονομάζονται πυρήνες. Μετά την εκτέλεση αυτής της αντιστοίχισης, οι SVM χρησιμοποιούν έναν επαναληπτικό αλγόριθμο εκπαίδευσης για να ελαχιστοποιήσουν μια λειτουργία σφάλματος [18]. Σε αντίθεση με την PCA όπου ο στόχος είναι η μείωση των διαστάσεων (χαρακτηριστικών) του συνόλου δεδομένων του προβλήματος, η SVM επιχειρεί να προβάλει το πρόβλημα σε περισσότερες διαστάσεις, με την ελπίδα ότι τα δεδομένα εξόδου θα είναι γραμμικώς διαχωρίσιμα, δηλαδή θα υπάρχει κάποιο υπερεπίπεδο που θα τα χωρίζει στη μέση. Στην **εικόνα 18** φαίνεται αυτή η διαδικασία για ένα τριδιάστατο χώρο χαρακτηριστικών, ώστε να είναι διαισθητικά κατανοητός ο τρόπος λειτουργίας.



**Εικόνα 18:** Τα δεδομένα της εικόνας στο διδιάστατο χώρο δεν είναι γραμμικώς διαχωρίσιμα, όταν όμως προβληθούν στον τριδιάστατο χώρο μπορεί να βρεθεί ένα επίπεδο που τα διαχωρίζει [78].


#### 4.1.5 Τεχνητά νευρωνικά δίκτυα

Τα τεχνητά νευρωνικά δίκτυα σχηματίζονται από τεχνητούς νευρώνες, οι οποίοι είναι μονάδες επεξεργασίας πληροφορίας και προσομοιάζουν τη λειτουργία βιολογικών νευρώνων. Όπως φαίνεται στην **εικόνα 19**, ένας τεχνητός νευρώνας αποτελείται από ένα σύνολο διασυνδέσεων κάθε μια από τις οποίες χαρακτηρίζεται από ένα βάρος, έναν αθροιστή που προσθέτει τα σταθμισμένα σήματα εισόδου και μια συνάρτηση ενεργοποίησης, η οποία λειτουργεί σαν περιοριστής του πλάτους της εξόδου σε ένα συγκεκριμένο εύρος.

Με μαθηματικούς όρους, η έξοδος  $y$  ενός νευρώνα  $k$  μπορεί να περιγραφεί με την παρακάτω σχέση:

$$y_k = \phi\left(\sum_{j=1}^m w_{kj} x_j + b_k\right) \quad (1)$$

,όπου  $x_j$ ,  $w_{j,k}$  είναι τα σήματα εισόδου με τα αντίστοιχα βάρη και  $b_k$  είναι η πόλωση, η οποία μειώνει ή αυξάνει την είσοδο που δέχεται η συνάρτηση ενεργοποίησης  $\varphi$ , ανάλογα με το αν είναι θετική ή αρνητική.

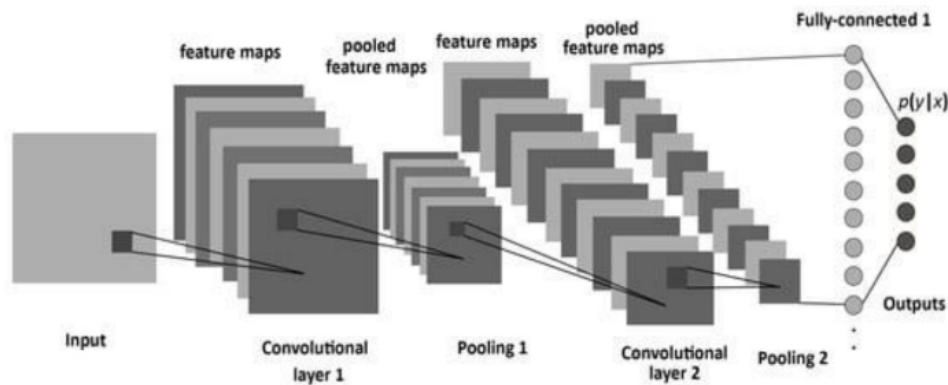


Εικόνα 19: Τεχνητός νευρώνας [89].

Οι νευρώνες ταξινομούνται σε επίπεδα, τα οποία μπορούν να διαθέτουν πολλαπλό αριθμό νευρώνων. Ο συνδυασμός πολλαπλών τέτοιων επιπέδων δημιουργεί ένα πολυεπίπεδο νευρωνικό δίκτυο ή Multilayer Perceptron (MLP). Ένα πολυεπίπεδο νευρωνικό δίκτυο αποτελείται από ένα επίπεδο εισόδου (input layer), ένα ή περισσότερα κρυφά επίπεδα (hidden layers) και ένα επίπεδο εξόδου (output layer). Κάθε νευρώνας που ανήκει σε ένα από τα ενδιάμεσα επίπεδα χρησιμοποιεί μη γραμμική συνάρτηση ενεργοποίησης. Τα MLP ανήκουν στην κατηγορία των νευρωνικών δικτύων πρόσθιας τροφοδότησης (feed forward neural network), στα οποία η ροή της πληροφορίας έχει κατεύθυνση αποκλειστικά από τα αριστερά προς τα δεξιά, δηλαδή δεν υπάρχει ανάδραση μεταξύ των διαφορετικών νευρώνων και επιπέδων (Gardner & Dorling, 1998). Επιπλέον, καθώς υπάρχει πλήρης συνδεσιμότητα (fully connected) μεταξύ των διαδοχικών επιπέδων, κάθε νευρώνας ενός επιπέδου συνδέεται με το σύνολο των νευρώνων του προηγούμενου επιπέδου. Η εκπαίδευση ενός MLP υλοποιείται με επιβλεπόμενη μάθηση χρησιμοποιώντας την τεχνική της οπισθοδιάδοσης (backpropagation).

#### 4.1.5.1 Συνελικτικά νευρωνικά δίκτυα

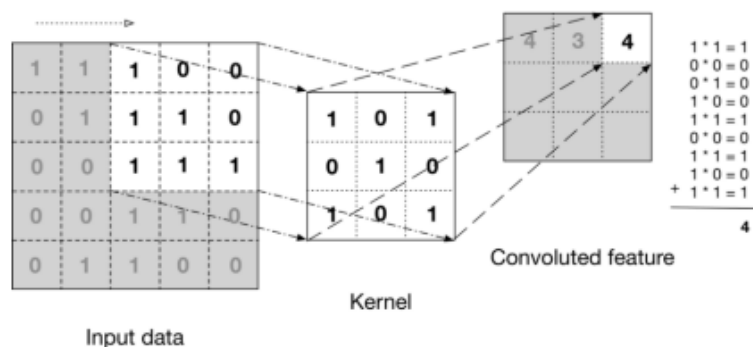
Τα συνελικτικά δίκτυα (Convolutional Neural Networks - CNN) είναι μια κατηγορία των νευρωνικών δικτύων βαθιάς μάθησης, τα οποία είναι κατάλληλα για την επεξεργασία δεδομένων με μοτίβο πλέγματος, όπως είναι οι εικόνες, ενώ έχουν σχεδιαστεί ώστε να μαθαίνουν αυτόματα και προσαρμοστικά χωρικές ιεραρχίες χαρακτηριστικών. Στην πιο απλή μορφή τους τα συνελικτικά δίκτυα μπορούν να θεωρηθούν ως ένα είδος νευρωνικού δικτύου που χρησιμοποιεί πολλά πανομοιότυπα αντίγραφα του ίδιου νευρώνα. Αυτό επιτρέπει στο δίκτυο να έχει πολλούς νευρώνες και να εκφράζει μεγάλα υπολογιστικά μοντέλα, ενώ παράλληλα διατηρεί τον αριθμό των παραμέτρων που περιγράφουν τη συμπεριφορά των νευρώνων αρκετά μικρό.



Εικόνα 20: Αρχιτεκτονική συνελκτικού νευρωνικού δικτύου [89].


Η αρχιτεκτονική του CNN (εικόνα 20) περιλαμβάνει διάφορα δομικά στοιχεία, όπως στρώματα συνέλιξης (convolutional layers), στρώματα συγκέντρωσης (pooling layers) και πλήρως συνδεδεμένα στρώματα (fully connected layers):

- Στρώματα συνέλιξης (convolutional layers): Αποτελούν θεμελιώδη συστατικά της αρχιτεκτονικής CNN, στα οποία εξάγονται χρήσιμα χαρακτηριστικά από το σήμα εισόδου μέσω γραμμικών (συνέλιξη) και μη γραμμικών πράξεων (συνάρτηση ενεργοποίησης). Στη διαδικασία της συνέλιξης ένας μικρός πίνακας, ή αλλιώς πυρήνας (kernel), εφαρμόζεται στην είσοδο που περιγράφεται από έναν δεύτερο μεγαλύτερο πίνακα και το αποτέλεσμα του αθροίσματος των γινομένων των επιμέρους στοιχείων τους δίνει μια έξοδο, που ονομάζεται χάρτης χαρακτηριστικών (feature map). Η διαδικασία αυτή συνεχίζεται έως ότου ληφθεί ένας αυθαίρετος αριθμός χαρτών με χαρακτηριστικά που περιγράφουν την είσοδο. Για παράδειγμα, στην **εικόνα 21** υλοποιείται η διαδικασία της συνέλιξης για μια είσοδο διάστασης 5x5 με τη χρήση ενός πυρήνα 3x3 ενώ η ολίσθηση γίνεται με βήμα ίσο με 1. Το αποτέλεσμα είναι ένας χάρτης χαρακτηριστικών διάστασης 3x3. Οι πυρήνες αποτελούν μια παράμετρο που προσδιορίζεται με την εκπαίδευση του CNN, ενώ άλλες παράμετροι όπως το βήμα (stride) ρυθμίζονται πριν από αυτή.



Εικόνα 21: Παράδειγμα διαδικασίας συνέλιξης [89].

- Στρώματα συγκέντρωσης (pooling layers): Στα στρώματα συγκέντρωσης υλοποιείται μια διαδικασία υποβιβασμού των διαστάσεων των πινάκων που αντιπροσωπεύουν τα χαρακτηριστικά (feature maps), τα οποία υπολογίστηκαν στο προηγούμενο στρώμα προκειμένου να μειωθούν οι περιττές παράμετροι και να μειωθεί ο χρόνος εκπαίδευσης του δικτύου. Αυτό πραγματοποιείται με τεχνικές όπως το max pooling ή το global average pooling. Στο παράδειγμα της **εικόνας 22**, υλοποιείται ο υποβιβασμός της διάστασης του πίνακα εισόδου με την τεχνική max pooling, εφαρμόζοντας ένα φίλτρο διάστασης 2x2, που ολισθαίνει με βήμα (stride) ίσο με 2, κρατώντας τη μέγιστη τιμή από κάθε παράθυρο.




**Εικόνα 22:** Παράδειγμα τεχνικής max pooling [89].

- Πλήρως συνδεδεμένα στρώματα (fully connected layers): Σε αυτή την κατηγορία στρωμάτων υπάρχει πλήρης σύνδεση των νευρώνων τους με τους νευρώνες των γειτονικών επιπέδων. Οι πίνακες που αντιστοιχούν στους χάρτες χαρακτηριστικών που έχουν προκύψει από τα προηγούμενα στρώματα, μετασχηματίζονται σε μονοδιάστατα διανύσματα (vectors) και δίνονται σαν είσοδος σε ένα ή περισσότερα πλήρως συνδεδεμένα στρώματα. Με βάση τα βάρη που έχουν προσδιοριστεί κατά τη διάρκεια της εκπαίδευσης, πραγματοποιείται η είσοδος στην κατάλληλη έξοδο.

#### 4.1.5.2 Αναδρομικά νευρωνικά δίκτυα

Τα αναδρομικά νευρωνικά δίκτυα (Recurrent Neural Networks) είναι μια ειδική κατηγορία νευρωνικών δικτύων, τα οποία χαρακτηρίζονται από ανατροφοδοτούμενες εσωτερικές συνδέσεις δίνοντας τη δυνατότητα επεξεργασίας δεδομένων ακολουθίας (Kelly & Knottenbelt, 2015). Η έξοδος του δικτύου σε κάθε χρονική στιγμή είναι εξαρτημένη τόσο από την προηγούμενη είσοδο, όσο και από τους υπολογισμούς που έχουν πραγματοποιηθεί σε πρότερες χρονικές στιγμές που έχει δεχτεί. Με αυτή την αρχιτεκτονική το δίκτυο δημιουργεί μια εσωτερική μνήμη, με την οποία έχει τη δυνατότητα να αξιοποιεί παρελθοντικές πληροφορίες για την πρόβλεψη. Η απεικόνιση ενός «ξεδιπλωμένου» αναδρομικού νευρωνικού δικτύου παρουσιάζεται στην **εικόνα 23**. Ένας νευρώνας A δέχεται σαν είσοδο τη χρονική στιγμή  $t$ , μια

είσοδο  $x_t$ , παράγει μια έξοδο  $h_t$  και την τροφοδοτεί στους νευρώνες του ίδιου επιπέδου (συμπεριλαμβανομένου του A) τη χρονική στιγμή  $t + 1$ .



Εικόνα 23: Ξεδιπλωμένο αναδρομικό νευρωνικό δίκτυο [89].

Θεωρητικά τα RNN δίκτυα έχουν τη δυνατότητα να συγκρατούν στη μνήμη τους μεγάλες ακολουθίες δεδομένων. Ωστόσο, στην πραγματικότητα δεν καταφέρνουν να μοντελοποιήσουν αποτελεσματικά μεγάλους μήκους ακολουθίες εξαιτίας ενός προβλήματος που προκύπτει κατά την εκπαίδευση του δικτύου. Συγκεκριμένα, για τη διαδικασία εκπαίδευσης χρησιμοποιείται ο αλγόριθμος Back Propagation through time (BPTT), ο οποίος κατά τον υπολογισμό των κλίσεων δεν διατηρεί μεγάλες τιμές κλίσεων όσο εξετάζουμε όλο και παλαιότερα τμήματα της ακολουθίας. Το πρόβλημα αναφέρεται ως εξαφάνιση κλίσεων (vanishing gradient) και έχει σαν αποτέλεσμα η διαδικασία εκπαίδευσης να μην ανανεώνει ορθά τις παραμέτρους του μοντέλου. Αυτό πρακτικά σημαίνει ότι όσο η χρονική απόσταση ανάμεσα στη χρήσιμη πληροφορία και τη στιγμή που μελετάται αυξάνεται, τόσο ένα δίκτυο RNN δυσκολεύεται να την αξιοποιήσει.

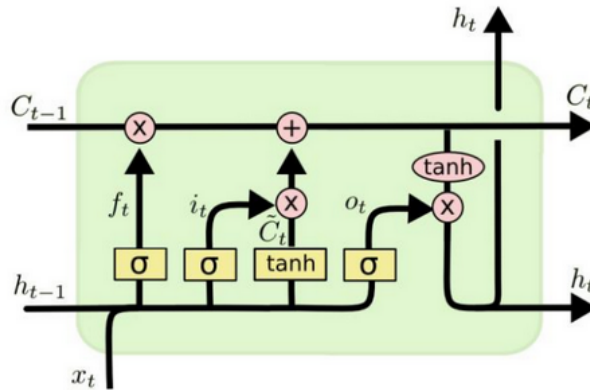
#### 4.1.5.3 Νευρώνες μακράς-βραχυπρόθεσμης μνήμης

Το πρόβλημα της εξαφάνισης των κλίσεων (vanishing gradient) μπορεί να αντιμετωπιστεί με τη χρήση νευρωνικών δικτύων μακράς βραχυπρόθεσμης μνήμης (Long Short Term Memory – LSTM), τα οποία αναπτύχθηκαν πρώτη φορά από τους Hochreiter και Schmidhuber, (1997). Τα LSTM σχεδιάστηκαν με τέτοιο τρόπο ώστε να αποθηκεύουν πληροφορία για μεγάλα χρονικά διαστήματα, υιοθετώντας μια διαφορετική αρχιτεκτονική σε σχέση με τα RNN. Στην **εικόνα 24** παρουσιάζεται η δομή ενός LSTM νευρώνα.

Η κατάσταση ενός νευρώνα τη χρονική στιγμή  $t$  περιγράφεται από τις παρακάτω παραμέτρους:

- το κύτταρο μνήμης (memory cell)  $C_t$
- τη θύρα λήθης (forget gate)  $f_t$
- τη θύρα εισόδου (input gate)  $i_t$

- τη θύρα εξόδου (output gate)  $o_t$
- την κρυφή κατάσταση (hidden state)  $h_t$



Εικόνα 24: Η δομή ενός LSTM νευρώνα [89].

Η ροή πληροφορίας γίνεται μέσω του άξονα που ονομάζεται κυτταρική κατάσταση (cell state) και ενώνει την μνήμη  $C_{t-1}$  του προηγούμενου χρονικού βήματος με την αντίστοιχη  $C_t$  της επόμενης χρονικής στιγμής. Αρχικά η πύλη λήθης αποφασίζει το ποσοστό της πληροφορίας που θα περάσει στο επόμενο στάδιο, λαμβάνοντας υπόψη την προηγούμενη κρυφή κατάσταση  $h_{t-1}$  και την είσοδο  $x_t$ . Η λειτουργία αυτή περιγράφεται από την παρακάτω σχέση:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

Στη συνέχεια πρέπει να αποφασιστεί ποια νέα πληροφορία θα αποθηκευτεί στο cell state. Αυτό υλοποιείται πρώτα μέσω μια σιγμοειδούς συνάρτησης, η οποία αποφασίζει ποιες τιμές θα ανανεωθούν στο επίπεδο εισόδου  $i_t$ . Ακολούθως με τη χρήση μιας υπερβολικής εφραπτομένης δημιουργείται ένα νέο διάνυσμα με υπονήφιες τιμές  $\bar{C}_t$  οι οποίες πρόκειται να προστεθούν στο cell state. Συνδυάζοντας τις δύο αυτές πράξεις υλοποιείται η ανανέωση της κυτταρικής κατάστασης. Οι ανωτέρω λειτουργίες συνοψίζονται με τις παρακάτω εξισώσεις:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

$$\bar{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (3)$$



Η ανανεωμένη κυτταρική μνήμη  $C_t$  προκύπτει τελικά ως το άθροισμα του γινομένου της μνήμης  $C_{t-1}$  της προηγούμενης χρονικής στιγμής με την πύλη λήθης  $f_t$ , ώστε να απορριφθεί ένα μέρος της παλιάς πληροφορία, και των νέων υποψήφιας τιμών  $\bar{C}_t$  προσαρμοσμένων κατά  $i_t$ . Η σχέση που απεικονίζει τα παραπάνω είναι η εξής:


$$\bar{C}_t = f_t \cdot C_{t-1} + i_t \cdot \bar{C}_t \quad (4)$$

Τελευταίο στάδιο της λειτουργίας του νευρώνα LSTM είναι ο προσδιορισμός της εξόδου. Η έξοδος θα είναι μια φιλτραρισμένη εκδοχή της κυτταρικής μνήμης  $C_t$ . Έτσι η μνήμη  $C_t$  διέρχεται μέσω ενός επιπέδου υπερβολικής εφαπτομένης, για να περιοριστεί η τιμή της στο εύρος  $(-1,1)$ , ενώ έπειτα πολλαπλασιάζεται με την πύλη εξόδου, η οποία διέπεται από μια σιγμοειδή συνάρτηση. Το γινόμενο αποτελεί την παραγόμενη έξοδο του νευρώνα. Η μαθηματική απεικόνιση των ανωτέρω δίνεται από τις παρακάτω εξισώσεις:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (6)$$

Μια χρήσιμη παραλλαγή των LSTM δικτύων αποτελούν τα αμφίδρομα LSTM δίκτυα. Τα συμβατικά αναδρομικά δίκτυα αναλύουν για κάθε δεδομένο σημείο μιας ακολουθίας, πληροφορίες που πηγάζουν μόνο από την κατεύθυνση του παρελθόντος. Η εργασία των Graves & Schmidhuber, (2005) διερευνά την δυνατότητα ανάλυσης πληροφοριών τόσο του μέλλοντος όσο και του παρελθόντος σε κάθε χρονική στιγμή. Αυτό επιτυγχάνεται συνενώνοντας δύο LSTM αναδρομικά δίκτυα και θέτοντας το διάνυσμα εισόδου μια φορά με την κανονική χρονική κατεύθυνση στο ένα δίκτυο και μια με την ανάποδη χρονική κατεύθυνση στο άλλο δίκτυο. Η έξοδος, η οποία παράγεται σε κάθε χρονική στιγμή από το αμφίδρομο αναδρομικό δίκτυο, είναι η συνένωση των αποτελεσμάτων, που έχουν επεξεργαστεί στα δύο επιμέρους δίκτυα. Η αρχιτεκτονική ενός αμφίδρομου LSTM δικτύου παρουσιάζεται στην **εικόνα 25**.



Εικόνα 25: Αρχιτεκτονική αμφίδρομου LSTM [89].



## 4.2 Διαδικασία ανάπτυξης


Τα τελευταία χρόνια έχουν αναπτυχθεί αρκετά σύνολα δεδομένων στο πλαίσιο της ανίχνευσης και διάγνωσης σφαλμάτων, τα οποία εμπεριέχουν μετρήσεις κατανάλωσης των μονάδων που περιλαμβάνουν τα συστήματα καθώς και μετρήσεις από διάφορους αισθητήρες που μετρούν τη θερμοκρασία, την πίεση και τη ροή αέρα για μεγάλα χρονικά διαστήματα. Στόχος της δημιουργίας αυτών των βάσεων δεδομένων, ήταν αφενός να υπάρχουν διαθέσιμα δεδομένα προσομοιώσεων συστημάτων HVAC για την εκπαίδευση των αλγορίθμων μηχανικής μάθησης είτε για την πρόβλεψη φορτίου είτε για εφαρμογές FDD και αφετέρου να υπάρχει ένα σημείο αναφοράς για τη σύγκριση των εκάστοτε νέων προσεγγίσεων της ερευνητικής κοινότητας. Ωστόσο, πέρα από το γεγονός ότι αυτά τα σύνολα δεδομένων πολλές φορές δεν είναι προσβάσιμα στο ευρύ κοινό, πολλά σύνολα παρουσιάζουν ορισμένα θέματα, όπως οι ελλειπείς τιμές ή η ανισορροπία των δειγμάτων κανονικής λειτουργίας και εσφαλμένης λειτουργίας. Οι παράγοντες αυτοί λειτουργούν ως εμπόδιο στη σωστή προσαρμογή του αλγορίθμου στα χαρακτηριστικά.

Στην παρούσα εργασία μελετάται η εφαρμογή τεχνικών μηχανικής μάθησης για τον έλεγχο ή την πρόβλεψη σφαλμάτων σε εξοπλισμό κλιματισμού κτιρίων (HVAC), ένα θέμα που αφορά σε μεγάλο βαθμό τον κλάδο των έξυπνων κτιρίων, καθώς υπολογίζεται ότι έως και 40% της ενέργειας που καταναλώνουν προέρχεται από τις εγκαταστάσεις κλιματισμού. Εξαιτίας της αδιάλειπτης λειτουργίας τους, τα συστήματα HVAC αναπόφευκτα θα παρουσιάσουν μηχανικές βλάβες με το πέρασμα του χρόνου, αυξάνοντας και τις απαιτήσεις σε ενέργεια, συχνά χωρίς να γίνεται αντιληπτό από τους υπεύθυνους ενεργειακής διαχείρισης των κτιρίων. Η μοντελοποίηση τόσο των κλιματικών ζωνών όσο και των υποσυστημάτων θέρμανσης/ψύξης μας επιτρέπει να συλλέξουμε δεδομένα για την κατάσταση λειτουργίας του κτιριακού εξοπλισμού.

Σε αυτή την εργασία χρησιμοποιήθηκαν δύο από τα συνολικά πέντε σύνολα δεδομένων από το εργαστήριο του τμήματος τεχνολογίας κτιρίων και υπαίθριων συστημάτων του Lawrence Berkeley National Laboratory (LBNL), τα οποία είναι διαθέσιμα στο διαδίκτυο με ελεύθερη πρόσβαση μαζί με την περιγραφή τους.<sup>3</sup> Κάποια από αυτά προέρχονται από πραγματικά πειράματα ενώ τα δύο που επιλέχθηκαν για την εφαρμογή της παρούσας εργασίας προέρχονται από μοντελοποιημένα κτίρια πολλαπλών ζωνών κλιματισμού. Τα δεδομένα αυτά έχουν μοντελοποιηθεί ως προς διαφορετικά χαρακτηριστικά σε διάφορες περιόδους λειτουργίας με ή χωρίς σφάλμα. Τα δύο σύνολα δεδομένων που επιλέχθηκαν διαφέρουν σημαντικά μεταξύ τους ως προς το ότι το ένα είναι ισορροπημένο ενώ το άλλο παρουσιάζει πολύ μεγάλη ετερογένεια, κάτι το οποίο επηρεάζει την κάθε προσέγγιση. Στην **εικόνα 26** βλέπουμε τις κατανομές των τιμών αληθείας σφάλματος για κάθε σύνολο δεδομένων:

---

<sup>3</sup> [https://figshare.com/articles/dataset/LBNLDataSynthesisInventory\\_pdf/11752740](https://figshare.com/articles/dataset/LBNLDataSynthesisInventory_pdf/11752740)



**Εικόνα 26:** Κατανομές τιμών αληθείας για τα dataset MZVAV-1 και MZVAV-2-2 [91].

Τα δύο σύνολα έχουν επίσης δύο συνθήκες παρουσίας (occupancy mode, πλήρες, κενό) που καθορίζονται από το αν υπάρχει κανένα άτομο μέσα στο κτίριο. Στον πίνακα της **εικόνας 27** αναγράφονται τα στοιχεία και των πέντε συνόλων δεδομένων. Για την εργασία χρησιμοποιήθηκαν τα MZVAV-1 και MZVAV-2-2.

Dataset Name	Creation Method
Simulated multi-zone variable air volume AHU data set(MZVAV-1)	Simulation
Experimental multi-zone variable air volume AHU data set(MZVAV-2-1.csv)	Experimental
Simulated multi-zone variable air volume AHU data set(MZVAV-2-2.csv)	Simulation
Experimental single-zone constant air volume AHU(SZCAV)	Experimental
Single zone variable air volume(SZVAV)	Experimental

**Εικόνα 27:** Στοιχεία των datasets [91].

Το MZVAV-1 έχει αναπτυχθεί χρησιμοποιώντας ένα πλαίσιο συν-προσομοίωσης με μοντέλο φακέλου κτιρίου (building envelope) στο λογισμικό EnergyPlus και μοντέλο συστήματος HVAC στο πρόγραμμα Dymola. Το κτίριο έχει τρεις ορόφους. Η μονάδα διαχείρισης αέρα βρίσκεται στο δεύτερο όροφο. Τα σημεία δεδομένων (datapoints) καταγράφονται ανά λεπτό. Το σφάλμα που εισάχθηκε σε αυτό το μοντέλο αφορά τον αισθητήρα θερμοκρασίας εξωτερικού αέρα [20]. Δηλαδή οι αισθητήρες εξωτερικού χώρου είχαν εσφαλμένη μέτρηση σε αυτό το σύνολο δεδομένων. Αυτό μπορεί να επηρεάζει την κατανάλωση ενέργειας στο σύστημα HVAC με αρνητικό τρόπο, καθώς δεν συναντώνται τα σημεία ελέγχου που θέτει ο θερμοστάτης.

Από την άλλη πλευρά, το MZVAV-2-2 είναι μοντελοποιημένο με βάση τη δοκιμαστική εγκατάσταση στο σταθμό ενεργειακών πόρων του εργαστηρίου. Έχει τρεις μονάδες διαχείρισης αέρα (AHU). Η μονάδα AHU-1 είναι για τον κοινόχρηστο χώρο του κτιρίου και του οι υπόλοιπες δύο είναι για τα δοκιμαστικά συστήματα και είναι πανομοιότυπες μεταξύ τους. Διάφοροι τύποι σφαλμάτων εγχύθηκαν στα σημεία δεδομένων σε διάφορα στοιχεία του μοντέλου αυτού. Οι τύποι βλάβης περιλαμβάνουν διαρροή βαλβίδας του σπειρώματος θέρμανσης, κολλημένη βαλβίδα σπειρώματος θέρμανσης, κολλημένη βαλβίδα σπειρώματος ψύξης και κολλημένος αποσβεστήρας [20]. Ο κολλημένος αποσβεστήρας είναι ένα σφάλμα που συμβαίνει συχνά σε πραγματικά συστήματα. Προκαλείται από τις δονήσεις του συστήματος κλιματισμού (air-condition) που φθείρουν την επαφή των αλουμινένιων πτερυγίων του αποσβεστήρα.

Σε πρώτη φάση, δοκιμάστηκε η εφαρμογή κάποιων μεθόδων στατιστικής μηχανικής μάθησης για να ανιχνεύεται αν κάποια παρατήρηση ανήκει σε λειτουργία με ή χωρίς σφάλμα. Χρησιμοποιήθηκε το σύνολο MZVAV-2-2, στο οποίο υπάρχει ισοβαρής κατανομή και των δύο ταμπελών, με ή χωρίς σφάλμα. Οι μέθοδοι που εφαρμόστηκαν δε θα λειτουργούσαν ικανοποιητικά αν εφαρμόζονταν στο άλλο σύνολο δεδομένων, για το οποίο ακολουθήθηκε διαφορετική προσέγγιση. Έπειτα έγινε εκπαίδευση του ίδιου συνόλου δεδομένων για ταξινόμηση ανάμεσα σε φυσιολογικά και εσφαλμένα δεδομένα με τη χρήση νευρωνικού δικτύου. Στη δεύτερη φάση του πειράματος αξιοποιήθηκαν τα αναδρομικά νευρωνικά δίκτυα και συγκεκριμένα οι νευρώνες LSTM για πρόβλεψη σφαλμάτων στα δεδομένα σε μορφή χρονοσειράς (timeseries), για το σύνολο δεδομένων MZVAV-1.

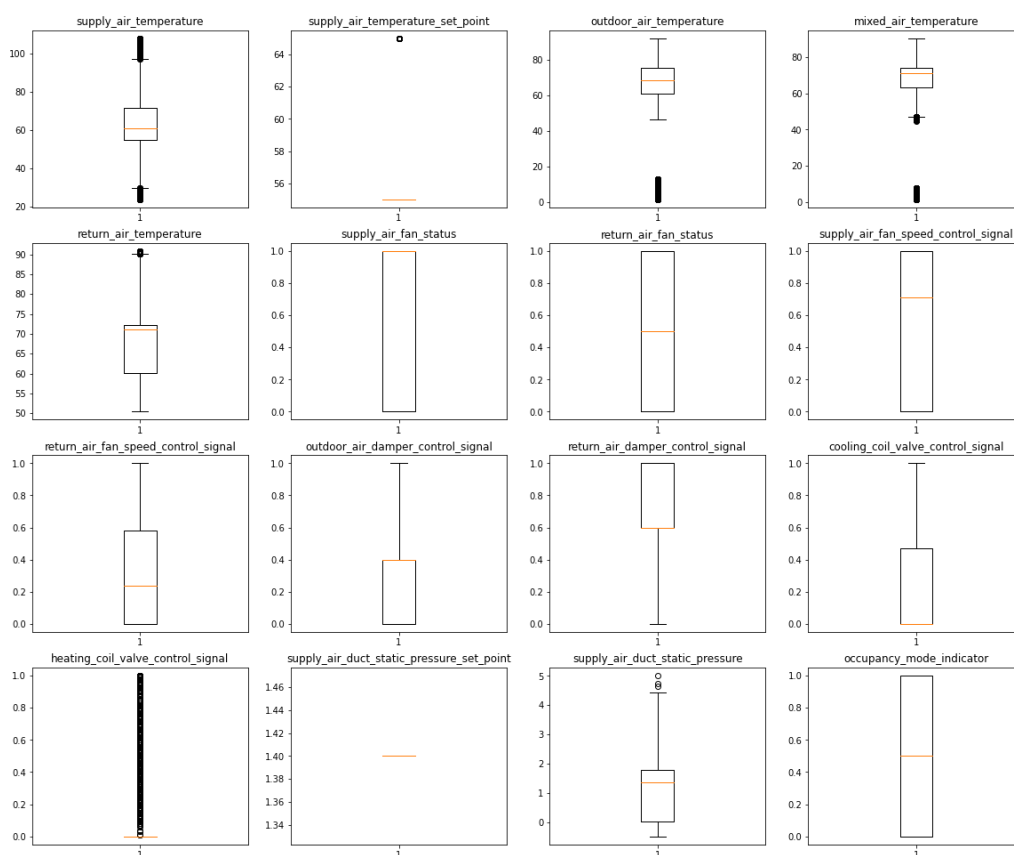
#### 4.2.1 Προεπεξεργασία δεδομένων

Η προεπεξεργασία των δεδομένων είναι απαραίτητη, καθώς τα αρχικά δεδομένα πάσχουν από διαφόρων ειδών προβλήματα. Σε αυτά συγκαταλέγονται η ύπαρξη αλληλοσυγκρουόμενων πληροφοριών, η ύπαρξη ασυνεπειών ως προς την κωδικοποίηση, την ονοματοδοσία πεδίων και τις μονάδες μέτρησης, καθώς και η ύπαρξη χαμένων τιμών και θορύβου, τυχαία δηλαδή κυμαινόμενων δεδομένων χωρίς ουσιαστικό περιεχόμενο. Τα προβληματικά αυτά δεδομένα καλούνται “ακάθαρτα” και η διαδικασία αντιμετώπισης των προβλημάτων τους καλείται “καθαρισμός δεδομένων”. Η προεπεξεργασία των δεδομένων περιλαμβάνει τον καθαρισμό τους, αλλά δεν περιορίζεται σε αυτόν. Ειδικές απαιτήσεις των μεθόδων επεξεργασίας συχνά επιβάλλουν τον μετασχηματισμό των δεδομένων. Δύο συνήθεις εργασίες μετασχηματισμού είναι η διακριτοποίηση και η κανονικοποίηση (standardization). Ο όρος διακριτοποίηση αναφέρεται στον μετασχηματισμό αριθμητικών τιμών σε ονομαστικές τιμές ή κατηγορικές μεταβλητές. Η κανονικοποίηση είναι η μετατροπή αριθμητικών τιμών σε άλλες, πιο “κατάλληλες”, αριθμητικές τιμές. Ένα επιπλέον θέμα που εμπίπτει στην προεπεξεργασία των δεδομένων είναι η μείωση του όγκου τους. Ειδική περίπτωση μείωσης των δεδομένων, με βαρύνουσα σημασία, είναι η

επιλογή σημαντικών χαρακτηριστικών, η επιλογή δηλαδή εκείνων των μεταβλητών ή πεδίων που είναι απαραίτητες για την εξόρυξη της γνώσης.

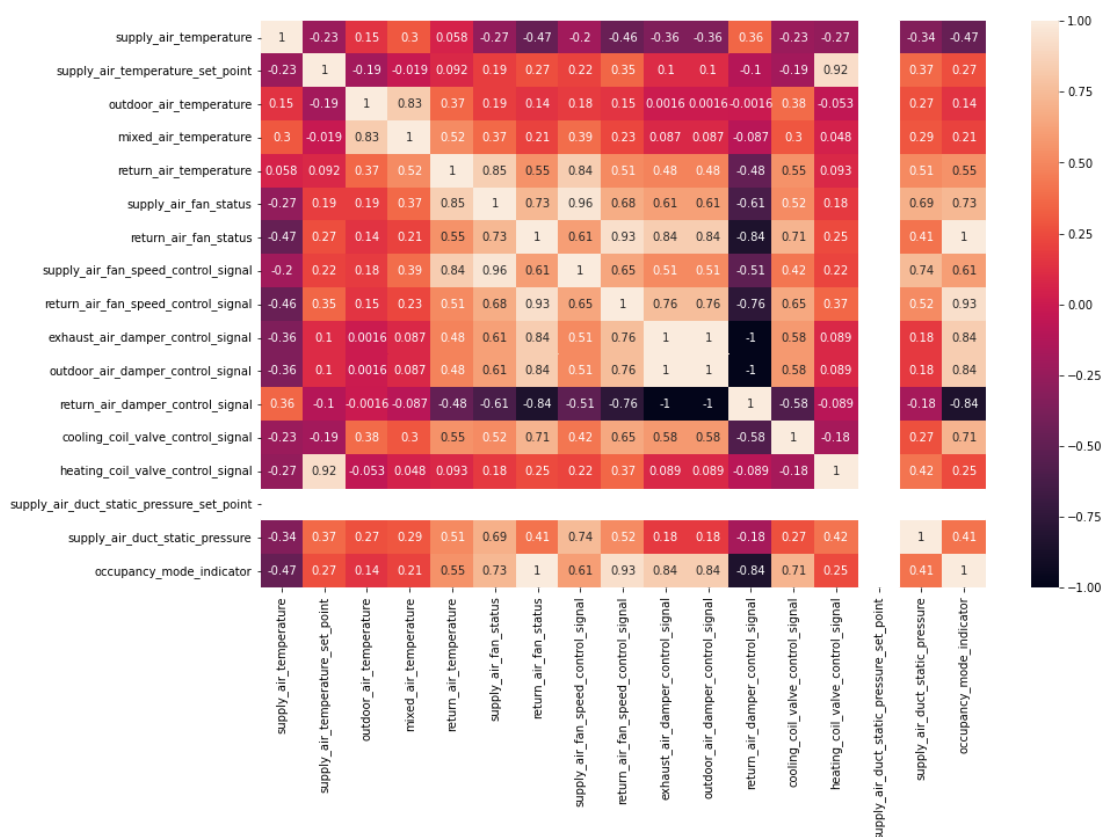
Η εργασία αυτή, επομένως και ο καθαρισμός των δεδομένων έγινε στη γλώσσα Python 3.6 στο περιβάλλον Google Colab. Για το σύνολο δεδομένων MZVAV-1 που χρησιμοποιήθηκε ως χρονοσειρά, υπάρχουν συνολικά 272160 μετρήσεις σε 17 χαρακτηριστικά. Αρχικά, η στήλη των χρονικών στιγμών της κάθε μέτρησης παραλείφθηκε και τέθηκε ως δείκτης αρίθμησης (index) κάθε ένδειξης. Στη συνέχεια, εξετάστηκε ο πίνακας συσχέτισης των 16 πρώτων χαρακτηριστικών με την τιμή αληθείας και διαπιστώθηκε ότι δύο στήλες του συνόλου δεδομένων που αφορούν τα setpoints θερμοκρασίας και πίεσης του παρεχόμενου αέρα, έχουν σχεδόν μηδενική συσχέτιση με την εξαρτημένη μεταβλητή, οπότε απορρίφθηκαν.

Για το δεύτερο σύνολο δεδομένων έγινε μια επεξεργασία των δεδομένων ώστε να αφαιρεθεί μία στήλη με στατιστικά μη σημαντικές τιμές (τυπική απόκλιση 0), και να συμπληρωθούν ορισμένες κενές τιμές με το μέσο όρο των γειτονικών τους (γραμμική παρεμβολή). Στην **εικόνα 28** φαίνεται το θηκόγραμμα (boxplot) για το σύνολο MZVAV-2-2, στο οποίο φαίνεται ότι υπάρχουν αρκετές έκτοπες τιμές (outliers) ειδικά στα χαρακτηριστικά με συνεχείς κατανομές. Στις περισσότερες περιπτώσεις είναι απλώς θερμοκρασιακές τιμές οι οποίες είναι λογικό να υπάρχουν, όπως για παράδειγμα σε μια πολύ ζεστή ή κρύα ημέρα, οπότε οι τιμές αυτές κρατήθηκαν.



**Εικόνα 28:** Το θηκόγραμμα του συνόλου.

Ο πίνακας συσχέτισης της **εικόνας 29** δίνει μια αίσθηση του ποιες μεταβλητές θα παίξουν μεγαλύτερο ρόλο στο στάδιο της εκπαίδευσης. Όσο πιο κοντά στο 1 είναι η τιμή, τόσο μεγαλύτερη θετική συσχέτιση έχουν δύο χαρακτηριστικά, και αντιστρόφως.



Εικόνα 29: Πίνακας συσχέτισης

## 4.2.2 Εκπαίδευση μοντέλων

Επόμενο στάδιο στη διαδικασία του πειράματος ήταν η χρήση των δεδομένων για την εκπαίδευση των τεσσάρων αλγορίθμων που αναλύθηκαν στις προηγούμενες ενότητες. Στη συνέχεια παρατίθενται οι ιδιαιτερότητες και τα χαρακτηριστικά της υλοποίησης καθενός από τα υπόψη μοντέλα.

### 4.2.2.1 Μοντέλα για το σύνολο δεδομένων MZVAV-2-2

Το σύνολο δεδομένων στο οποίο εφαρμόστηκαν οι πρώτες μέθοδοι, είναι μια τεχνητή βάση δεδομένων και παρουσιάζει πολύ ισορροπημένα δεδομένα αληθείας. Ωστόσο, τα δεδομένα της στήλης με τις τιμές αληθείας περιέχουν αρνητικά δείγματα μέχρι τη μέση της χρονικής περιόδου μετρήσεων και θετικά στην υπόλοιπη. Προκειμένου η εκπαίδευση να είναι επιτυχής και να μην μάθει το μοντέλο απλώς να αντιγράφει επαναλαμβανόμενες τιμές, οι καταγεγραμμένες μετρήσεις χωρίστηκαν με τυχαίο τρόπο με τη μέθοδο `train_test_split` της βιβλιοθήκης `scikit-learn`. Το σύνολο

των μετρήσεων αυτών διαχωρίστηκε σε σετ εκπαίδευσης και σετ ελέγχου, με αναλογία 70-30% που είναι αρκετά καθιερωμένη για ισορροπημένα δεδομένα.

Αρχικά δοκιμάστηκε η KNN, που λειτουργεί ως εξής: Στην ταξινόμηση K-κοντινότερων γειτόνων, η συνάρτηση προσεγγίζεται τοπικά μόνο, και οι υπολογισμοί γίνονται κατά την επαλήθευση (validation). Σαν μετρική χρησιμοποιήθηκε η απόσταση Minkowski, και για την αύξηση της ακρίβειας του αλγόριθμου έγινε κανονικοποίηση των δεδομένων, κάτι που συνίσταται όταν η ταξινόμηση βασίζεται σε μετρικές απόστασης. Η έξοδος κάθε δείγματος είναι μέλος μιας κλάσης. Έπειτα η ταξινόμηση γίνεται με μια ψηφοφορία όπου το δείγμα ανατίθεται στην κλάση που είναι πιο συχνή στα κοντινότερα γειτονικά σημεία. Για να αποφευχθεί η υπερεκπαίδευση, επιλέχθηκε σαν παράμετρος οι 10 γείτονες, καθώς έδειξε καλύτερη επίδοση από χαμηλότερες τιμές.

Στη συνέχεια πάλι με τη χρήση της βιβλιοθήκης scikit-learn, τα ίδια δεδομένα εκπαιδεύτηκαν με ένα μοντέλο τυχαίου δάσους (Random Forest, RF). Κάθε δέντρο ξεκινά από τη ρίζα του, που περιλαμβάνει το σύνολο των σημείων των δεδομένων εκπαίδευσης. Έπειτα, μέσω δυαδικής διαίρεσης και ξεκινώντας από την κορυφή του, χωρίζεται διαδοχικά ο αριθμός των παρατηρήσεων σε επιμέρους χώρους με βάση το κατάλληλο κριτήριο διάσπασης. Το βέλτιστο σημείο διαχωρισμού σε κάθε κόμβο είναι αποτέλεσμα της ελαχιστοποίησης του μέσου τετραγωνικού σφάλματος. Το μοντέλο που προκύπτει είναι σε θέση να αντιστοιχίσει κάθε νέα παρατήρηση με μια πρόβλεψη του αν πρόκειται για κανονική ή εσφαλμένη λειτουργία.

Στα πλαίσια βελτιστοποίησης της αποτελεσματικότητας του μοντέλου χρειάστηκε η ρύθμιση ορισμένων παραμέτρων. Αρχικά ελέγχθηκαν διάφορες τιμές της παραμέτρου “ελάχιστα δείγματα διαχωρισμού” (min samples split), η οποία αφορά τον ελάχιστο αριθμό παρατηρήσεων που απαιτείται για το διαχωρισμό ενός εσωτερικού κόμβου. Συγκεκριμένα, δοκιμάστηκαν για την παράμετρο τιμές στο εύρος (10-20), μέσω μιας επαναληπτικής διαδικασίας (for loop). Για κάθε τιμή της παραμέτρου πραγματοποιήθηκε υπολογισμός του Μέσου Τετραγωνικού Σφάλματος των προβλέψεων στα δεδομένα επαλήθευσης (validation set) και επιλέχθηκε η τιμή με το ελάχιστο σφάλμα. Επιπλέον, για λόγους αποφυγής πολυπλοκότητας και υπερπροσαρμογής του μοντέλου, ορίστηκε η παράμετρος ‘μέγιστο βάθος’ (max depth) του δέντρου ίση με 5, η οποία περιγράφει το μήκος της μέγιστης διαδρομής από τη ρίζα στα φύλλα του δέντρου.

Η τρίτη μεθοδολογία που εφαρμόστηκε, είναι η Gradient Boosting (GB) ή προώθηση κλίσης. Για την εκπαίδευση χρησιμοποιήθηκε αριθμός εκτιμητών ( $n_{\text{estimators}}$ ) ίσος με 100. Ο ρυθμός εκμάθησης τέθηκε σε 0.2, ώστε να γίνει αποφυγή υπερπροσαρμογής αν το μοντέλο μάθαινε με πιο γοργό ρυθμό. Το όνομα της τεχνικής προέρχεται από δύο μεθόδους, τον αλγόριθμο Gradient Descent (στοχαστική κάθοδος κλίσης) και την τεχνική Boosting. Η Gradient Descent αποτελεί μία μέθοδο βελτιστοποίησης πρώτης τάξης. Για να βρει κάποιος το ολικό ελάχιστο μιας

συνάρτησης χρησιμοποιώντας τη συγκεκριμένη τεχνική, αρχικά υπολογίζει την παράγωγο της και κάνει ανάποδα βήματα από την κατεύθυνση της παραγώγου. Η παράγωγος μετράει κατά πόσο θα αλλάξει η τιμή μίας συνάρτησης  $J(\theta)$  εάν μεταβληθεί ελάχιστα η μεταβλητή  $\theta$ . Ουσιαστικά είναι η κλίση της συνάρτησης, υψηλές τιμές της συνάρτησης υποδηλώνουν μεγάλη κλίση άρα και μεγάλη μεταβολή στην τιμή της  $J(\theta)$  για μικρές μεταβολές του  $\theta$ .

Μία τέταρτη μέθοδος στατιστικής μηχανικής μάθησης που αξιοποιείται συχνά είναι οι μηχανές διανυσμάτων στήριξης (SVM). Αποτελούν γενίκευση των ταξινομητών διανυσμάτων στήριξης (SVC), και μπορούν να χρησιμοποιηθούν ακόμη κι αν τα δεδομένα δεν είναι γραμμικά διαχωρίσιμα στο υπερεπίπεδο που ανήκουν. Ο ταξινομητής δημιουργεί κλάσεις ανάλογα με τα πιθανά αποτελέσματα και για κάθε δείγμα βγαίνει ένα ποσοστό σε κάθε κλάση και επιλέγεται αυτό με την μεγαλύτερη πιθανότητα. Στην περίπτωση των SVM η επιλογή γίνεται με βάση την απόσταση από το υπερεπίπεδο που ορίζει ο κάθε επιμέρους ταξινομητής. Στις SVM διατίθενται ως υπερπαραμέτροι ένα πλήθος συναρτήσεων πυρήνα (kernel functions). Εδώ χρησιμοποιήθηκε ο πυρήνας Radial Basis Kernel (rbf), ο οποίος χρησιμοποιείται συχνά στη μηχανική μάθηση για την εύρεση μή-γραμμικών ταξινομητών.

Αυτά ως προς τις στατιστικές μεθοδολογίες που δοκιμάστηκαν. Στη συνέχεια, δοκιμάστηκε ένα μοντέλο deep learning με 3 επίπεδα (layers). Το μοντέλο περιέχει 3 κρυφά στρώματα στα οποία εισάγονται ως είσοδοι οι έξοδοι του προηγούμενου στρώματος:

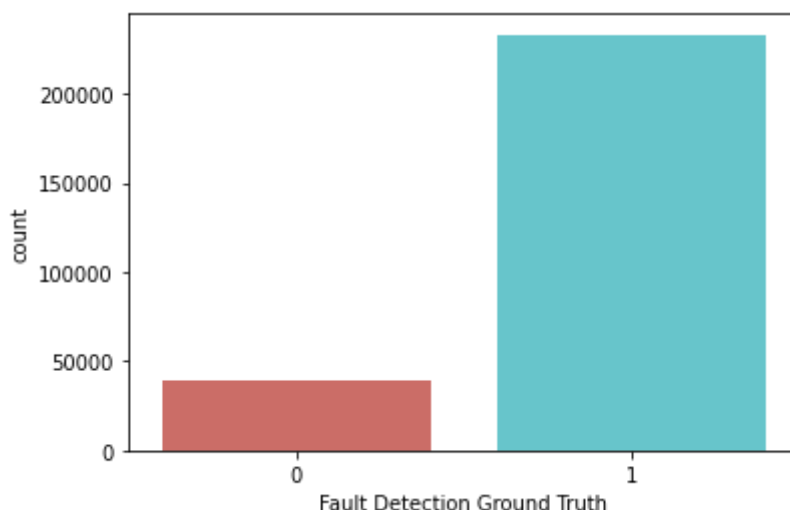
- Ένα στρώμα εισόδου με τα 15 χαρακτηριστικά.
- Πρώτο κρυμμένο στρώμα, με 128 νευρώνες και 64 εξόδους.
- Δεύτερο κρυμμένο στρώμα, με 64 νευρώνες και 32 εξόδους.
- Τρίτο κρυμμένο στρώμα, με 32 νευρώνες και 16 εξόδους.
- Τελευταίο στρώμα με 16 εισόδους και 2 εξόδους που συνδυάζονται σε μία έξοδο.

Ανάμεσα στα layers χρησιμοποιείται ως συνάρτηση ενεργοποίησης η ReLu (Rectified Linear Unit), η οποία κυριαρχεί στα βαθιά νευρωνικά δίκτυα. Ως κριτήριο υπολογισμού απωλειών επιλέγεται το Cross\_Entropy, το οποίο ενδείκνυται για εφαρμογές ταξινόμησης με δύο κλάσεις, όπως η ανίχνευση σφαλμάτων. Επίσης ως βελτιστοποιητής χρησιμοποιείται η στοχαστική κάθοδος κλίσης, η οποία σε κάθε επανάληψη του βρόχου ελαχιστοποιεί το σφάλμα στις εξόδους των νευρώνων (backpropagation). Επίσης πριν την τροφοδότηση του νευρωνικού δικτύου με δεδομένα, είναι απαραίτητο να κανονικοποιηθούν ώστε οι τιμές κάθε χαρακτηριστικού να έχουν μέση τιμή 0 και διακύμανση 1. Αφού στη συνέχεια μετατραπούν σε ταυσιές (tensors), ο αλγόριθμος επαναλαμβάνεται σε ένα loop για 2000 εποχές και εμφανίζει τη γραφική παράσταση της εξέλιξης του σφάλματος στο πέρασμα του χρόνου. Για την υλοποίηση αυτού του νευρωνικού δικτύου δοκιμάστηκε η βιβλιοθήκη Torch.

#### 4.2.2.2 Μοντέλο για το σύνολο δεδομένων MZVAV-1

Η τελευταία μέθοδος, που θα αναφερθεί στη συνέχεια, πραγματοποιήθηκε με τη βιβλιοθήκη Keras που ανήκει στη συλλογή του TensorFlow. Έτσι υπήρξε μια πρώτη επαφή και με τις δύο αυτές κυρίαρχες βιβλιοθήκες για νευρωνικά δίκτυα. Η βιβλιοθήκη Keras παρέχει τη δυνατότητα κατασκευής ενός νευρωνικού δικτύου με τρόπο εύκολο και διαισθητικό. Για τον ορισμό των επιπέδων του δικτύου υπάρχει η γραμμική κλάση (sequential class) και η συναρτησιακή (functional class). Στη γραμμική κλάση, όλα τα στρώματα (layers) ορίζονται ως αντικείμενα τα οποία ομαδοποιούνται σειριακά σε μια στοίβα, ενώ η συναρτησιακή κλάση χρησιμοποιείται για μοντέλα μη γραμμικής τοπολογίας. Στην παρούσα εργασία χρησιμοποιήθηκε η πιο απλή γραμμική κλάση, καθώς καλύπτει τις απαιτήσεις του μοντέλου που χρησιμοποιήθηκε.

Το σύνολο δεδομένων που χρησιμοποιήθηκε εδώ, δεν είναι καθόλου ισορροπημένο, κάτι το οποίο είναι αναμενόμενο σε πραγματικές συνθήκες, καθώς ένα σύστημα HVAC μπορεί να παρουσιάζει μια βλάβη η οποία δεν έχει γίνει αντιληπτή ενώ συνεχίζει να λειτουργεί. Κάτι τέτοιο θα δημιουργούσε μεγάλη ετερογένεια στα δεδομένα και συγκεκριμένα στη στήλη που αντιπροσωπεύει το αν υπάρχει σφάλμα ή όχι. Στην **εικόνα 28** φαίνεται πόσο μεγάλη διαφορά υπάρχει ανάμεσα στα δείγματα με σφάλμα και τα δείγματα με ομαλή λειτουργία.



**Εικόνα 30:** Το σύστημα στο μεγαλύτερο μέρος του λειτουργεί με σφάλμα.

Τα παραδείγματα αλγορίθμων που δοκιμάστηκαν στην προηγούμενη ενότητα, βγάζουν απαράδεκτα αποτελέσματα για αυτό το σύνολο δεδομένων, κάτι που είναι αναμενόμενο. Για το σκοπό αυτό, τα δεδομένα αυτή τη φορά αντιμετωπίστηκαν ως χρονοσειρά, όπου κάθε δείγμα συνδέεται χρονικά με τα προηγούμενα. Θεωρώντας ότι κάθε ένα σημείο είναι σημείο μιας χρονοσειράς επιλέχθηκε η χρήση LSTM για ταξινόμηση ακολουθιών. Τα βαθιά δίκτυα LSTM είναι δημοφιλής επιλογή όταν πρόκειται για χρονοσειρές ή γενικά δεδομένα με εγγενή ακολουθιακή πληροφορία.



Ακόμη, επειδή αυτός ο τύπος δικτύου τείνει να απαιτεί μεγάλο αριθμό δεδομένων, το σύνολο μετρήσεων MZVAV-1 είναι κατάλληλο. Ο νευρώνας LSTM περιλαμβάνει και ένα βρόχο ανάδρασης και μπορεί να θυμάται επιλεκτικά κάποιες καταστάσεις σε δεδομένα χρονοσειρών, ώστε να προβλέψει την επόμενη χρονικά τιμή. Αυτό βρίσκει πολλές εφαρμογές σε συστήματα ενέργειας όπως για παράδειγμα για να προβλέπεται η κατανάλωση ενέργειας σε ένα σπίτι ή για μη-παρεμβατική παρακολούθηση φορτίου (NILM).

Για την εφαρμογή του έγινε χρήση παραθύρου ίσου με 1, ώστε αυτό το κυλιόμενο παράθυρο να προβλέπει τί θα συμβεί τη χρονική στιγμή  $t$ , γνωρίζοντας τις τιμές των μεταβλητών την προηγούμενη χρονική στιγμή  $t-1$ . Το σύνολο δεδομένων χωρίστηκε σε σύνολα εκπαίδευσης και ελέγχου. Η εκπαίδευση έγινε σε 201601 δείγματα ενώ ο έλεγχος στα υπόλοιπα 70558. Επιλέχθηκαν αυτές οι τιμές γιατί τα δείγματα με λειτουργία χωρίς σφάλμα είναι λίγα. Με την επιλογή αυτή, που έγινε εμπειρικά με βάση το πως κατανέμονται οι τιμές χωρίς σφάλμα και με σφάλμα, καταφέρθηκε ο διαχωρισμός σε δύο ικανοποιητικά υποσύνολα εκπαίδευσης και ελέγχου (train test sets).

Στη συνέχεια με τον κατάλληλο κώδικα τα δεδομένα κανονικοποιήθηκαν. Έχει παρατηρηθεί ότι τα νευρωνικά δίκτυα μαθαίνουν πιο αποδοτικά όταν εκπαιδεύονται σε δεδομένα που έχουν μετασχηματιστεί με τέτοιο τρόπο ώστε να διαθέτουν ιδιότητες κανονικής κατανομής, δηλαδή μηδενική μέση τιμή και τυπική απόκλιση ίση με τη μονάδα (Kelly & Knottenbelt, 2015). Επομένως, πριν ξεκινήσει η εκπαίδευση του δικτύου πραγματοποιήθηκε προσαρμογή των δεδομένων σε κατάλληλη μορφή σύμφωνα με την παρακάτω σχέση:

$$x_{new} = \frac{x - x_{mean}}{\sigma_x}$$

Η μορφοποίηση των δεδομένων κατά αυτό τον τρόπο ονομάζεται τυποποίηση (standardization) και εφαρμόζεται αφαιρώντας από κάθε δείγμα, τον μέσο όρο της ακολουθίας δεδομένων και έπειτα διαιρώντας το αποτέλεσμα με τη τυπική απόκλιση  $\sigma_x$ .

Από τα παραπάνω προέκυψε μία νέα στήλη η οποία δείχνει αν υπάρχει σφάλμα τη χρονική στιγμή  $t$ . Η μεταβλητή αυτή είναι ο νέος στόχος, ενώ οι υπόλοιπες στήλες αναφέρονται στην προηγούμενη χρονική στιγμή. Στη συνέχεια, τα σύνολα εκπαίδευσης και ελέγχου χωρίστηκαν με τρόπο ώστε η στήλη της χρονικής στιγμής  $t$  να είναι η έξοδος του δικτύου, και οι υπόλοιπες στήλες να είναι είσοδοι του LSTM. Έπειτα, δόθηκε άλλο σχήμα στα νέα σύνολα (reshape) κάτι το οποίο είναι απαραίτητο βήμα, καθώς τα LSTM αναμένουν στην είσοδό του πρώτου νευρώνα 3-διάστατη μορφή δεδομένων. Τέλος, άλλη μία απαίτηση του μοντέλου LSTM στη βιβλιοθήκη Keras είναι οι ταμπέλες εξόδου να είναι σε κωδικοποίηση one-hot.

Η αρχιτεκτονική του νευρωνικού δικτύου που χρησιμοποιήθηκε αποτελεί έναν συνδυασμό συνεκτικών και αμφίδρομων LSTM επιπέδων, Στον **Πίνακα 1** συνοψίζονται οι τεχνικές λεπτομέρειες του δικτύου που υλοποιήθηκε.

**Πίνακας 1:** Αρχιτεκτονική του μοντέλου LSTM που εφαρμόστηκε.

Τύπος στρώματος (layer type)	Υπερπαράμετροι στρώματος (hyperparameters)
Input Layer	Shape (None,1,16)
Bidirectional LSTM	Size: 14, Return_sequences = True
Bidirectional LSTM	Size: 7, Return_sequences = True
Bidirectional LSTM	Size: 3, Activation = Tanh
Dense Layer	Nb_classes = 2, Activation = sigmoid

Στο πρώτο στρώμα εισάγονται κάθε φορά τα 16 χαρακτηριστικά εισόδου που υπολογίστηκαν παραπάνω σε ένα κυλιόμενο παράθυρο μήκους 1. Αυτό σημαίνει ότι το μοντέλο επεξεργάζεται τα δεδομένα του προηγούμενου βήματος, λαμβάνοντας υπόψη το ιστορικό που είχε το σύστημα πριν. Μπορούν να δοκιμαστούν κυλιόμενα παράθυρα και μεγαλύτερου μήκους, τα οποία θα “αντιλαμβάνονται” ακόμη παλαιότερες τιμές, αλλά για λόγους υπολογισμού και καθώς το μοντέλο αυτό είχε ικανοποιητικά αποτελέσματα, κάτι τέτοιο δεν εφαρμόστηκε.

Στη συνέχεια ακολουθούν 3 στρώματα LSTM, με 14, 7 και 3 νευρώνες αντίστοιχα, προκειμένου, να αξιοποιηθούν παρελθοντικές αλλά και μελλοντικές τιμές. Ως συνάρτηση ενεργοποίησης χρησιμοποιήθηκε η tanh, και επίσης στα δύο πρώτα στρώματα απαιτήθηκε η παράμετρος return\_sequences να είναι True, ώστε η επόμενη στρώση να λαμβάνει έναν 3D πίνακα. Στο τέλος ακολουθεί ένα fully connected ή Dense στρώμα όπου η συνάρτηση ενεργοποίησης ορίζεται η sigmoid, καθώς οι τιμές σφάλματος ή ομαλής λειτουργίας είναι 0 ή 1. Από τα στρώματα αυτά παράγεται τελικά η ζητούμενη έξοδος, που είναι η πρόβλεψη σχετικά με την ύπαρξη σφάλματος στη μονάδα AHU μεταβλητού όγκου αέρα (VAV) τη δεδομένη χρονική στιγμή.

Το στάδιο της εκπαίδευσης ενός νευρωνικού δικτύου αποτελεί μια επαναλαμβανόμενη διαδικασία στην οποία αναλύονται τα δεδομένα εκπαίδευσης αρκετές φορές προκειμένου να βελτιστοποιηθούν κάποιες εσωτερικές παράμετροι του δικτύου, όπως για παράδειγμα τα βάρη των νευρώνων. Οι παράμετροι που επιλέχθηκαν για την υλοποίηση αυτού του σταδίου φαίνονται στον **Πίνακα 2**.

Η υπερπαράμετρος epoch αφορά το πλήθος των επαναλήψεων όπου τα δεδομένα εκπαίδευσης θα τροφοδοτηθούν στο σύνολο τους στο δίκτυο, ενώ αποτελείται από

μια ή περισσότερες παρτίδες (batches). Το μέγεθος της παρτίδας (batch size) καθορίζει τον αριθμό των παρατηρήσεων (διανυσμάτων εισόδου) που θα αναλυθούν πριν ανανεωθούν οι εσωτερικοί παράμετροι του δικτύου. Επόμενο βήμα ήταν η επιλογή της συνάρτησης κόστους, με την οποία αξιολογείται η αποτελεσματικότητα του μοντέλου. Η συνάρτηση που επιλέχθηκε, ήταν το Κριτήριο Εντροπίας (categorical\_crossentropy), το οποίο είναι σύμφωνα με τη βιβλιογραφία η κατάλληλη συνάρτηση κόστους σε προβλήματα ταξινόμησης ανάμεσα σε δύο τιμές (binary classification). Η συνάρτηση σφάλματος categorical\_crossentropy υπολογίζει το σφάλμα ενός στιγμιότυπου υπολογίζοντας σε κάθε επανάληψη το άθροισμα:

$$Loss = - \sum_{i=1}^{output\ size} y_i \cdot \log \hat{y}_i \quad (1)$$

,όπου  $\hat{y}_i$  είναι η αριθμητική τιμή του i-οστού στοιχείου εξόδου,  $y_i$  η μεταβλητή στόχου και *output size* ο αριθμός των στοιχείων στην έξοδο. Αυτή η συνάρτηση κόστους είναι ένα πολύ καλό μέτρο του πόσο ξεχωρίζουν μεταξύ τους δύο διακριτές κατανομές πιθανοτήτων.

**Πίνακας 2:** Υπερπαράμετροι εκπαίδευσης LSTM

Υπερπαράμετροι Εκπαίδευσης	Επιλεγόμενη Τιμή
Epoch	250
Batch Size	40
Loss Function	Categorical_crossentropy
Optimizer	Adaptive Moment Estimation (Adam)
Validation Split	0.0

Ως αλγόριθμος βελτιστοποίησης (Optimizer) των βαρών των νευρώνων, με στόχο τη μείωση του σφάλματος categorical\_crossentropy, χρησιμοποιήθηκε ο αλγόριθμος Adaptive Moment Estimation (Adam). Τέλος, να σημειωθεί ότι το σύνολο εκπαίδευσης δε διαχωρίστηκε περαιτέρω και σε σύνολο επικύρωσης για μικρο-ρύθμιση των υπερπαραμέτρων, λόγω της κατανομής τιμών αληθείας της χρονοσειράς. Αυτό γίνεται θέτοντας την παράμετρο Validation Split ίση με 0.

### 4.2.3 Μετρικές αξιολόγησης

Το σύστημα που σχεδιάστηκε θα πρέπει να είναι σε θέση να υπολογίζει σωστά αν το σύστημα παρουσιάζει κάποια δυσλειτουργία ώστε να επιθεωρηθεί από τους ειδικούς. Για το λόγο αυτό πρέπει σε πρώτοι φάση οι αλγόριθμοι τέτοιου τύπου να αξιολογούν τα εκτιμηθέντα αποτελέσματα σε σχέση με τις πραγματικές τιμές.

Επομένως είναι απαραίτητη η χρήση κατάλληλων μετρικών που μπορούν να μας δώσουν την ακρίβεια των συμβάντων του συστήματος (event detection). Αυτό γίνεται, χρησιμοποιώντας ανάλογους δείκτες (classification metrics). Στο πλαίσιο αυτό ορίζονται οι παρακάτω παράμετροι :

- True Positives (TP): Ο αριθμός ορθών εκτιμήσεων λειτουργίας Faulty ενός στοιχείου που είναι όντως Faulty (συμβαίνει σφάλμα).
- False Positives (FP): Ο αριθμός εσφαλμένων εκτιμήσεων λειτουργίας Faulty ενός στοιχείου, που είναι στην πραγματικότητα Normal.
- True Negatives (TN): Ο αριθμός ορθών εκτιμήσεων λειτουργίας Normal ενός στοιχείου που είναι όντως Normal.
- False Negatives (FN): Ο αριθμός ορθών εκτιμήσεων λειτουργίας Normal ενός στοιχείου που είναι όντως Normal.
- Positives (P): Ο αριθμός των δειγμάτων που το σύστημα είναι σε κατάσταση Faulty.
- Negatives (N): Ο αριθμός των δειγμάτων που είναι σε κατάσταση Normal.

Έτσι με βάση αυτούς τους ορισμούς ορίζονται οι παρακάτω δείκτες:

$$1. \text{ Accuracy} = \frac{TP+TN}{P+N}$$

$$2. \text{ Precision} = \frac{TP}{TP+FP}$$

$$3. \text{ Recall} = \frac{TP}{TP+FN}$$

$$4. F_1 \text{ score} = \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Ο δείκτης Ακρίβειας (Accuracy) στην ουσία μετρά το ποσοστό των σωστών εκτιμήσεων για την κατάσταση λειτουργίας του συστήματος σε σχέση με το σύνολο όλων των διαθέσιμων δειγμάτων. Το αποτέλεσμα του δείκτη αυτού πρέπει να ερμηνεύεται με προσοχή ιδιαίτερα όταν τα δεδομένα δεν είναι ισορροπημένα όπως εδώ. Θα μπορούσε για παράδειγμα το μοντέλο να προβλέπει συνέχεια την τιμή 1 (Faulty) που είναι και η πιο συχνή σε αυτό το dataset. Θα φαινόταν ότι έχει πολύ καλή απόδοση, αλλά θα έδειχνε συνεχώς ότι το σύστημα έχει κάποιο σφάλμα, ακόμη κι αν αυτό λειτουργούσε φυσιολογικά. Για το λόγο αυτό, πρέπει να εξετάσουμε όλες τις μετρικές.

Ο δείκτης ακρίβειας θετικότητας (Precision – positive predictive value) δηλώνει το πόσες φορές ο αλγόριθμος έκρινε σωστά ότι, σε σχέση με το σύνολο των θετικών εκτιμήσεων (ορθών και εσφαλμένων), ενώ ο δείκτης ευαισθησίας (Recall – sensitivity) φανερώνει το ποσοστό των πραγματικών ενεργοποιήσεων που κατάφερε να βρει ο αλγόριθμος. Τέλος ο δείκτης F1 αποτελεί τον αρμονικό μέσο όρο των δύο παραπάνω μετρικών και η ανώτερη τιμή που μπορεί να έχει είναι 1, φανερώνοντας τέλεια ακρίβεια των δεικτών Precision και Recall.

Σε εφαρμογές δυαδικής ταξινόμησης η καμπύλη ROC (Receiver Operating Characteristic), είναι μία γραφική παράσταση που απεικονίζει την ικανότητα ταξινόμησης ενός μοντέλου. Η καμπύλη ROC δημιουργείται σχεδιάζοντας το ποσοστό TP (True Positive Rate, TPR) ως προς το ποσοστό FP (False Positive Rate, FPR). Το TPR αναφέρεται και ως ευαισθησία, ή πιθανότητα ανίχνευσης. Το FPR είναι γνωστό ως πιθανότητα εσφαλμένου συναγερμού.

## Κεφάλαιο 5. Ανάλυση αποτελεσμάτων

Σε αυτό το κεφάλαιο παρατίθενται τα αποτελέσματα των μεθόδων που εφαρμόστηκαν παραπάνω, μαζί με τις παρατηρήσεις που προέκυψαν για κάθε μοντέλο, και γίνεται προσπάθεια σύγκρισης των αποτελεσμάτων αυτών.


### 5.1 Αποτελέσματα για το σύνολο δεδομένων MZVAV-2-2

Σε πρώτη φάση, καταγράφεται στους παρακάτω πίνακες η αναφορά ταξινόμησης (classification report) για τις μεθόδους KNN, Random Forest, Gradient Boost, SVM, και Deep Neural Network. Επίσης για κάθε μέθοδο παρατίθεται και ο πίνακας σύγχυσης (confusion matrix) ο οποίος δείχνει τί πραγματικά συμβαίνει στη φάση ελέγχου, όταν ο αλγόριθμος καλείται να ταξινομήσει νέα, άγνωστα δεδομένα.

Η μέθοδος των κοντινότερων γειτόνων πέτυχε πολύ καλά αποτελέσματα, χωρίς να υπάρχει κάποια ένδειξη υπερπροσαρμογής ή υπερεκπαίδευσης στο σύνολο δεδομένων. Η μέθοδος φαίνεται ότι αποδίδει πολύ καλά όταν τα δεδομένα είναι ισορροπημένα, αν όμως υπήρχε μεγάλη ετερογένεια, όπως στο σύνολο δεδομένων MZVAV-2-2, τα δεδομένα της μίας κλάσης θα ήταν πολύ αραιά ώστε να ταξινομηθούν σωστά. Στον **πίνακα 3** φαίνονται οι μετρικές για το μοντέλο αυτό. Η **εικόνα 31** δείχνει πιο “πρακτικά” το πως τα πήγε το μοντέλο.

**Πίνακας 3:** Αναφορά ταξινόμησης για τη μέθοδο K-Nearest Neighbours (KNN)

Label	Precision	Recall	F1-score	Accuracy
0	0.91	0.97	0.94	0.94
1	0.97	0.91	0.94	

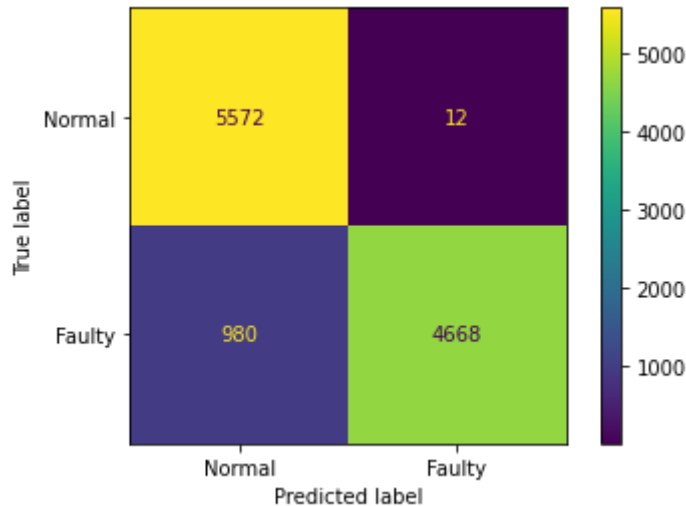


**Εικόνα 31:** Πίνακας σύγχυσης μεθόδου KNN

Η επόμενη μέθοδος που δοκιμάστηκε σύνολο δεδομένων MZVAV-2-2 ήταν η μέθοδος τυχαίου δάσους. Σε αυτήν επιτεύχθηκαν καλά αποτελέσματα, ωστόσο εμφανίστηκαν τιμές ανάκλησης και ακρίβειας θετικότητας ίσες με ένα, όπως δείχνει ο **πίνακας 4**. Όταν η ανάκληση είναι 1, αυτό σημαίνει ότι οι προβλέψεις δεν παράγουν False Negative (FN) τιμές. Αν και αυτό φαίνεται καλό εκ πρώτης όψεως, χρειάζεται προσοχή γενικά, καθώς αποτελεί ένδειξη υπερπροσαρμογής (overfitting) στο σύνολο δεδομένων. Αυτό διακρίνεται και από τον πίνακα σύγχυσης (**εικόνα 32**), όπου παρατηρείται ότι το μοντέλο αδυνατεί να προβλέψει αρκετές περιπτώσεις στις οποίες συμβαίνει σφάλμα. Έτσι μπορεί κάποια σφάλματα να περάσουν απαρατήρητα για κάποιο χρονικό διάστημα μέχρι να εντοπιστούν.

**Πίνακας 4:** Αναφορά ταξινόμησης για τη μέθοδο Random Forest (RF)

Label	Precision	Recall	F1-score	Accuracy
0	0.85	1.00	0.92	0.91
1	1.00	0.82	0.90	




**Εικόνα 32:** Πίνακας σύγχυσης μεθόδου RF

Η επόμενη δοκιμή έγινε με τη βοήθεια της μεθόδου GB. Η αναφορά ταξινόμησης της GB στον **πίνακα 5** δείχνει καθαρά πως πρόκειται για την πιο αποδοτική μέθοδο από όσες δοκιμάστηκαν στο πρώτο σύνολο δεδομένων. Η μέθοδος αυτή ήταν αρκετά

γρήγορη στην εκτέλεση, και επιπλέον πέτυχε απόδοση 96%, καλύτερη από τα υπόλοιπα μοντέλα. Ο πίνακας σύγχυσης (εικόνα 33), αποδεικνύει ότι το μοντέλο έχει τη δυνατότητα να εντοπίζει πολύ καλά σε ποιες περιπτώσεις συμβαίνει σφάλμα.

**Πίνακας 5:** Αναφορά ταξινόμησης για τη μέθοδο Gradient Boost (GB)

Label	Precision	Recall	F1-score	Accuracy
0	0.94	0.98	0.96	0.96
1	0.98	0.93	0.95	



**Εικόνα 33:** Πίνακας σύγχυσης μεθόδου Gradient Boost


Το μοντέλο SVM που εξετάστηκε έπειτα ήταν το πιο αργό για εκπαίδευση και εμφάνισε ακρίβεια 94%, όπως φαίνεται στον **πίνακα 6**. Παρόλο που η μέθοδος με τα διανύσματα στήριξης είναι πολύ ισχυρή σε προβλήματα ταξινόμησης μη γραμμικής φύσης, εδώ τα πήγε λίγο χειρότερα από την Gradient Boosting, καθώς οι τεχνικές που εφαρμόζουν γενικά boosting είναι πάρα πολύ ισχυρές. Επίσης, σημειώνεται ότι οι SVM εκπαιδεύονται αρκετά αργά, κάτι που παρατηρήθηκε και κατά την εκτέλεση των δοκιμών αυτών, σε σχέση με τα υπόλοιπα μοντέλα (πλην όσων χρησιμοποιούν νευρωνικό δίκτυο).

Το μοντέλο δεν τα πηγαίνει άσχημα στα νέα, άγνωστα δεδομένα (**εικόνα 34**), και μάλιστα υπάρχει ομοιότητα στο ποσοστό λάθος προβλέψεων και για τις δύο κατηγορίες, αλλά αυτό στην πράξη εξαρτάται από τις απαιτήσεις του συστήματος. Ίσως το να παράγονται ψευδείς ειδοποιήσεις για την παρουσία σφάλματος πιο συχνά, να μην είναι κάτι το επιθυμητό.



**Πίνακας 6:** Αναφορά ταξινόμησης για τη μέθοδο Support Vector Machine (SVM)


Label	Precision	Recall	F1-score	Accuracy
0	0.94	0.94	0.94	0.94
1	0.94	0.94	0.94	



**Εικόνα 34:** Πίνακας σύγκρισης μεθόδου SVM

Τελευταίο για το πρώτο πείραμα δοκιμάστηκε ένα νευρωνικό δίκτυο τύπου βαθιάς μάθησης. Το μοντέλο με χρήση 3 κρυφών στρωμάτων νευρώνων για βαθιά μάθηση εμφάνισε απόδοση 93.7% (**πίνακας 7**). Το μοντέλο φαίνεται να τα πηγαίνει πολύ καλά σε μελλοντικά δεδομένα. Παρατηρείται ότι τα false positives είναι μόλις 8 που σημαίνει ότι έχουμε πετύχει το να μην υπάρχει false alarm για κάποιο σφάλμα, λύνοντας το πρόβλημα που τέθηκε στην προηγούμενη παράγραφο. Από την άλλη ίσως κάποια σφάλματα να περάσουν απαρατήρητα στο μέλλον (**εικόνα 36**). Αυτό δεν είναι απόλυτα κακό, μιας και η φύση των σφαλμάτων στον εξοπλισμό HVAC είναι επίμονη (persistent faults), που σημαίνει ότι σύντομα θα εντοπιστούν από το σύστημα.


Μετά το πέρας της εκπαίδευσης σχεδιάστηκε η μεταβολή του σφάλματος μετά το πέρας κάθε εποχής για το σύνολο των δεδομένων εκπαίδευσης. Αυτή η αναπαράσταση (**εικόνα 35**) είναι γενικά χρήσιμη για να δούμε με τι ρυθμό βελτιώνεται το μοντέλο και βοηθάει τους ερευνητές να ρυθμίσουν (fine-tune) τις υπερπαραμέτρους του μοντέλου. Παρατηρείται ότι με το πέρας των εποχών το σφάλμα μειώνεται, καθώς το μοντέλο βελτιώνεται.



**Εικόνα 35:** Η γραφική παράσταση του σφάλματος εκπαίδευσης για το DNN

**Πίνακας 7:** Αναφορά ταξινόμησης για τη μέθοδο Artificial Neural Network(ANN)

Label	Precision	Recall	F1-score	Accuracy
0	0.93	0.94	0.94	0.93
1	0.94	0.93	0.94	



**Εικόνα 36:** Πίνακας σύγχυσης


## 5.2 Αποτελέσματα για το σύνολο δεδομένων MZVAV-1

Στο σύνολο δεδομένων MZVAV-1 εφαρμόστηκε η μέθοδος δυαδικής ταξινόμησης με πρόβλεψη χρονοσειράς με τη βοήθεια αναδρομικού νευρωνικού δικτύου LSTM. Ακολουθήθηκε μία διαφορετική προσέγγιση από τις προηγούμενες μεθόδους, λόγω της μεγάλης ετερογένειας στο σύνολο δεδομένων. Οι τιμές μετρήσεων που αντιστοιχούν σε λειτουργία με σφάλμα είναι δραματικά περισσότερες από τις τιμές που το μοντελοποιημένο σύστημα λειτουργεί φυσιολογικά.

Οι νευρώνες μακράς-βραχυπρόθεσμης μνήμης έχουν προταθεί σαν πολλά υποσχόμενοι στο κομμάτι της ανίχνευσης σφαλμάτων, ακόμη και για να προβλέψουν πότε στο μέλλον αναμένεται να αστοχήσει κάποιο στοιχείο του εξοπλισμού [76]. Αυτό γίνεται αντιληπτό και από τα αποτελέσματα που προέκυψαν, τα οποία δεν φαίνονται ίσως τόσο καλά σε σχέση με τα αποτελέσματα των προηγούμενων μεθόδων, όμως παρέχουν ένα πιο ρεαλιστικό πλαίσιο που θα μπορούσε να βρει εφαρμογή σε ένα πραγματικό σύστημα.

**Πίνακας 8:** Αναφορά ταξινόμησης για τη μέθοδο LSTM


Label	Precision	Recall	F1-score	Accuracy
0	0.68	0.72	0.70	0.89
1	0.93	0.91	0.94	



**Εικόνα 37:** Πίνακας σύγχυσης για το μοντέλο LSTM

Το μοντέλο αυτό προβλέπει το αν υπάρχει σφάλμα ή όχι βασισμένο σε ιστορικά στοιχεία για την προηγούμενη χρονική στιγμή. Ο **πίνακας 8** δείχνει ότι το μοντέλο διαφέρει αρκετά από αυτά που παρουσιάστηκαν προηγουμένως, όμως είναι πιο ρεαλιστική η απόδοση που πετυχαίνει με τα δεδομένα που ήταν διαθέσιμα. Όπως διακρίνεται από τον πίνακα σύγχυσης (**εικόνα 37**), ο αλγόριθμος καταφέρνει να εντοπίσει την πλειονότητα των σφαλμάτων στο σύστημα, αλλά επιμένει να ταξινομεί λανθασμένα μεγάλο ποσοστό των περιπτώσεων σωστής λειτουργίας, παράγοντας False Positives (FP).

Αυτό θα μπορούσε να ισχύει και από την αντίστροφη οπτική. Για παράδειγμα σε μία μονάδα AHU που παρουσιάζει ομαλή λειτουργία, αλλά ξαφνικά εμφανίζεται μια βλάβη σε κάποιο μηχανικό στοιχείο, που αλλάζει την απόδοση του συστήματος παροχής αέρα, θα καταγράφονταν δείγματα εσφαλμένης λειτουργίας τα οποία στην αρχή μπορεί να περνούσαν απαρατήρητα από το αυτοματοποιημένο σύστημα ελέγχου (automated fault detection system). Παρόλα αυτά, είναι πολύ πιθανό με το πέρασμα της ώρας (και θεωρώντας ότι η δειγματοληψία γίνεται ανά 1 λεπτό, οπότε τα δείγματα είναι κοντά χρονικά) θα εντοπιζόταν το σφάλμα και θα παρήγαγε την κατάλληλη ειδοποίηση στον υπεύθυνο επιτήρησης του συστήματος. Κάποιες προτάσεις και ιδέες, καθώς και έρευνες που έχουν γίνει για τη βελτίωση ενός τέτοιου συστήματος θα δοθούν στο επόμενο, καταληκτικό κεφάλαιο.



**Εικόνα 38:** Η καμπύλη ROC αποτελεί ένδειξη της επικάλυψης των κατανομών True Positive και True Negative τιμών. Όταν το AUC είναι 0.85, αυτό σημαίνει ότι το μοντέλο έχει πιθανότητα 85% να ξεχωρίσει την κλάση 0 (Normal) από την κλάση 1 (Faulty).



## Κεφάλαιο 6. Επίλογος

Η ενεργειακή κατανάλωση ενός κτιρίου είναι ένα πολύπλοκο σύστημα που περιλαμβάνει πολλά στοιχεία όπως οι μονάδες θέρμανσης, ψύξης και κλιματισμού (HVAC), οι εγκαταστάσεις φωτισμού, ανέλκυσης, ασφάλειας κ.τ.λ. Τα τελευταία χρόνια μεγάλη προσπάθεια έχει στραφεί σε μεθόδους που θα επιτρέψουν την αυτόνομη διαχείριση σπιτιών και κτιρίων γενικότερα. Η μετάβαση από το παραδοσιακό δίκτυο διανομής στα έξυπνα δίκτυα αποτέλεσε ένα πρώτο βήμα, ενώ οι τεχνικές αυτές διευρύνονται ώστε να περιλάβουν και νέες λειτουργικότητες, όπως η ανίχνευση βλαβών στα συστήματα που αποτελούν ένα κτίριο, όπως το σύστημα HVAC.

Τυπικά, η παρακολούθηση της απόδοσης του συστήματος και ο εντοπισμός σφαλμάτων πραγματοποιούνται από τεχνικούς εμπειρογνώμονες, διαδικασία που είναι αργή και αφήνει πίσω πολλά προβλήματα απαρατήρητα, ή ακόμη και αγνοούμενα. Η αποτελεσματική ενσωμάτωση αυτομάτων και απομακρυσμένων μεθοδολογιών ικανών να εντοπίζουν σφάλματα άμεσα όταν συμβαίνουν, θα άλλαζε πολύ το τοπίο. Επιπλέον, η ειδοποίηση και η επικοινωνία άμεσα με το προσωπικό συντήρησης σε μια απλή γλώσσα, που θα περιέγραφε το σφάλμα και την έντασή του, είναι στοιχεία πολύ επιθυμητά. Ένα τέτοιο σύστημα θα μείωνε δραματικά το κόστος για προγραμματισμένο έλεγχο (service) ανά τακτά διαστήματα, μειώνοντας τον εργατικό κόπο, τη σπατάλη ενέργειας και την ενεργειακή ζήτηση κατά τις ώρες αιχμής.

Οι πειραματικές διαδικασίες που εφαρμόστηκαν σε αυτή την εργασία είχαν στόχο να δείξουν την προοπτική που παρουσιάζουν οι μέθοδοι μηχανικής μάθησης στο πεδίο της πρόβλεψης σφαλμάτων, ειδικά στον τομέα των συστημάτων HVAC. Οι μέθοδοι που εφαρμόστηκαν στο πρώτο, ισορροπημένο σύνολο δεδομένων είχαν πιο πολύ εκπαιδευτικό σκοπό, αλλά και να αναδείξουν τις δυνατότητες και τις αδυναμίες κάποιων πιο κλασικών τεχνικών μηχανικής μάθησης, οι οποίες μπορούν να αποτελέσουν κομμάτι ενός πραγματικού μοντέλου, ειδικά σε συνδυασμένες (ensemble) μεθόδους. Όπως αναδείχθηκε, οι τεχνικές που συνδυάζουν τη μέθοδο boosting, όπως η Gradient Boosting, μπορούν να αυξήσουν την απόδοση τέτοιων αλγορίθμων. Τα συγκεντρωμένα δέντρα (ensemble trees) έχουν αποκτήσει φήμη σε διαδικασίες ταξινόμησης και τείνουν να αποδίδουν σε μια μεγάλη γκάμα εφαρμογών. Η μέθοδος boosting όταν εφαρμόζεται σε δέντρα, αποδίδει καλά ακόμη και όταν τα σύνολα δεδομένων δεν είναι ισορροπημένα. Στην ουσία “τιμωρεί” τις μη ορθές ταξινομήσεις αναθέτοντας τους μεγαλύτερα βάρη, και αυτός είναι ένας πολύ καλός τρόπος να αντιμετωπιστεί το πρόβλημα των ετερογενών συνόλων δεδομένων. Ιδιαίτερα η μέθοδος XGBoost παρουσιάζει προοπτική και θα μπορούσαν να αναπτυχθούν μοντέλα βασισμένα σε αυτή καθώς καταφέρνει τα παραπάνω με χαμηλότερο υπολογιστικό κόστος και μεγαλύτερη ευρωστία στην υπερπροσαρμογή.

Η χρήση ενός βαθιού νευρωνικού δικτύου για την εξαγωγή χρήσιμων χαρακτηριστικών και την ορθή ταξινόμηση των δειγμάτων, πέτυχε πολύ καλά αποτελέσματα, παρόλα αυτά μπορούν να δοκιμαστούν πολλές τοπολογίες που ενδεχομένως να φτάσουν ή και να ξεπεράσουν τη μέθοδο Gradient Boost. Για παράδειγμα, τα συνελκτικά δίκτυα (Convolutional, CNN), αν και συνήθως χρησιμεύουν σε εφαρμογές εικόνων, θα μπορούσαν να εφαρμοστούν και εδώ σε κάποιο στρώμα, καθώς οι χρονοσειρές που παράγονται από τους αισθητήρες είναι στην ουσία διδιάστατοι πίνακες, όπως οι εικόνες.

Η μέθοδος με τη χρήση του νευρωνικού δικτύου LSTM σε ένα σύνολο δεδομένων με τεράστια διαφορά στην κατανομή των σφαλμάτων και τον ομαλών σημείων, αναδεικνύει ότι τα αναδρομικά νευρωνικά δίκτυα με μνήμη, έχουν πολύ μεγάλες δυνατότητες σε δεδομένα χρονοσειρών, και μπορούν να εξάγουν αξιόπιστα μοντέλα για χρήση σε πραγματικές, μη ιδανικές συνθήκες. Οι συνθήκες στις οποίες δουλεύει ένα μοντέλο είναι πολύ σημαντικός παράγοντας για την αξιοπιστία και την εφαρμοσιμότητα ενός συστήματος αυτόνομης διαχείρισης/ελέγχου. Τα δεδομένα που λαμβάνονται σε ένα πραγματικό κτίριο ή έξυπνο σπίτι, μπορεί να παρουσιάζουν κενές τιμές, ή να μη λειτουργούν αποδοτικά για μεγάλο χρονικό διάστημα και αυτό θα πρέπει να είναι σε θέση να το εντοπίσει το μοντέλο. Τα αναδρομικά κύτταρα με μνήμη είναι ιδανικά για αυτή την εφαρμογή, καθώς διατηρούν ιστορικό του τί συνέβη στο παρελθόν και μπορούν να εξάγουν πολύ χρήσιμες και αρκετά ακριβείς προβλέψεις για το μέλλον. Έχουν προταθεί συνδεσμολογίες που περιλαμβάνουν νευρώνες LSTM σε διάφορα βάθη, και έχει βρεθεί ότι μεγαλύτερο βάθος δε σημαίνει απαραίτητα καλύτερη ικανότητα διάκρισης. Συνήθως δύο με τρία επίπεδα νευρώνων παράγουν τα καλύτερα αποτελέσματα [76], οπότε από εκεί και έπειτα έμφαση πρέπει να δοθεί κυρίως στη σωστή ρύθμιση των διαφόρων υπερπαραμέτρων, παρακολουθώντας την πορεία του σφάλματος επικύρωσης (validation error) σε σχέση με το σφάλμα εκπαίδευσης (training error).

Τα αποτελέσματα της ανωτέρω πειραματικής διαδικασίας καταδεικνύουν ότι πράγματι είναι εφικτή η ανάπτυξη ενός αξιόπιστου μοντέλου HVAC FDD βασιζόμενοι αποκλειστικά σε ιστορικά δεδομένα του κτιρίου. Ωστόσο, η ανάληψη διαφόρων ενεργειών θα μπορούσε να βελτιώσει την απόδοση και να επεκτείνει τις δυνατότητες των μοντέλων που παρουσιάστηκαν.

Αρχικά, τα σύνολα δεδομένων αναφέρονταν σε πολλά χαρακτηριστικά, τα οποία δεν έχουν όλα την ίδια συσχέτιση με τη μεταβλητή εξόδου (το αν υπάρχει σφάλμα ή όχι). Σε αυτό το πρόβλημα, θα μπορούσε κάλλιστα να βοηθήσει ή εφαρμογή κάποιου βήματος μείωσης διαστάσεων ή δημιουργίας νέων χαρακτηριστικών (features) από τα ήδη υπάρχοντα. Η μέθοδος PCA που αναφέρθηκε στο κεφάλαιο 3, έχει αποδειχθεί ισχυρή σε αυτόν τον τομέα, ειδικά σε συνδυασμό με άλλες τεχνικές [30, 82]. Επίσης, βιβλιοθήκες όπως η tsfresh παρέχουν τη δυνατότητα να αναλυθούν τα ταξινομηθούν νέα χαρακτηριστικά ανάλογα με τη συσχέτιση που έχουν, και να επιλεγθούν τα καλύτερα για την εκπαίδευση του μοντέλου.

Ένας άλλος τρόπος προσέγγισης της ανίχνευσης σφαλμάτων σε HVAC είναι να θεωρηθεί ως ένα πρόβλημα ανίχνευσης ανωμαλιών (anomaly detection), αντί για απλής ταξινόμησης. Αυτή είναι μια τεχνική μη-επιβλεπόμενης μάθησης όπου γίνεται πρόβλεψη της μελλοντικής τιμής για τις τιμές που διαβάζουν οι αισθητήρες και συγκρίνει με τις φυσιολογικές τιμές που τίθενται από κάποιο κατώφλι (threshold), για να συμπεράνει αν η νέες τιμές είναι κανονικές ή όχι.

Η μη παρεμβατική παρακολούθηση φορτίου (NILM) είναι μία άλλη μέθοδος βασισμένη στα δεδομένα που θα μπορούσε να αξιολογηθεί για την ανίχνευση σφαλμάτων, με το να αναγνωρίζει πότε το σύστημα είναι κλειστό και πότε λειτουργεί. Η NILM μπορεί να μειώσει δραματικά το κόστος παρακολούθησης και διαγνωστικής ενός έξυπνου κτιρίου, στον τομέα των HVAC. Για παράδειγμα, ο αριθμός των εγκατεστημένων αισθητήρων σε συμβατικές μονάδες κλιματισμού (air-conditioner) θα μειωνόταν, μειώνοντας φυσικά και το κεφάλαιο που απαιτείται για την εγκατάσταση ενός αξιόπιστου συστήματος.

Ένα από τα σημαντικότερα ζητήματα που προκύπτουν στη διαδικασία δημιουργίας μοντέλων για ανίχνευση σφαλμάτων στα συστήματα HVAC είναι η ποιότητα των δεδομένων που αποθηκεύονται, όπως εξηγήθηκε σε προηγούμενες ενότητες. Επειδή είναι δύσκολο σε πραγματικά κτίρια να μοντελοποιηθούν φυσικά σφάλματα και να παρθούν μετρήσεις λειτουργίας σε μη ιδανική κατάσταση, τα σύνολα δεδομένων που προκύπτουν είναι σε μεγάλο βαθμό μη ισορροπημένα για να χρησιμοποιηθεί επιτηρούμενη μάθηση. Επομένως παρουσιάζει ενδιαφέρον η εφαρμογή τεχνικών αύξησης δεδομένων, ώστε να παραχθούν τιμές λειτουργίας με σφάλμα και να επέλθει ισορροπία στο εκάστοτε σύνολο δεδομένων. Έχουν προταθεί στη βιβλιογραφία τεχνικές που έχουν αυτή τη δυνατότητα, όπως η μέθοδος SMOTE ή ακόμη και τα παραγωγικά αντιπαραθετικά δίκτυα (Generative Adversarial Networks, GAN). Η μέθοδος SMOTE (Synthetic Minority Oversampling Technique) επιλέγει δείγματα που είναι κοντά μεταξύ τους στο χώρο των χαρακτηριστικών, χαράσσοντας μια γραμμή μεταξύ τους και δημιουργώντας νέα δείγματα με βάση αυτή τη γραμμή [82].

Τέλος, όσον αφορά τα δίκτυα μακράς βραχέας μνήμης (LSTM) τα οποία δοκιμάστηκαν σε αυτή την εργασία, θα μπορούσαν να γίνουν βελτιώσεις στο μοντέλο που παρουσιάστηκε, όπως το να λαμβάνει σαν είσοδο ένα μεγαλύτερο κυλιόμενο παράθυρο παρελθοντικών τιμών το οποίο θα επηρεάζει τις προβλέψεις, καθώς επίσης και να γίνει ρύθμιση των υπερπαραμέτρων με πιο μεθοδικό τρόπο. Πάντως ειδικά για δεδομένα που προκύπτουν από μετρητές, αισθητήρες κ.τ.λ και είναι σε μορφή χρονοσειράς, τα αναδρομικά νευρωνικά δίκτυα έχουν πολλές προοπτικές εφαρμογής στο κομμάτι που πραγματεύεται η εργασία.

Κλείνοντας, ο σκοπός της εργασίας ήταν να διερευνηθούν κάποιες πιθανές μεθοδολογίες μηχανικής μάθησης οι οποίες να μπορούν να εφαρμοστούν σε συστήματα κλιματισμού, και συγκεκριμένα σε HVAC, τα οποία είναι συνήθως πιο



σύνθετες διατάξεις και στα οποία τα λειτουργικά σφάλματα επηρεάζουν κατά πολύ την κατανάλωση ενέργειας. Οι μέθοδοι που δοκιμάστηκαν μπορούν κάλλιστα να εφαρμοστούν σε ένα γενικότερο πλαίσιο αυτόνομης ενεργειακής διαχείρισης, μιας και ο αυτοματοποιημένος έλεγχος σφαλμάτων σε μία έξυπνη οικία ή κτίριο αποτελεί ένα καίριο ζήτημα για τη σωστή συνολική λειτουργία. Έτσι, σε συνδυασμό με άλλες φιλοσοφίες που βρίσκουν γόνιμο έδαφος τα τελευταία χρόνια, όπως τα μικρο-δίκτυα (smart grids) και τα έξυπνα δίκτυα (smart grids), μπορούν να επιτευχθούν οι περιβαλλοντικοί και οικονομικοί στόχοι που επιτάσσουν οι συνθήκες, και που αποτελούν καίριο ζήτημα για το μέλλον της ανθρωπότητας και του πλανήτη.

## Βιβλιογραφία

1. Hong, T.; Koo, C.; Kim, J.; Lee, M.; Jeong, K. A review on sustainable construction management strategies for monitoring, diagnosing, and retrofitting the building's dynamic energy performance: Focused on the operation and maintenance phase. *Appl. Energy* 2015, 155, 671–707.
2. Seyedzadeh, S.; Pour Rahimian, F.; Glesk, I.; Roper, M. Machine learning for estimation of building energy consumption and performance: A review. *Vis. Eng.* 2018, 6, 5.
3. Li, Y.; O'Neill, Z. A critical review of fault modeling of HVAC systems in buildings. *Build. Simul.* 2018, 11, 953–975.
4. M.M. Ardehali, T. F. Smith, J.M. House, and C.J. Klaassen, “Building Energy Use and Control Problems: An Assessment of Case Studies”, *ASHRAE Transactions*, 2003, vol. 109, pt 2.
5. D.E. Claridge, C.H. Culp, M. Liu, S. Deng, W.D. Turner, and J.S. Haberl, “Campus Wide Continuous Commissioning of University Buildings”, In *Proceedings of the 2000 ACEEE Summer Study*, ACEEE, Washington, DC.
6. G. H. Cibse, “Building Control Systems”, Butterworth-Heinemann, Oxford, 2000
7. A.S. Willsky, “A Survey of Design Methods for Failure Detection in Dynamic Systems”, *Automatica*, 1976, 29: 601-611
8. L.F. Pau, “Failure Diagnosis and Performance Monitoring”, 1981, New York: Marcel Dekker
9. T.A. Reddy, D. Niebur, K.K. Andersen, P.P. Pericolo, and G. Cabrera, “Evaluation of the suitability of different chiller performance models for on-line training applied to automated fault detection and diagnosis”, *International Journal of Heating, Ventilating, Air Conditioning and Refrigerating Research*, 2003, 9(4)
10. “Improving Performance with Integrated Smart Buildings,” Dec. 2017. [Online]. Available: [http://www.facilitiesnet.com/emails/Building\\_Maximizer/Whitepaper/041912.asp](http://www.facilitiesnet.com/emails/Building_Maximizer/Whitepaper/041912.asp)
11. A. T.-p. So and W. L. Chan, “Applications in Electrical Systems,” in *Intelligent Building Systems*, ser. The International Series on Asian Studies in Computer and Information Science. Springer, Boston, MA, 1999, pp. 123–142.
12. S. Katipamula, M. R. Brambley, “Methods for fault detection, diagnostics, and prognostics for building systems – a review part 2”, *HVAC&R Research*, 2005, vol. 11, n2.
13. J. Cheng and T. Kunz, “A Survey on Smart Home Networking,” Carleton University, Systems and Computer Engineering,, Tech. Rep., Sep. 2009.
14. “Smart Building Market by Type & Region - Global Forecast 2022,” MarketsAndMarkets, UK, Technical Report TC 3445, Aug. 2017.
15. “Statista - The Statistics Portal for Market Data, Market Research and Market Studies.”

16. European Commission and Directorate-General for the Information Society and Media, ICT for a low carbon economy: smart electricity distribution networks. Luxembourg: EUR-OP, 2009
17. Zeeshan Bin Siddique, Mudassar Ali Khan, Ikram Ud Din, Ahmad Almogren, Irfan Mohiuddin, Shah Nazir, "Machine Learning-Based Detection of Spam Emails", *Scientific Programming*, vol. 2021, Article ID 6508784, 11 pages, 2021. <https://doi.org/10.1155/2021/6508784>
18. Djamel Djenouri, Roufaida Laidi, Youcef Djenouri, and Ilangko Balasingham. 2019. Machine Learning for Smart Building Applications: Review and Taxonomy. *ACM Comput. Surv.* 52, 2, Article 24 (March 2020), 36 pages. <https://doi.org/10.1145/3311950>
19. Abbaspour S, Fotouhi F, Sedaghatbaf A, Fotouhi H, Vahabi M, Linden M. A Comparative Analysis of Hybrid Deep Learning Models for Human Activity Recognition. *Sensors*. 2020; 20(19):5707. <https://doi.org/10.3390/s20195707>
20. Yongcai Wang, Xiaohong Hao, Lei Song, Chenye Wu, Yuexuan Wang, Changjian Hu, and Lu Yu. 2014. Monitoring Massive Appliances by a Minimal Number of Smart Meters. *ACM Trans. Embed. Comput. Syst.* 13, 2s (Jan 2014), 56:1–56:20.
21. Global Status Report towards a Zero-Emission, Efficient and Resilient Buildings and Construction Sector
22. Yang, H.; Zhang, T.; Li, H.; Woradechjumroen, D.; Liu, X. HVAC Equipment, Unitary: Fault Detection and Diagnosis; CRC Press: Boca Raton, FL, USA, 2014; pp. 854–864
23. Qin, J.; Wang, S. A fault detection and diagnosis strategy of VAV air-conditioning systems for improved energy and control performances. *Energy Build.* 2005, 37, 1035–1048
24. Katipamula, S.; Brambley, M.R. Review Article: Methods for Fault Detection, Diagnostics, and Prognostics for Building Systems— A Review, Part I. *HVACR Res.* 2005, 11, 3–25.
25. G. Evola and V. Popov, "Computational analysis of wind driven natural ventilation in buildings," *Energy and Buildings*, vol. 38, no. 5, pp. 491–501, 2006
26. ASHRAE, "ANSI/ASHRAE Standard 62.1-2007: Ventilation for Acceptable Indoor Air Quality," pp. 1–41, 2007
27. Yu, D. Woradechjumroen, and D. Yu, "A review of fault detection and diagnosis methodologies on air-handling units," *Energy and Buildings*, vol. 82, pp. 550 – 562, 2014.
28. P. Bayer, D. Saner, S. Bolay, L. Rybach, and P. Blum, "Greenhouse gas emission savings of ground source heat pump systems in europe: A review," *Renewable and Sustainable Energy Reviews*, vol. 16, no. 2, pp. 1256–1267, 2012
29. Tidriri, K.; Chatti, N.; Verron, S.; Tiplica, T. Bridging data-driven and model-based approaches for process fault diagnosis and health monitoring: A review of researches and future challenges. *Annu. Rev. Control* 2016, 42, 63–81.

30. Maurya, M.R.; Rengaswamy, R.; Venkatasubramanian, V. A Signed Directed Graph and Qualitative Trend Analysis-Based Framework for Incipient Fault Diagnosis. *Chem. Eng. Res. Des.* 2007, 85, 1407–1422.
31. Yan, K.; Zhong, C.; Ji, Z.; Huang, J. Semi-supervised learning for early detection and diagnosis of various air handling unit faults. *Energy Build.* 2018, 181, 75–83.
32. Cheng, “Heat Transfer in Geothermal Systems,” *Advances in Heat Transfer*, vol. 14, pp. 1–105, 1979.
33. Chandrashekar, G.; Sahin, F. A survey on feature selection methods. *Comput. Electr. Eng.* 2014, 40, 16–28.
34. L. E. Moser, P. M. Melliar-Smith, D. A. Agarwal, R. K. Budhia, and C. A. Lingley Papadopoulos, “Totem: a fault tolerant multicast group communication system,” *Communications of the ACM*, vol. 39, no. 4, pp. 54
35. Yan, K.; Shen, W.; Mulumba, T.; Afshari, A. ARX model based fault detection and diagnosis for chillers using support vector machines. *Energy Build.* 2014, 81, 287–295.
36. L. N. De Barros, M. Lemos, V. Bernal, and J. Wainer, “Model based diagnosis for network communication faults,” in *Proceedings of the International Workshop On Artificial Intelligence for Distributed Information Networking*,
37. R. Zhang and T. Hong, “Modeling of HVAC operational faults in building performance simulation,” *Applied Energy*, vol. 202, pp. 178–188, 2017.
38. B. Serrano and M. VélezReyes, “Nonlinear control of a heating, ventilating, and air conditioning system with thermal load estimation,” *IEEE Transactions on Control Systems Technology*, vol. 7, no. 1, pp. 56–63, 1999.
39. Álvarez, J. Redondo, E. Camponogara, J. NormeyRico, M. Berenguel, and P. Ortigosa, “Optimizing building comfort temperature regulation via model predictive control,” *Energy and Buildings*, vol. 57, pp. 361–372, 2013
40. J. Carreira, H. Madeira, and J. G. Silva, “Assessing the effects of communication faults on parallel applications,” in *Proceedings of the International Computer Performance and Dependability Symposium*. IEEE, 1995, pp. 214–223.
41. L. Ferrarini and G. Mantovani, “Modeling and control of thermal energy of a large commercial building,” in *Proceedings of the IEEE International Workshop on Intelligent Energy Systems (IWIES)*, 2013, pp. 149–154.
42. S. Fielsch, T. Grunert, M. Stursberg, and A. Kummert, “Model Predictive Control for Hydronic Heating Systems in Residential Buildings,” in *Proceedings of the 20th World Congress The International Federation of Automatic Control*, 2017, pp. 4216–4221

43. S. M. Attaran, R. Yusof, and H. Selamat, "A novel optimization algorithm based on epsilon constraintRBF neural network for tuning PID controller in decoupled HVAC system," *Applied Thermal Engineering*, vol. 99, no. 1, pp. 613–624, 2016.
44. M. Baranski, J. Fütterer, and D. Müller, "Development of a generic modelAssisted control algorithm for building HVAC systems," *Energy Procedia*, vol. 122, no. 1, pp. 1003–1008, 2017.
45. N. Fernandez, S. Katipamula, W. Wang, Y. Xie, M. Zhao, and C. Corbin, "Impacts of Commercial Building Controls on Energy Savings and Peak Load Reduction," *Pacific Northwest National Laboratory, Tech. Rep.*, 2017.
46. K. W. Roth, D. Westphalen, M. Y. Feng, P. Llana, and L. Quartararo, "Energy Impact of Commercial Building Controls and Performance Diagnostics: Market Characterization, Energy Impact of Building Faults and Energy Savings Potential," *U.S. Department of Energy, Tech. Rep.*, 2005
47. Zhao, Y.; Li, T.; Zhang, X.; Zhang, C. Artificial intelligence-based fault detection and diagnosis methods for building energy systems: Advantages, challenges and the future. *Renew. Sustain. Energy Rev.* 2019, 109, 85–101.
48. Wang, S.; Cui, J. Sensor-fault detection, diagnosis and estimation for centrifugal chiller systems using principal-component analysis method. *Appl. Energy* 2005, 82, 197–213.
49. Du, Z.; Jin, X. Detection and diagnosis for sensor fault in HVAC systems. *Energy Convers. Manag.* 2007, 48, 693–702.
50. Hu, Y.; Li, G.; Chen, H.; Li, H.; Liu, J. Sensitivity analysis for PCA-based chiller sensor fault detection. *Int. J. Refrig.* 2016, 63, 133–143.
51. Zhao, Y.; Wang, S.; Xiao, F. A statistical fault detection and diagnosis method for centrifugal chillers based on exponentially-weighted moving average control charts and support vector regression. *Appl. Therm. Eng.* 2013, 51, 560–572.
52. Beghi, A.; Brignoli, R.; Cecchinato, L.; Menegazzo, G.; Rampazzo, M.; Simmini, F. Data-driven Fault Detection and Diagnosis for HVAC water chillers. *Control Eng. Pract.* 2016, 53, 79–91.
53. Mahadevan, S.; Shah, S.L. Fault detection and diagnosis in process data using one-class support vector machines. *J. Process Control* 2009, 19, 1627–1639.
54. D. Ivanova, N. Valov, and M. Deyanov, "Application of the genetic algorithm for cascade control of a HVAC system," in *Proceedings of the MATEC Web of Conferences*, 2019, pp. 1-5.
55. C. Guo, Q. Song, and W. Cai, "A neural network assisted cascade control system for air handling unit," *IEEE Transactions on Industrial Electronics*, vol. 54, no. 1, pp. 620–628, 2007.
56. Zhang, H.; Chen, H.; Guo, Y.; Wang, J.; Li, G.; Shen, L. Sensor fault detection and diagnosis for a water source heat pump air-conditioning system based on PCA and preprocessed by combined clustering. *Appl. Therm. Eng.* 2019, 160, 114098.

57. Xiao, F.; Wang, S.; Zhang, J. A diagnostic tool for online sensor health monitoring in air-conditioning systems. *Autom. Constr.* 2005, 15, 489–503.
58. Zhao, Y.; Li, T.; Zhang, X.; Zhang, C. Artificial intelligence-based fault detection and diagnosis methods for building energy systems: Advantages, challenges and the future. *Renew. Sustain. Energy Rev.* 2019, 109, 85–101.
59. Dehestani, D.; Eftekhari, F.; Guo, Y.; Ling, S.; Su, S.; Nguyen, H. Online Support Vector Machine Application for Model Based Fault Detection and Isolation of HVAC System. *Int. J. Mach. Learn. Comput.* 2011, 1, 66–72.
60. Han, H.; Gu, B.; Hong, Y.; Kang, J. Automated FDD of multiple-simultaneous faults (MSF) and the application to building chillers. *Energy Build.* 2011, 43, 2524–2532.
61. Kriegel, H.P.; Schubert, M.; Zimek, A. Angle-Based Outlier Detection in High-Dimensional Data; ACM: New York, NY, USA, 2008.
62. Bode, G.; Thul, S.; Baranski, M.; Müller, D. Real-world application of machine-learning-based fault detection trained with experimental data. *Energy* 2020, 198, 117323.
63. Ebrahimifakhar, A.; Kabirikopaei, A.; Yuill, D. Data-driven fault detection and diagnosis for packaged rooftop units using statistical machine learning classification methods. *Energy Build.* 2020, 225, 110318.
64. Lee, D.; Lai, C.-W.; Liao, K.-K.; Chang, J.-W. Artificial intelligence assisted false alarm detection and diagnosis system development for reducing maintenance cost of chillers at the data centre. *J. Build. Eng.* 2020, 36, 102110.
65. Wang, H.; Chen, Y. A robust fault detection and diagnosis strategy for multiple faults of VAV air handling units. *Energy Build.* 2016, 127, 442–451.
66. Yu, Z.; Fung, B.C.; Haghighat, F.; Yoshino, H.; Morofsky, E. A systematic procedure to study the influence of occupant behavior on building energy consumption. *Energy Build.* 2011, 43, 1409–1417.
67. Liang, J.; Du, R. Model-based Fault Detection and Diagnosis of HVAC systems using Support Vector Machine method. *Int. J. Refrig.* 2007, 30, 1104–1114.
68. Suykens, J.A.K.; Vandewalle, J. Least Squares Support Vector Machine Classifiers. *Neural Process. Lett.* 1999, 9, 293–300.
69. Han, H.; Cui, X.; Fan, Y.; Qing, H. Least squares support vector machine (LS-SVM)-based chiller fault diagnosis using fault indicative features. *Appl. Therm. Eng.* 2019, 154, 540–547.
70. Van Every, P.M.; Rodriguez, M.; Jones, C.B.; Mammoli, A.A.; Martínez-Ramón, M. Advanced detection of HVAC faults using unsupervised SVM novelty detection and Gaussian process models. *Energy Build.* 2017, 149, 216–224.

71. Han, H.; Cao, Z.; Gu, B.; Ren, N. PCA-SVM-Based Automated Fault Detection and Diagnosis (AFDD) for Vapor-Compression Refrigeration Systems. *HVACR Res.* 2010, 16, 295–313.
72. Li, B.; Zhao, Y.-P. Simultaneous fault diagnosis for aircraft engine using multi-label learning. *Proc. Inst. Mech. Eng. Part I J. Syst. Control. Eng.* 2022, 09596518221085756.
73. Wu, B.; Cai, W.; Zhang, X. A fault detection model for air handling units based on the machine learning algorithms. In *Proceedings of the IECON 2020 The 46th Annual Conference of the IEEE Industrial Electronics Society*, Singapore, 18–21 October 2020; pp. 4789–4793.
74. Tran, D.A.T.; Chen, Y.; Jiang, C. Comparative investigations on reference models for fault detection and diagnosis in centrifugal chiller systems. *Energy Build.* 2016, 133, 246–256.
75. Afram, A.; Janabi-Sharifi, F.; Fung, A.S.; Raahemifar, K. Artificial neural network (ANN) based model predictive control (MPC) and optimization of HVAC systems: A state of the art review and case study of a residential HVAC system. *Energy Build.* 2017, 141, 96–113.
76. Taheri, S.; Ahmadi, A.; Mohammadi-Ivatloo, B.; Asadi, S. Fault detection diagnostic for HVAC systems via deep learning algorithms. *Energy Build.* 2021, 250, 111275.
77. Tang, F.; Kusiak, A.; Wei, X. Modeling and short-term prediction of HVAC system with a clustering algorithm. *Energy Build.* 2014, 82, 310–321.
78. Nelson, W.; Culp, C. Machine Learning Methods for Automated Fault Detection and Diagnostics in Building Systems —A Review. *Energies* 2022, 15, 5534.
79. Jakkula, V.; Cook, D. Outlier Detection in Smart Environment Structured Power Datasets. In *Proceedings of the 2010 Sixth International Conference on Intelligent Environments*, Kuala Lumpur, Malaysia, 19–21 July 2010; pp. 29–33.
80. Yuwono, M.; Guo, Y.; Wall, J.; Li, J.; West, S.; Platt, G.; Su, S.W. Unsupervised feature selection using swarm intelligence and consensus clustering for automatic fault detection and diagnosis in Heating Ventilation and Air Conditioning systems. *Appl. Soft Comput.* 2015, 34, 402–425.
81. Shun Li, Jin Wen, A model-based fault detection and diagnostic methodology based on PCA method and wavelet transform, *Energy and Buildings*, Volume 68, Part A, 2014, Pages 63-71,
82. Chawla NV, Bowyer KW, Hall LO, Kegelmeyer WP (2002) SMOTE: synthetic minority over-sampling technique. *J Artif Intell Res* 16:341–378
83. U. S. D. o. Energy, "Commercial Energy End-Use Splits, by Fuel Type (Quadrillion Btu)," *Building Energy Data Book*, 2010.
84. S. Treado and Y. Chen, "Saving Building Energy through Advanced Control Strategies," *Energies*, vol. 6, pp. 4769-4785, 2013.
85. Heather Chappells † & Elizabeth Shove ‡ (2005) Debating the future of comfort: environmental sustainability, energy consumption and the indoor environment, *Building Research & Information*, 33:1, 32-40, DOI: 10.1080/0961321042000322762

86. Damtoft, Jesper Sand & Lukasik, J. & Herfort, Duncan & Sorrentino, D. & Gartner, Ellis. (2008). Sustainable Development and Climate Change Initiatives. Cement and Concrete Research. 38. 115-127. 10.1016/j.cemconres.2007.09.008.
87. Laustsen, J. (2008) Energy Efficiency Requirements in Building Codes, Energy Efficiency Policies for New Buildings. International Energy Agency (IEA), Paris.
88. B. Qolomany et al., "Leveraging Machine Learning and Big Data for Smart Buildings: A Comprehensive Survey," in IEEE Access, vol. 7, pp. 90316-90356, 2019, doi: 10.1109/ACCESS.2019.2926642.
89. Νικόλαος Ι. Δούμουρας: Μη Παρεμβατική Παρακολούθηση Ηλεκτρικού Φορτίου Οικιακών Εγκαταστάσεων με χρήση Τεχνικών Μηχανικής Μάθησης, Διπλωματική εργασία, Αθήνα, Ιούλιος 2021
90. Djamel Djenouri, Roufaida Laidi, Youcef Djenouri, and Ilanko Balasingham. 2019. Machine Learning for Smart Building Applications: Review and Taxonomy. ACM Comput. Surv. 52, 2, Article 24 (March 2020), 36 pages. <https://doi.org/10.1145/3311950>
91. Md. Zubayer Ahmed Fahim: Predictive Maintenance of HVAC System using supervised Machine Learning Algorithms, Brac University, September 2021
92. Reviews and commentary on computational biology by Lior Pachter: What is principal component analysis?, <https://liorpachter.wordpress.com/2014/05/26/what-is-principal-component-analysis/>
93. Τσιάρα Αγγελική: Ταξινόμηση εικόνων με Τυχαία Δάση, μεταπτυχιακή εργασία ειδίκευσης, Ιωάννινα, Ιανουάριος 2012